

Directed Acyclic Graphs

Juan Martín Favetto

Primavera 2026

Intro

Repaso: Clase 1

- **Resultados potenciales**: Y_{1i}, Y_{0i} y el problema fundamental de inferencia causal (no observamos el camino no tomado).
- **Diferencia simple en resultados (SDO)** = ATT + sesgo de selección.
- **ATE vs. ATT**: no existe un único efecto del tratamiento, depende de para quién.
- **Asignación aleatoria**: $\{Y_{0i}, Y_{1i}\} \perp D_i \Rightarrow$ SDO = ATE.
- **Validez interna vs. externa**, ilustradas con STAR, RAND HIE y el experimento de Oregon (OHP).

Publica en un top journal siguiendo estos 4 simples pasos

1. Define qué efecto causal quieres estimar.
2. Haz explícitos los supuestos acerca del proceso generador de datos.

Publica en un top journal siguiendo estos 4 simples pasos

1. Define qué efecto causal quieres estimar.
2. Haz explícitos los supuestos acerca del proceso generador de datos.
3. En base a (1) y (2): elige la estrategia de identificación.

Publica en un top journal siguiendo estos 4 simples pasos

1. Define qué efecto causal quieres estimar.
2. Haz explícitos los supuestos acerca del proceso generador de datos.
3. En base a (1) y (2): elige la estrategia de identificación.
4. En base a (2): defiende los supuestos con checkeos de robustez.

Objetivo de esta clase

Identificar y hacer explicitos nuestros supuestos acerca del proceso de generación de datos. Para definir qué estamos buscando estimar y cómo estimarlo antes de comenzar el análisis.

Objetivos de la clase

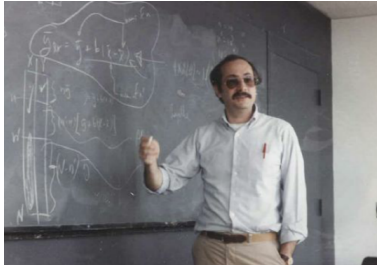
Al finalizar esta clase, van a entender:

- Qué son los DAGs y su notación básica
- La diferencia entre caminos causales y backdoor paths
- Qué son los confounders y los colliders
- El backdoor criterion para la identificación causal
- Cómo el collider bias puede confundir nuestro análisis
- Aplicaciones de los DAGs en el mundo real

Origen

Demasiado potencial

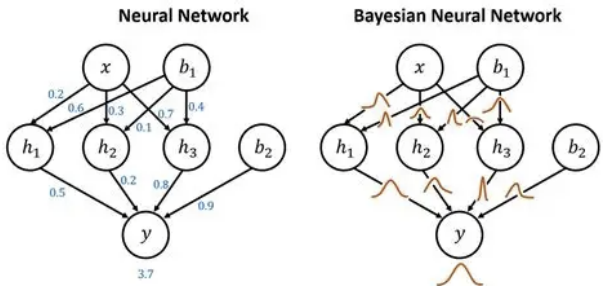
- Neyman (1923) y Rubin (años 70): modelo de resultados potenciales.
- La pregunta central: ¿qué le habría pasado a la misma persona en el otro estado del mundo?
- Sigue siendo el lenguaje dominante en economía aplicada.
- Límite: no ofrecía una forma gráfica de representar los supuestos causales.



Donald Rubin

La revolución de Judea Pearl

- Años 80–90: Pearl desarrolla las **redes bayesianas** para inteligencia artificial (no para economía).
- De ahí surgen los DAGs y conceptos que veremos hoy.



Ejemplo de red bayesiana

En economía

- Años 90 y 2000: la revolución de la credibilidad (Angrist, Imbens, Card).
- Se priorizaron experimentos, variables instrumentales, RD y DiD. Se miraba a los DAGs con cierto escepticismo.

- **Rubin**: ¿qué efecto queremos estimar?
- **Pearl**: ¿bajo qué supuestos podemos identificarlo?

Los DAGs complementan el enfoque de resultados potenciales haciendo explícitos los supuestos sobre el proceso generador de datos.

Fundamentos de los DAGs

¿Qué es un DAG?

Directed Acyclic Graph:

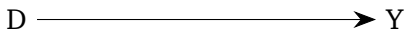
- **Directed (dirigido):** las flechas muestran la dirección de la causalidad
- **Acyclic (acíclico):** no hay ciclos, la causalidad fluye hacia adelante en el tiempo
- **Graph (grafíco):** representación visual de las relaciones

Componentes clave:

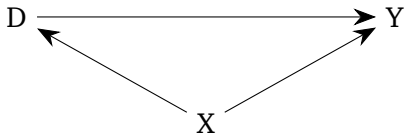
- **Nodos:** variables aleatorias (círculos)
- **Flechas:** relaciones causales (aristas dirigidas)
- **Flechas faltantes:** ausencia de relación asumida explícitamente

Los DAGs son dirigidos

Porque la causalidad es dirigida. Una causa no puede ocurrir después de una consecuencia.



Ejemplo básico de un DAG



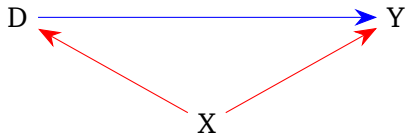
¿Qué nos dice esto?

- X causa tanto a D como a Y
- D causa a Y
- Hay DOS caminos de D a Y:
  1. Camino directo: $D \rightarrow Y$ (el efecto causal que queremos)
  2. Backdoor path: $D \leftarrow X \rightarrow Y$ (confounding)

Ejemplo básico de un DAG



El problema fundamental

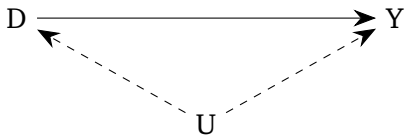


Cuando observamos correlación entre D e Y, esta contiene:

- **Camino causal:** efecto causal genuino (lo que queremos medir)
- **Backdoor path:** correlación espuria a través de X (confounding)

Objetivo: cerrar el backdoor path para aislar el efecto causal

Otro ejemplo básico de un DAG



¿Qué nos dice esto?

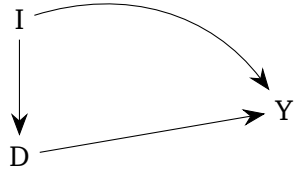
- D causa a Y
- U causa tanto a D como a Y, pero no es observada por quien investiga
- Como U no es observada, *el backdoor path no puede cerrarse controlando por U*

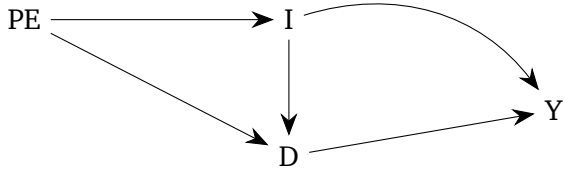
La educación abre puertas

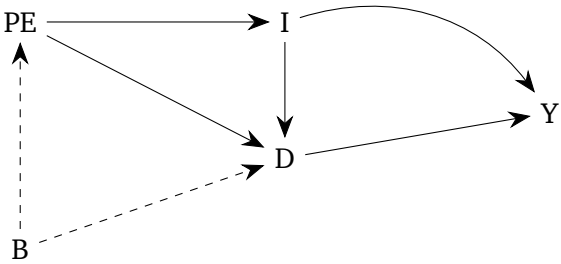
Becker (1994)

- La educación aumenta el producto marginal de una persona.
- En mercados competitivos, los trabajadores cobran su producto marginal ⇒ más educación implica mayores ingresos.
- Pero la educación universitaria no es aleatoria, se elige de manera óptima, dadas las preferencias y las restricciones de recursos de cada individuo.
- Para identificar el efecto causal de la educación sobre los ingresos necesitamos hacer explícitos nuestros supuestos sobre *cómo se elige* la educación.


D
Y

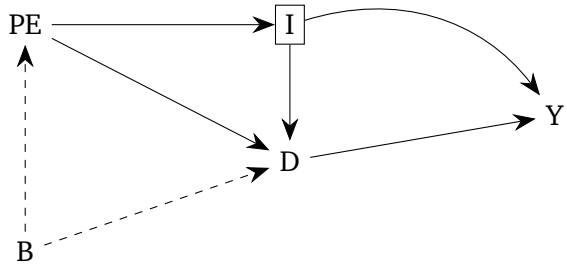

I
Y
D


PE
I
Y
D



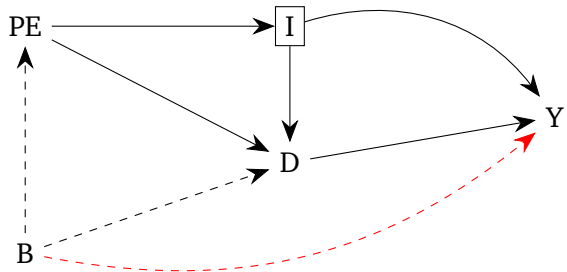
- ¿Qué está pasando?
- ¿Qué NO está pasando? ¿Cuáles son los supuestos?

El backdoor criterion

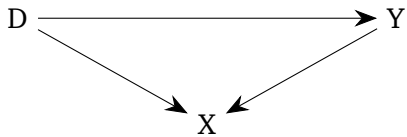


$$Y_i = \alpha + \delta D_i + \beta I_i + \varepsilon_i$$

¿Se cumplen los supuestos?



Cómo cerrar un backdoor path: los colliders lo cierran automáticamente



- X es un collider
- El backdoor path está cerrado.

Cómo cerrar un backdoor path: condicionar en un no-collider

Si tenemos un no-collider que genera un backdoor path abierto, podemos cerrarlo condicionando (controlando) por esa variable. Condicionar requiere mantener la variable fija usando algo como subclasificación, matching, regresión, u otro método. Es equivalente a “controlar por” la variable en una regresión.

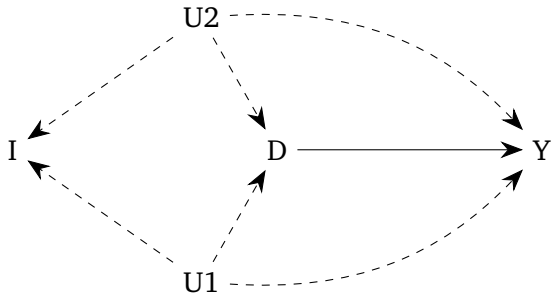
El backdoor criterion

Cuando todos los backdoor paths fueron cerrados, decimos que llegamos a un diseño de investigación que satisface el backdoor criterion.

Definición

Un conjunto de variables X satisface el backdoor criterion en un DAG si y solo si X bloquea todo camino entre confounders que contenga una flecha desde D hacia Y.

Un escenario más complejo



Malos Controles

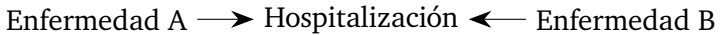


- X es un collider: dos flechas apuntan hacia X
- A y B pueden ser independientes entre sí
- Condicionar en X (controlar por X, o simplemente seleccionar una muestra según X) abre un camino entre A y B e induce una correlación espuria

Ejemplo simple



- En la población general, la apariencia y la habilidad son independientes
- El éxito es un collider
- Entre los que tienen éxito, la apariencia y la habilidad aparecen negativamente correlacionados.



- Las enfermedades A y B no tienen relación causal alguna en la población general
- Hospitalización es un collider: cualquiera de las dos enfermedades aumenta la probabilidad de estar internado
- Entre los pacientes hospitalizados — la muestra que suele usar un médico que no hizo este curso — A y B aparecen correlacionadas
- Nadie condicionó a propósito: alcanza con estudiar solo a quienes fueron testeados o internados

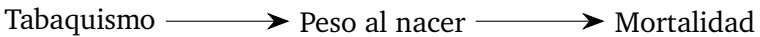
No creo que fumar le haga daño al bebé

Hernández-Díaz, Schisterman & Hernán (2006)

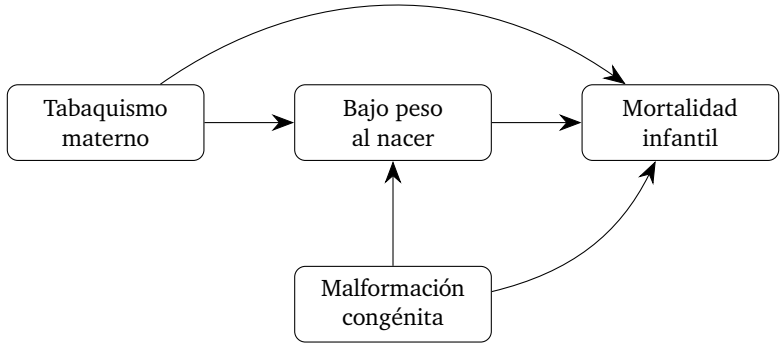
Con datos de más de 3 millones de nacimientos en Estados Unidos (1991):

- Sin ajustar, los bebés de madres fumadoras tienen 55% más mortalidad infantil que los de no fumadoras (Risk Ratio = 1.55).
- Pero entre los bebés de bajo peso (<2500g), el signo se invierte: RR = 0.79.

Hernández-Díaz, S., Schisterman, E. F., & Hernán, M. A. (2006). "The Birth Weight 'Paradox' Uncovered?" *American Journal of Epidemiology*, 164(11), 1115–1120.



- Si este fuera el DAG completo, controlar por peso debería anular el efecto de fumar (RR = 1).
- No es lo que vemos: el RR ajustado no es 1, y encima cambia de signo dentro del estrato de bajo peso.
- Falta algo en el DAG...


Tabaquismo materno
Bajo peso al nacer
Mortalidad infantil
Malformación congénita

La lección general

- Hay sesgo de selección al condicionar en una variable que (1) es afectada por la exposición y (2) comparte causas con el resultado — no hace falta que sea mediadora de un efecto verdadero.
- Para estimar el efecto total de fumar sobre la mortalidad, no hay que controlar por peso al nacer.
- El mismo patrón aparece con altitud y peso al nacer, o con enzimas hepáticas, alcoholismo y cáncer de hígado.
- Peso al nacer es un “bad control”.

Mortalidad por COVID-19

Ejemplo: mortalidad por COVID-19 (OpenSAFELY)

Williamson et al. (2020) usan datos de historias clínicas de más de 17 millones de adultos en Inglaterra (OpenSAFELY) para estudiar los factores asociados a la muerte por COVID-19.

"Factors associated with COVID-19-related death using OpenSAFELY." *Nature*, 584, 430–436.

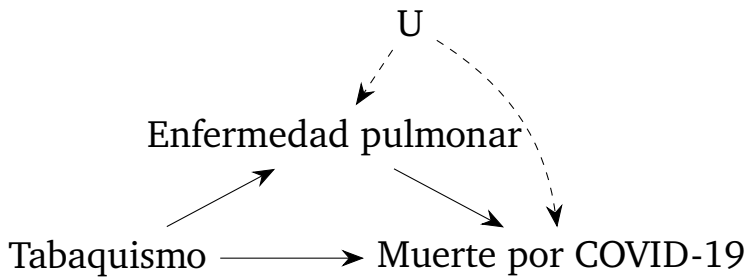
Table 2: Hazard ratios and 95% confidence intervals for COVID-19-related death

Characteristic	Category	COVID-19 death HR (95% CI)	
		Adjusted for age and sex	Fully adjusted
Age	18–39	0.05 (0.04–0.07)	0.06 (0.04–0.08)
	40–49	0.28 (0.23–0.33)	0.30 (0.25–0.36)
	50–59	1.00 (ref)	1.00 (ref)
	60–69	2.79 (2.52–3.10)	2.40 (2.16–2.66)
	70–79	8.62 (7.84–9.46)	6.07 (5.51–6.69)
	80+	38.29 (35.02–41.87)	20.60 (18.70–22.68)
Sex	Female	1.00 (ref)	1.00 (ref)
	Male	1.78 (1.71–1.85)	1.59 (1.53–1.65)
BMI (kg m^{-2})	Not obese	1.00 (ref)	1.00 (ref)
	30–34.9 (obese class I)	1.23 (1.17–1.30)	1.05 (1.00–1.11)
	35–39.9 (obese class II)	1.81 (1.68–1.95)	1.40 (1.30–1.52)
	≥40 (obese class III)	2.66 (2.39–2.95)	1.92 (1.72–2.13)
Smoking	Never	1.00 (ref)	1.00 (ref)
	Former	1.43 (1.37–1.49)	1.19 (1.14–1.24)
	Current	1.14 (1.05–1.23)	0.89 (0.82–0.97)

Table 2: Hazard ratios and 95% confidence intervals for COVID-19-related death

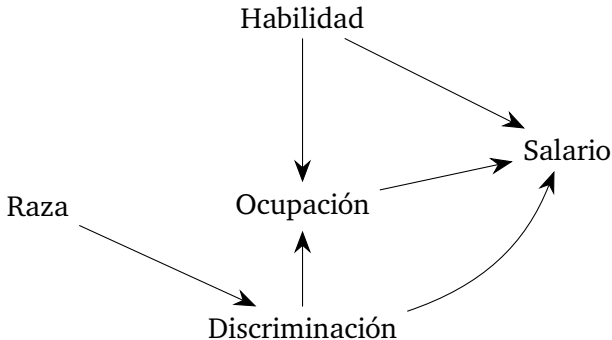
Characteristic	Category	COVID-19 death HR (95% CI)	
		Adjusted for age and sex	Fully adjusted
Age	18–39	0.05 (0.04–0.07)	0.06 (0.04–0.08)
	40–49	0.28 (0.23–0.33)	0.30 (0.25–0.36)
	50–59	1.00 (ref)	1.00 (ref)
	60–69	2.79 (2.52–3.10)	2.40 (2.16–2.66)
	70–79	8.62 (7.84–9.46)	6.07 (5.51–6.69)
	80+	38.29 (35.02–41.87)	20.60 (18.70–22.68)
Sex	Female	1.00 (ref)	1.00 (ref)
	Male	1.78 (1.71–1.85)	1.59 (1.53–1.65)
BMI (kg m^{-2})	Not obese	1.00 (ref)	1.00 (ref)
	30–34.9 (obese class I)	1.23 (1.17–1.30)	1.05 (1.00–1.11)
	35–39.9 (obese class II)	1.81 (1.68–1.95)	1.40 (1.30–1.52)
	≥40 (obese class III)	2.66 (2.39–2.95)	1.92 (1.72–2.13)
Smoking	Never	1.00 (ref)	1.00 (ref)
	Former	1.43 (1.37–1.49)	1.19 (1.14–1.24)
	Current	1.14 (1.05–1.23)	0.89 (0.82–0.97)

¿Por qué el efecto del tabaquismo actual cambia de signo?



Discriminación racial y salarios

Ejemplo: discriminación racial y salarios



Ejemplo: discriminación racial y salarios

	Variable dependiente: Salario		
	Efecto Total	Sesgo de Collider	Efecto Directo Verdadero
Negro	−3.029***	0.599***	−0.994***
	(0.086)	(0.030)	(0.029)
Ocupación		1.793***	0.992***
		(0.006)	(0.010)
Habilidad			2.006***
			(0.023)
Constante	2.118***	0.196***	1.011***
	(0.054)	(0.018)	(0.017)
Observaciones	10,000	10,000	10,000
R^2 ajustado	0.110	0.910	0.950

Nota: $^{*}p < 0.1$; $^{**}p < 0.05$; $^{***}p < 0.01$.

Referencias

Referencias I

- Becker, G. S. (1994). *Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education* (3. ed.). University of Chicago Press.
- Cunningham, S. (2021). Capítulo 3: *Directed Acyclic Graphs*. En *Causal Inference: The Mixtape* (pp. 96–118). Yale University Press.
- Hernández-Díaz, S., Schisterman, E. F., & Hernán, M. A. (2006). "The Birth Weight 'Paradox' Uncovered?" *American Journal of Epidemiology*, 164(11), 1115–1120. `https://doi.org/10.1093/aje/kwj275`
- Williamson, E. J., Walker, A. J., Bhaskaran, K., Bacon, S., Bates, C., Morton, C. E., et al. (2020). "Factors associated with COVID-19-related death using OpenSAFELY." *Nature*, 584, 430–436. `https://doi.org/10.1038/s41586-020-2521-4`

Lecturas

Lecturas

Causal Inference: The Mixtape
Cunningham, S. (2021)

- Capítulo 3 — *"Directed Acyclic Graphs"* **LINK** ***

Contacto

Contacto

Email

juanifavetto@gmail.com

Teléfono

+54 9 2972 40-8438

Por favor evitar usar el webcampus