

Selección en Observables

Juan Martín Favetto

Primavera 2026

Subclasificación

¿Cuál es el efecto de fumar en la mortalidad?

- Tal vez las personas que fumaban cigarrillo difieren de los no fumadores en aspectos directamente relacionados con la incidencia de cáncer de pulmón.
- Ya vimos que un experimento controlado asegura que los resultados potenciales sean independientes del tratamiento y, por lo tanto, la diferencia de medias nos da el efecto causal.
- En casos como este, no podemos hacer un experimento controlado. Pero tal vez el grupo de tratamiento y de control difieren en un conjunto de características observables.
- Un supuesto que justifica la interpretación causal de nuestras estimaciones en casos como estos es el llamado supuesto de **independencia condicional** o **selección en observables**.

Definition

Conditional Independence Assumption

$$(Y_{1i}, Y_{0i}) \perp\!\!\!\perp D_i \quad | \quad X_i$$

THE EFFECTIVENESS OF ADJUSTMENT BY SUBCLASSIFICATION IN REMOVING BIAS IN OBSERVATIONAL STUDIES

W. G. COCHRAN

Harvard University, Cambridge, Mass., U. S. A.

DEATH RATES PER 1,000 PERSON-YEARS

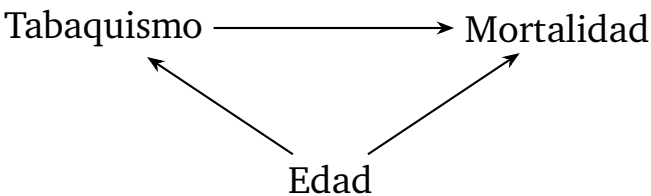
Smoking group	Study		
	Canadian	British	U. S.
Non-smokers	20.2	11.3	13.5
Cigarettes only	20.5	14.1	13.5
Cigars, pipes	35.5	20.7	17.4

Desbalance de covariables

MEAN AGES, YEARS

Smoking group	Study		
	Canadian	British	U. S.
Non-smokers	54.9	49.1	57.0
Cigarettes only	50.5	49.8	53.2
Cigars and/or pipe	65.9	55.7	59.7

Sesgo de variables omitidas



Independencia Condicional

- Recordemos que

$$SDO = \alpha_{ATT} + \mathbb{E}[Y_{0i}|D = 1] - \mathbb{E}[Y_{0i}|D = 0]$$

- En este caso, como los que fuman son jóvenes, el sesgo de selección es negativo.
- En este caso, la simple comparación de medias podría estar subestimando el efecto de fumar sobre la salud: $SDO < \alpha_{ATT}$.
- El supuesto de IC implicaría que los dos grupos son comparables una vez que condicionamos en un conjunto de observables, en este caso, la edad:

$$\mathbb{E}[Y_{0i}|D = 1, X_i] = \mathbb{E}[Y_{0i}|D = 0, X_i]$$

Efecto individual del tratamiento

- Bajo IC, el efecto del tratamiento “ceteris paribus” sobre un individuo pasa a ser la comparación condicional

$$\mathbb{E}[Y_i \mid D_i = 1, X_i = x] - \mathbb{E}[Y_i \mid D_i = 0, X_i = x]$$

- Esto es, la esperanza condicional de Y_i dado D_i, condicional en $X_i = x$.
- **Lo que estamos haciendo es comparar dentro de grupos que tienen el mismo valor de X_i.**

Subclasificación

¿Cómo logra la subclasificación el balance de covariables?

1. Dividir la edad en estratos.
2. Calcular la tasa de mortalidad del grupo de tratamiento (fumadores de cigarette) por estrato (en este caso, edad).
3. Ponderar la tasa de mortalidad del grupo de tratamiento por un peso específico de cada estrato (edad) que corresponde al grupo de control.

Esto nos da la tasa de mortalidad del grupo de tratamiento ajustada por edad.

Paso 1: Dividir la edad en estratos.

	Death rates	Number of	
	Cigarette smokers	Cigarette smokers	Pipe or cigar smokers
Age 20–40	20	65	10
Age 41–70	40	25	25
Age ≥ 71	60	10	65
Total		100	100

Paso 2: Calcular la tasa de mortalidad del grupo de tratamiento.

	Death rates	Number of	
	Cigarette smokers	**Cigarette smokers**	Pipe or cigar smokers
Age 20–40	20	**65**	10
Age 41–70	40	**25**	25
Age ≥ 71	60	**10**	65
Total		100	100

$$20 \times \frac{\mathbf{65}}{100} + 40 \times \frac{\mathbf{25}}{100} + 60 \times \frac{\mathbf{10}}{100} = 29$$

Paso 3: Ponderar la tasa de mortalidad del grupo de tratamiento por un peso específico de cada estrato (edad) que corresponde al grupo de control.

	Death rates	Number of	
	Cigarette smokers	Cigarette smokers	**Pipe or cigar smokers**
Age 20–40	20	65	**10**
Age 41–70	40	25	**25**
Age ≥ 71	60	10	**65**
Total		100	100

$$20 \times \frac{\mathbf{10}}{100} + 40 \times \frac{\mathbf{25}}{100} + 60 \times \frac{\mathbf{65}}{100} = 51$$

Paso 3: Ponderar la tasa de mortalidad del grupo de tratamiento por un peso específico de cada estrato (edad) que corresponde al grupo de control.

Table: Adjusted mortality rates using three age groups.

Smoking group	Canada	UK	US
Non-smokers	20.2	11.3	13.5
Cigarettes	29.5	14.8	21.2
Cigars/pipes	19.8	11.0	13.7

Emparejamiento (matching) y regresión

"Regression based causal inference is predicated on the assumption that when key observed variables have been made equal across treatment and control groups, selection bias from the things we can't see is also mostly eliminated."

– Angrist y Pischke, *Mastering Metrics*

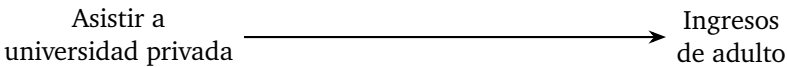
Ejemplo: Retornos de universidades privadas

- Actualmente, algunos alumnos de la UCEMA pagan arriba de 15.000usd al año para cursar acá.
- Mientras tanto, la universidad pública es gratuita.
- La UCEMA puede tener varias ventajas, pero una diferencia de 15.000usd al año debería hacer que nos preguntemos si realmente vale la pena.
- ¿Cuál es la pregunta causal?

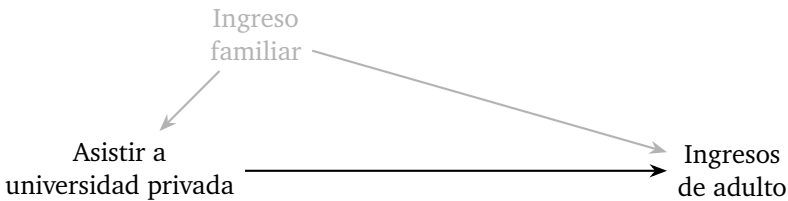
Ejemplo: Retornos de universidades privadas

- El estudio de Dale y Krueger (DK; 2002) analiza la diferencia en los ingresos entre los graduados de universidades más y menos selectivas, medida por los puntajes promedio del SAT en sus escuelas.
- Entonces el tratamiento es la graduación en una escuela privada.
- Las comparaciones entre los graduados de escuelas privadas y estatales muestran consistentemente mayores ingresos para aquellos que fueron a las privadas.
- Por otro lado, parte de la diferencia en los ingresos es atribuible a las diferencias en las características de las personas que asistieron a escuelas privadas y las que no.

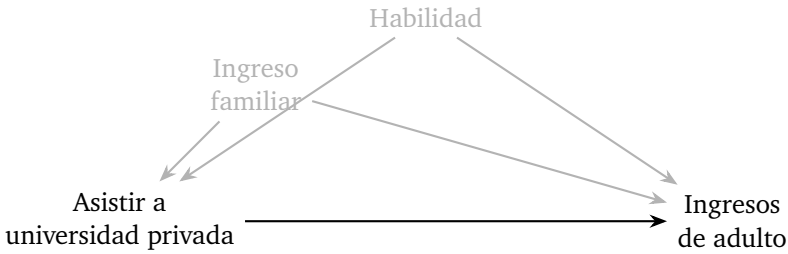
Retornos a la universidad privada



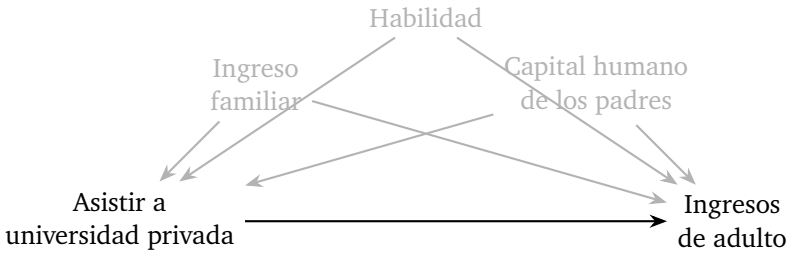
Retornos a la universidad privada



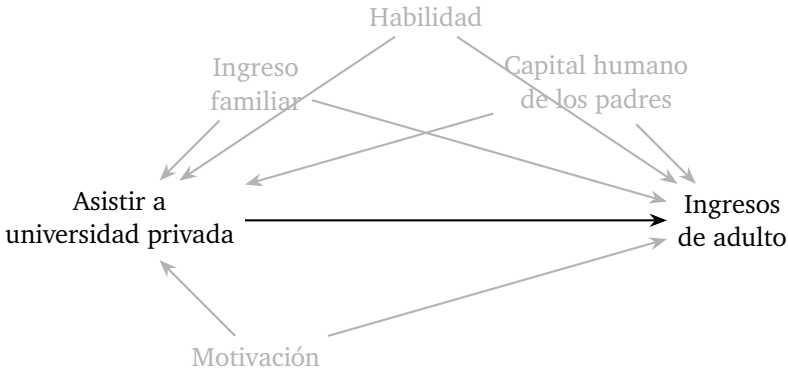
Retornos a la universidad privada



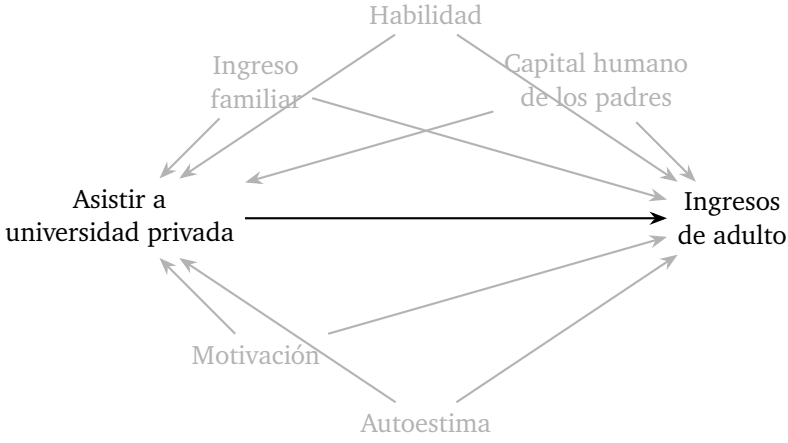
Retornos a la universidad privada



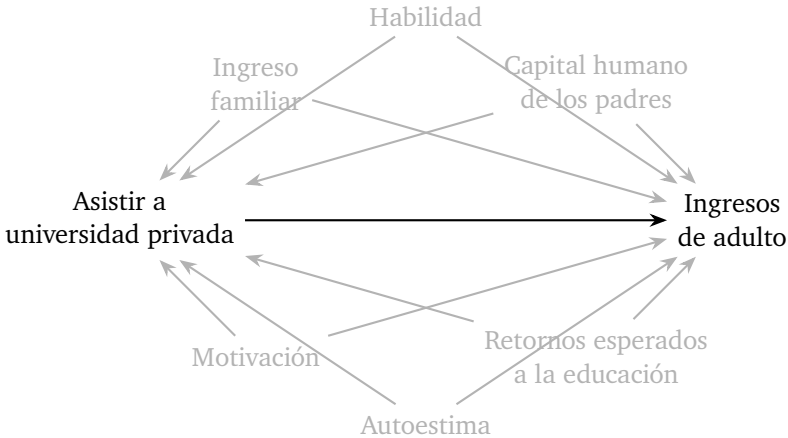
Retornos a la universidad privada



Retornos a la universidad privada



Retornos a la universidad privada



Retornos de universidades privadas

- Variables que probablemente difieran con el tipo de escuela incluyen:
  - los propios puntajes SAT de los estudiantes (que se correlacionan con sus ingresos),
  - los tipos de escuela a las que se postularon (lo que dice algo sobre los propios juicios de los estudiantes sobre su capacidad),
  - los ingresos familiares (que también se correlacionan con los ingresos de adulto).
- Considera un conjunto hipotético de solicitantes, todos los cuales aplicaron a una o más escuelas...

Table 2.1: The college matching matrix

		Private			Public			
Applicant group	Student	Ivy	Leafy	Smart	All State	Tall State	Altered State	1996 earnings
A	1		Reject	**Admit**		Admit		110,000
A	2		Reject	**Admit**		Admit		100,000
A	3		Reject	Admit		**Admit**		110,000
B	4	**Admit**			Admit		Admit	60,000
B	5	Admit			Admit		**Admit**	30,000
C	6		**Admit**					115,000
C	7		**Admit**					75,000
D	8	Reject			Admit	**Admit**		90,000
D	9	Reject			**Admit**	Admit		60,000

Nota: la decisión efectiva de inscripción se muestra en negrita. Fuente: Angrist y Pischke (2015), Mastering Metrics, cap. 2.

Matriz de postulación y asistencia a universidades

- Cinco de los nueve estudiantes (números 1,2,4,6,7) asistieron a escuelas privadas.
- Las ganancias promedio en este grupo son de $92,000.
- Los otros cuatro, con ingresos promedio de $72,500, fueron a una escuela pública.
- La brecha de casi $20,000 entre estos dos grupos sugiere una gran ventaja de la escuela privada.

Comparaciones y efectos causales

- Condicionando en la selectividad (dónde apliqué, dónde me admitieron), comparamos dentro de cada grupo:
  - grupo A: los estudiantes 1 y 2 (privada) contra el 3 (pública) → −\$5.000
  - grupo B: el estudiante 4 (privada) contra el 5 (pública) → \$30.000
- Descartamos C y D: no hay variación de tratamiento (en C todos van a privada, en D todos a pública)no e.
- El promedio ponderado de la brecha del grupo A y grupo B es $\left(\frac{3}{5} \times -5,000\right) + \left(\frac{2}{5} \times 30,000\right) = \$9{,}000$: el estimador de *matching within-group*.

Regresión

- Si tenemos un dataset como el de la tabla 2.1 y descartamos los grupos que no sirven, con una sola variable de control, A_i (dummy para el grupo A, $A_i = 1$ si fui a la privada), se puede escribir la regresión de interés:

$$Y_i = \alpha + \beta P_i + \gamma A_i + \varepsilon_i$$

- El uso de datos para los cinco estudiantes en los Grupos A y B genera $\beta = 10.000$ y $\gamma = 60.000$.
- El coeficiente de la escuela privada en este caso es de 10.000, cerca del que obtuvimos promediando las brechas dentro de los grupos A y B y muy por debajo de la diferencia bruta público-privada de casi 20.000.

Función de Valor Esperado Condicional

Función de Valor Esperado Condicional (CEF)

- Una regresión se basa en la Función de Valor Esperado Condicional (CEF).
- La CEF para una variable dependiente Y_i, dado un vector de covariables X_i es la esperanza o el promedio poblacional de Y_i cuando X_i se mantiene fijo.
- La CEF se escribe como $\mathbb{E}[Y_i \mid X_i]$ y es una función de X_i.
- Si D_i es una variable binaria, la CEF toma dos valores: $\mathbb{E}[Y_i \mid D_i = 1]$ y $\mathbb{E}[Y_i \mid D_i = 0]$.
- Aunque este caso especial es importante, a menudo estamos interesados en CEF que son funciones de muchas variables, que se representan convenientemente en el vector X_i.
- Para un valor específico de X_i, digamos $X_i = x$, escribimos $\mathbb{E}[Y_i \mid X_i = x]$.

CEF de salarios dado años de educación

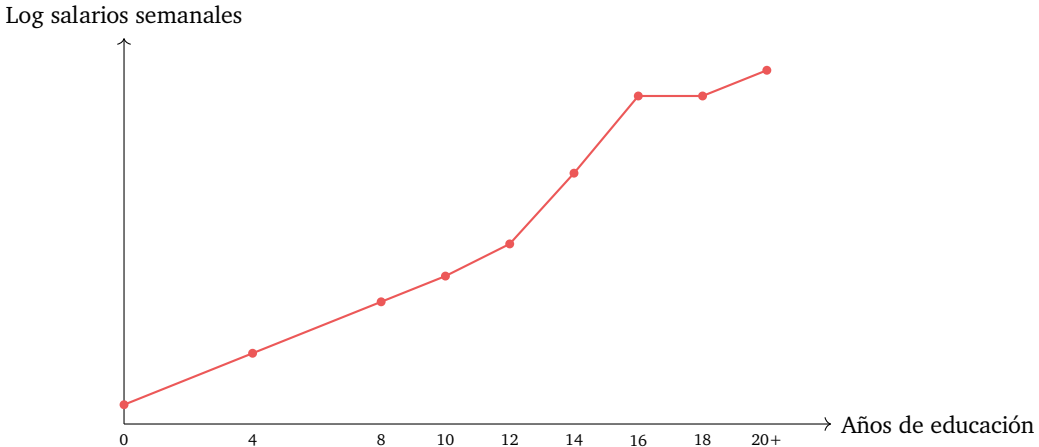


Figura 3.1.1 (aproximación): la CEF de log salarios semanales dado años de educación.
Fuente: Angrist y Pischke (2015), Mastering Metrics.

Ley de las Expectativas Iteradas

- Una esperanza incondicional se puede expresar como el promedio poblacional de la CEF:

$$\mathbb{E}[Y_i] = \mathbb{E}\{\mathbb{E}[Y_i|X_i]\}$$

- La esperanza externa promedia los valores de la CEF usando la distribución de X_i: es un "promedio de promedios", ponderado por qué tan frecuente es cada grupo de X_i en la población.

Descomposición de la CEF

Definimos el residuo de la CEF como

$$\epsilon_i \equiv Y_i - \mathbb{E}[Y_i|X_i]$$

de donde sale la identidad

$$Y_i = \mathbb{E}[Y_i|X_i] + \epsilon_i$$

Despejando,

$$\begin{aligned}\mathbb{E}[\epsilon_i|X_i] &= \mathbb{E}\big[\, Y_i - \mathbb{E}[Y_i|X_i] \,\big|\, X_i \,\big] \\ &= \mathbb{E}[Y_i|X_i] - \mathbb{E}\big[\mathbb{E}[Y_i|X_i] \,\big|\, X_i\big] \\ &= \mathbb{E}[Y_i|X_i] - \mathbb{E}[Y_i|X_i] \;=\; 0\end{aligned}$$

El residuo: media condicional cero

$$\mathbb{E}[\epsilon_i | X_i] = 0$$

- Es más fuerte que $\mathbb{E}[\epsilon_i] = 0$: vale en cada grupo de X_i, no solo en promedio general sobre toda la población.
- Ningún subgrupo de X_i tiene error sistemático positivo o negativo, no hay cancelación entre grupos.

Consecuencia

Aplicando la Ley de Expectativas Iteradas a ϵ_i:

$$\mathbb{E}[\epsilon_i] = \mathbb{E}\big\{\mathbb{E}[\epsilon_i | X_i]\big\} = \mathbb{E}\{0\} = 0$$

- Y para cualquier función $g(X_i)$:

$$\mathbb{E}[\epsilon_i \, g(X_i)] = \mathbb{E}\big[g(X_i)\, \mathbb{E}[\epsilon_i | X_i]\big] = \mathbb{E}[g(X_i) \cdot 0] = 0$$

- ϵ_i no está correlacionado con ninguna función de X_i.

Regresión

- Podemos definir a la regresión como la solución del problema de mínimos cuadrados de una población.
- Específicamente, el vector β de coeficientes $K \times 1$ se define resolviendo:

$$\beta = \arg\min_b E\left[(Y_i - X_i'b)^2\right]$$

- El residual se define como $e_i = Y_i - X_i'\beta$, donde β es el coeficiente de regresión.
- Por construcción, $\mathbb{E}[X_i(Y_i - X_i'\beta)] = 0$, lo que significa:
  - Los residuales (e_i) son no correlacionados con los regresores (X_i).
  - El término de error (e_i) no tiene un significado o existencia independiente.

Regresión

- La regresión resuelve el problema de mínimos cuadrados y por lo tanto es el mejor predictor lineal (MPL) de Y_i dado X_i.
- **Si la CEF es lineal, entonces la regresión es exactamente igual a la CEF.**
- **En caso de que no sea lineal, la regresión proporciona la mejor aproximación lineal a la CEF.**

Regresión

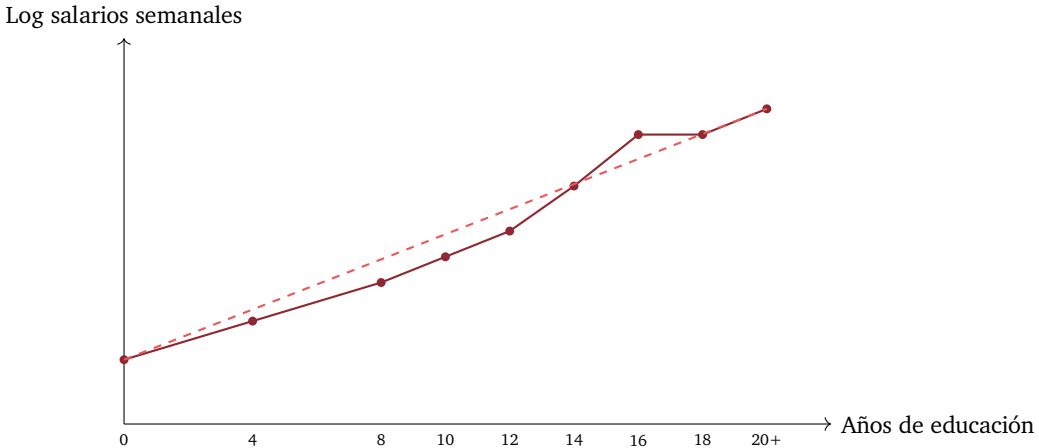


Figura 3.1.2 (aproximación): la regresión traza la CEF de salarios promedio dado escolaridad (puntos = CEF; línea punteada = regresión). *Fuente: Angrist y Pischke (2009)*.

Regresión multivariada

Regresión multivariada

- Usamos la regresión multivariada para controlar factores de confusión y crear comparaciones ceteris paribus.
- Nos interesa la relación entre una variable dependiente Y_i y otra variable X_{1i}, donde X_{1i} está asociada con otra variable X_{2i}, que también predice Y_i.
- Por ejemplo, la relación entre seguro de salud y salud podría explicarse por un mayor nivel educativo de los asegurados.
- En problemas de efectos de tratamiento, esto se llama sesgo de selección; en regresión, sesgo por variables omitidas.
- Veremos que no es una herramienta perfecta, pero es el benchmark para todo el resto de estrategias de identificación causal.

Regresión multivariada

- Si $X_{1i} = D_i$ es una variable dummy, "mantener las cosas constantes" implica reemplazar la comparación incondicional

$$\mathbb{E}[Y_i|D_i = 1] - \mathbb{E}[Y_i|D_i = 0]$$

  a la comparación condicional

$$\mathbb{E}[Y_i|D_i = 1, X_{2i} = x] - \mathbb{E}[Y_i|D_i = 0, X_{2i} = x]$$

- Esto es, la *Función de Esperanza Condicional (CEF)* de Y_i dado D_i, condicional en $X_{2i} = x$.
- Lo que estamos haciendo es comparar dentro de grupos que tienen el mismo valor de X_{2i}.

Regresión multivariada

- Estas comparaciones se consideran “efectos” de X_{1i} (no necesariamente causales), calculados al emparejar según los valores de X_{2i}.
- El emparejamiento (“matching”) no garantiza comparaciones 100% ceteris paribus, pero ayuda a acercarse a ello.
- Emparejar según X_{2i} asegura que las comparaciones de promedios entre valores de X_{1i} tengan el mismo valor de X_{2i}.

$$\mathbb{E}[Y_i|X_{1i} = 1, X_{2i} = x] - \mathbb{E}[Y_i|X_{1i} = 0, X_{2i} = x]$$

- La regresión múltiple combina conjuntos de comparaciones en un solo efecto promedio controlado.

Dale y Krueger (2002) en la práctica

- La base de datos College and Beyond (C&B) incluye a más de 14,000 graduados universitarios que asistieron a 30 universidades.
- Las escuelas se definen como comparables si caen en las mismas (cuatro) categorías de selectividad de Barron, quedando 9,202 estudiantes.
- De esa muestra se dejan los grupos de estudiantes emparejados que se hayan graduado de universidades públicas y privadas (5.583 estudiantes).
- Estos solicitantes emparejados se dividen en 151 grupos de selectividad diferentes que contienen graduados públicos y privados.

Modelo empírico

$$\ln Y_i = \alpha + \beta P_i + \sum_{j=1}^{150} \gamma_j GROUP_{ji} + \delta_1 SAT_i + \delta_2 \ln PI_i + \varepsilon_i \tag{1}$$

- β: coeficiente de interés (efecto causal de asistir a una escuela privada, P_i).
- γ_j, $j = 1, \ldots, 150$: coeficientes de 150 dummies de grupo de selectividad ($GROUP_{ji}$).
- Dos controles adicionales: puntaje individual del SAT (SAT_i) y log de ingresos de los padres ($\ln PI_i$).

	No selection controls			Selection controls		
	(1)	(2)	(3)	(4)	(5)	(6)
Private School	.135	.095	.086	.007	.003	.013
	(.055)	(.052)	(.034)	(.038)	(.039)	(.025)
Own SAT score/100		.048	.016		.033	.001
		(.009)	(.007)		(.007)	(.007)
Predicted log(Parental Income)			.219			.190
			(.022)			(.023)
Female			−.403			−.395
			(.018)			(.021)
Black			.005			−.040
			(.041)			(.042)
Hispanic			.062			.032
			(.072)			(.070)
Asian			.170			.145
			(.074)			(.068)
Other/Missing Race			−.074			−.079
			(.157)			(.156)
High School Top 10 Percent			.095			.082
			(.027)			(.028)
High School Rank Missing			.019			.015
			(.033)			(.037)
Athlete			.123			.115
			(.025)			(.027)
Selection Controls	N	N	N	Y	Y	Y

Notas: columnas (4)-(6) incluyen una dummy por cada grupo de selectividad formado emparejando según a qué escuelas fue aceptado/rechazado cada estudiante. Muestra de 5,583 estudiantes. Errores estándar entre paréntesis. Fuente: Dale y Krueger (2002).

Los resultados de la tabla anterior salen de la muestra de estudiantes para los que se pudo encontrar un match. Tal vez hay algo especial en ellos que produce estos resultados, lo cual limitaría la validez externa, ¿cómo resolvemos esto?

Controles lineales: Promedio del SAT

- Veamos qué pasa si, en vez de realizar los emparejamientos anteriores, directamente ponemos un control lineal por el puntaje SAT promedio de las escuelas que te admiten.
- También se agregan dummies por el número de escuelas a las que postuló.
- De esta manera, la ecuación sería

$$\ln Y_i = \alpha + \beta P_i + \gamma Avg_SAT_i + \phi_1 two_app + \phi_2 three_app + \delta_1 SAT_i + \delta_2 \ln PI_i + \varepsilon_i$$

Tabla 2.3: efectos de la escuela privada, controles del SAT promedio

	No selection controls			Selection controls		
	(1)	(2)	(3)	(4)	(5)	(6)
Private school	.212	.152	.139	.034	.031	.037
	(.060)	(.057)	(.043)	(.062)	(.062)	(.039)
Own SAT score × 100		.051	.024		.036	.009
		(.008)	(.006)		(.006)	(.006)
Log parental income			.181			.159
			(.026)			(.023)
Average SAT score of schools applied to × 100				.110	.082	.077
				(.024)	(.022)	(.012)
Sent two applications				.071	.062	.058
				(.013)	(.011)	(.010)
Sent three applications				.093	.079	.066
				(.021)	(.019)	(.017)
Sent four or more applications				.139	.127	.098
				(.024)	(.023)	(.020)

Notas: esta tabla reporta estimaciones del efecto de asistir a una escuela privada sobre ingresos. Muestra de 14,238. Errores estándar entre paréntesis. Fuente: Dale y Krueger (2002), Table 2.3.

Volver a OVB

El límite del modelo con controles lineales

Estamos asumiendo una relación lineal entre selectividad e ingresos. Si la relación real tuviera una forma distinta, eg. el ingreso salta mucho al pasar cierto umbral de selectividad pero después se aplana, el control lineal la va a aproximar mal, y esa mala aproximación puede filtrarse al coeficiente de P_i que nos interesa.

Efectos de pares

- Tal vez el punto no es ir a una universidad privada, pero ir a una univerisidad con buenos estudiantes.
- Reemplazamos P_i en la ecuación (1) por la puntuación media en las pruebas de acceso de los compañeros de la universidad en la que se cursaron los estudios.

Tabla 2.4: efectos de la selectividad de la universidad, controles del SAT promedio

	No selection controls		Selection controls	
	(1)	(3)	(4)	(6)
School average SAT score × 100	.109	.076	−.021	.000
	(.026)	(.016)	(.026)	(.018)
Own SAT score × 100		.018		.009
		(.006)		(.006)
Log parental income		.187		.161
		(.024)		(.025)
Average SAT score of schools applied to × 100			.138	.089
			(.017)	(.013)
Sent two applications			.082	.063
			(.015)	(.011)
Sent three applications			.107	.074
			(.026)	(.022)
Sent four or more applications			.153	.106
			(.031)	(.025)

Notas: esta tabla reporta estimaciones del efecto de la selectividad promedio de la universidad (SAT promedio de los compañeros) sobre ingresos. Columnas (4) y (6) incluyen controles de auto-revelación (SAT promedio y cantidad de escuelas a las que postuló). Muestra de 14,238 estudiantes. Errores estándar entre paréntesis. Fuente: Dale y Krueger (2002), Table 2.4.

Regresión y la CEF

- Supongamos que la CEF del logaritmo de los ingresos fuera una función lineal de las notas individuales, los ingresos paternos y el nivel selectivo de las universidades.
- Por lo tanto

$$\mathbb{E}[\ln Y_i | P_i, GROUP_{ji}, SAT_i, \ln IP_i] =$$
$$= \alpha + \beta P_i + \sum_{j=1}^{150} \gamma_j GROUP_{ji} + \delta_1 SAT_i + \delta_2 \ln IP_i + \varepsilon_i \quad (2)$$

Regresión y la CEF

- Las estimaciones de los efectos de estudiar en un centro privado basados en una regresión son idénticas a las que se obtendrían mediante una estrategia que
  (i) agrupara a los estudiantes según los valores de $GROUP_i$, SAT_i y $\ln IP_i$;
  (ii) comparara dentro de cada grupo los ingresos promedio de los estudiantes que asistieron a centros privados ($P_i = 1$) con los que acudieron a centros públicos ($P_i = 0$) para cada combinación posible de las variables condicionales, y produjera un promedio simple promediando todas estas comparaciones concretas dentro de las celdas.

$$\mathbb{E}[\ln Y_i | P_i = 1, GROUP_{ji}, SAT_i, \ln IP_i] - \mathbb{E}[\ln Y_i | P_i = 0, GROUP_{ji}, SAT_i, \ln IP_i]$$

Regresión y Causalidad

Regresión y Causalidad

- Una regresión es causal cuando la CEF que aproxima es causal.
- Una CEF es causal cuando describe diferencias en los resultados potenciales promedio para una población fija de referencia.
- En un experimento controlado, la interpretación causal viene de que la variable de interés es independiente de los resultados potenciales por lo que los grupos son comparables.
- Cuando no se puede hacer un RCT, el supuesto de Independencia condicional (o selección en observables) es clave para la interpretación causal de una regresión.

Independencia Condicional (IC)

- Los resultados potenciales (Y_{1i}, Y_{0i}) son independientes de D_i luego de controlar por un conjunto de características observadas X_i.
- Dado X_i, D_i no está correlacionada con los resultados potenciales Y_{1i} e Y_{0i}

$$\mathbb{E}(Y_{1i}|D=1, X_i) = \mathbb{E}(Y_{1i}|D=0, X_i) = \mathbb{E}(Y_{1i}|X_i)$$

$$\mathbb{E}(Y_{0i}|D=1, X_i) = \mathbb{E}(Y_{0i}|D=0, X_i) = \mathbb{E}(Y_{0i}|X_i)$$

Selección en Observables

- Pensemos en la decisión de ir a la universidad (definimos la variable artificial D, que vale 1 si el individuo va a la universidad).
- El ingreso de un individuo sería: $Y_i = Y_{1i}D + Y_{0i}(1 - D)$
- Y_{1i} serían los ingresos potenciales con educación universitaria e Y_{0i} los ingresos potenciales sin ella.
- Como no observamos Y_{1i} e Y_{0i} para un mismo individuo, intentamos medir el promedio de estas diferencias, para toda la población (ATE), o para el grupo que fue a la universidad (ATT).

Independencia Condicional

$$\underbrace{\mathbb{E}[Y_i|D=1] - \mathbb{E}[Y_i|D=0]}_{\text{Diferencia en ingresos cond. en educación}} = \underbrace{\mathbb{E}[Y_{1i}|D=1] - \mathbb{E}[Y_{0i}|D=1]}_{\alpha_{ATT}} + \underbrace{\mathbb{E}[Y_{0i}|D=1] - \mathbb{E}[Y_{0i}|D=0]}_{\text{sesgo selección}}$$

- Si quienes van a la universidad hubieran tenido ingresos mayores de todos modos, el sesgo de selección sería...?
- El supuesto de IC implicaría que los dos grupos son comparables una vez que condicionamos en un conjunto de observables (e.g. habilidad)

$$\mathbb{E}[Y_{0i}|X_i, D=1] = \mathbb{E}[Y_{0i}|X_i, D=0] \tag{3}$$

Independencia Condicional

- Bajo IC, las comparaciones de ingresos entre los grupos, condicional en las X, tiene una interpretación causal. Por lo tanto:

$$\underbrace{\mathbb{E}[Y_i|X_i, D=1] - \mathbb{E}[Y_i|X_i, D=0]}_{\text{Dif. en ingresos cond. en educación}} = \mathbb{E}[Y_{1i}|X_i, D=1] - \mathbb{E}[Y_{0i}|X_i, D=0]$$

$$= \mathbb{E}[Y_{1i}|X_i, D=1] - \underbrace{\mathbb{E}[Y_{0i}|X_i, D=1]}_{\text{dado (3)}}$$

$$= \underbrace{\mathbb{E}[Y - Y_{0i}|X_i, D=1]}_{\text{ATT en grupos definidos por } X_i}$$

Selección en observables y matching

- Acabamos de estimar el efecto del tratamiento para los grupos definidos por la variable X_i:

$$\mathbb{E}[Y_i|X_i = x, D = 1] - \mathbb{E}[Y_i|X_i = x, D = 0] = \mathbb{E}[Y_{1i} - Y_{0i}|X_i = x, D = 1] \equiv \rho_x$$

- Repetimos esto para todos los valores posibles de X_i.
- Para pasar de estos promedios condicionales por grupo al promedio general, utilizamos las reglas de probabilidad condicional.

$$\mathbb{E}[Y_{1i} - Y_{0i}|D = 1] = \sum_x \mathbb{E}[Y_{1i} - Y_{0i}|X_i = x, D = 1] \Pr(X_i = x, D = 1)$$

Independencia condicional y causalidad en la regresión

- El supuesto de IC es el fundamento de una regresión causal.
- Supongamos que el efecto del tratamiento es constante. Por lo tanto, supongamos que $\rho_x = \rho$ y escribamos

$$Y_{0i} = \alpha + \eta_i$$

$$Y_{1i} = Y_{0i} + \rho$$

- Usando $Y_i = Y_{0i}(1 - D_i) + Y_{1i}D_i$

$$= \alpha + \rho D_i + \eta_i$$

Del emparejamiento a la regresión

$$Y_i = \alpha + \rho D_i + \eta_i \tag{4}$$

- Usando el supuesto de IC (3):

$$\mathbb{E}[Y_{0i}|X_i, D = 1] = \mathbb{E}[Y_{0i}|X_i, D = 0] \tag{5}$$

- Tenemos

$$\mathbb{E}[Y_{0i}|X_i, D_i] = \mathbb{E}[Y_{0i}|X_i] \iff \mathbb{E}[\eta_i|X_i, D_i] = \mathbb{E}[\eta_i|X_i]$$

- (4) todavía no es una regresión porque η_i sigue siendo función de X_i y esa dependencia de X_i no está explicada como un regresor. Entonces η_i queda correlacionado con D_i a través de X_i.

Del emparejamiento a la regresión

$$\mathbb{E}[\eta_i|X_i, D_i] = \mathbb{E}[\eta_i|X_i]$$

- Aproximando $\mathbb{E}[\eta_i|X_i]$ con una función lineal

$$\mathbb{E}[\eta_i|X_i] = \gamma X_i \qquad \eta_i = \gamma X_i + e_i \qquad \mathbb{E}[e_i|X_i] = 0$$

- Sustituimos en (4)

$$Y_i = \alpha + \rho D_i + \gamma X_i + e_i$$

  La cual es una regresión (i.e. $\mathbb{E}[e_i|X_i, D_i] = 0$)

Independencia Condicional

- Clave:
  - qué variables incluir en X
  - la única fuente de diferencias entre los dos grupos son las X.
  - Siempre va a existir un problema de selección si ambos grupos difieren en variables no observables (por ejemplo si el grupo tratado se caracteriza por su mayor esfuerzo).

Sesgo de variables omitidas

Problemas con OLS: Variables omitidas

- La regresión pretende ser un modo de analizar el impacto de una variable manteniendo el resto de las cosas iguales (*ceteris paribus*).
- No introducir suficientes controles, o los adecuados, abre la puerta al sesgo de selección.
- La versión del sesgo de selección que aparece en las regresiones cuando los controles no son los adecuados se denomina sesgo de variables omitidas (OVB).

Variables omitidas

- Volvamos al ejemplo de los 5 estudiantes.
- Quisiéramos correr la regresión “larga”:

$$Y_i = \alpha^l + \beta^l P_i + \gamma A_i + \varepsilon_i^l$$

- Pero en cambio corremos una regresión “corta”

$$Y_i = \alpha^c + \beta^c P_i + \varepsilon_i^c$$

- Como el único regresor aquí es una variable binaria, la pendiente de este modelo resultará igual a la diferencia del Y_i promedio entre los sujetos que tienen $P_i = 1$ y los que lo tienen $P_i = 0$.

La conección entre el coeficiente de la regresión corta y el de la larga tiene dos componentes:

1. La relación entre la variable omitida y la de tratamiento.
2. La relación entre la varible omitida y el resultado.

Sesgo de Variables Omitidas (OVB)

- Para obtener el OVB, hagamos la siguiente regresión entre la variable omitida y la explicativa:

$$A_i = \delta_0 + \delta_{AP} P_i + u_i$$

- La relación entre los coeficientes de la regresión “corta” y la “larga” está dada por la fórmula del sesgo de variables omitidas (OVB):

$$\begin{aligned}\text{Efecto de } P_i \text{ en corta} &= \text{Efecto de } P_i \text{ en larga: } \beta^l \\ &+ (\text{[Relación entre } A_i \text{ y } P_i\text{]: } \delta_{AP}) \times \text{[Efecto de } A_i \text{ en larga]: } \gamma\end{aligned}$$

$$\beta^c = \beta^l + \underbrace{\delta_{AP} \times \gamma}_{\text{sesgo}}$$

Sesgo de Variables Omitidas (OVB)

- El sesgo de variables omitidas (OVB), definido como la diferencia entre los coeficientes de P_i en los modelos simple y largo, consiste en una sencilla reordenación de la ecuación anterior:

$$OVB = (\text{[Relación entre } A_i \text{ y } P_i\text{]: } \delta_{AP}) \times \text{[Efecto de } A_i \text{ en larga]: } \gamma$$

$$\beta^c - \beta^l = \delta_{AP} \times \gamma$$

OVB: Dale & Krueger

- En la estimación de DK veamos el caso de los controles por notas individuales del SAT.
- La regresión "larga" es:

$$\ln Y_i = \alpha^l + \beta^l P_i + \sum_{j=1}^{150} \gamma_j GROUP_{ji} + \gamma_1 SAT_i + \gamma_2 \ln PI_i + \varepsilon_i$$

- Note en las dos primeras columnas de la tabla 2.3 (no considerando los controles por selección) que cuando a la regresión "corta" le añadimos el control del SAT el coeficiente de P_i cae de 0.212 a 0.152:

$$OVB = \beta^c - \beta^l = 0.212 - 0.152 = 0.06$$

- Note también que en la columna 2 $\gamma_1 = 0.051$.

Ver Tabla 2.3

Sesgo de Variables Omitidas (OVB)

- La primera columna de la tabla siguiente muestra la regresión auxiliar:

$$SAT_i = \pi_0 + \pi_1 P_i + \varepsilon_i$$

  con $\pi_1 = 1.165$.
- Por lo tanto,

$$OVB = \beta^c - \beta^l = \pi_1 \times \gamma_1 = 1.165 \times 0.051 = 0.06$$

Table 2.5: Private school effects: Omitted variables bias

	Own SAT score × 100			Log parental income		
	(1)	(2)	(3)	(4)	(5)	(6)
Private school	1.165	1.130	.066	.128	.138	.028
	(.194)	(.188)	(.112)	(.055)	(.057)	(.037)
Female			−.567			.016
			(.076)			(.013)
Black			−1.947			−.359
			(.079)			(.019)
Hispanic			−1.185			−.259
			(.168)			(.050)
Asian			−.014			−.060
			(.116)			(.033)
Other/Missing race			−.521			−.082
			(.293)			(.063)
High school top 10%			.948			.064
			(.107)			(.020)
High school rank missing			.356			−.030
			(.102)			(.023)
Athlete			−.318			.037
			(.147)			(.016)

Nota: esta tabla describe la relación entre asistencia a escuela privada y las características de los estudiantes (SAT propio, ingreso parental), usadas como variable dependiente. Fuente: Dale y Krueger (2002).

¿Por qué variables controlar?

- En la búsqueda de identificar efectos causales, ¿qué variables deben incluirse en el lado derecho de una ecuación de regresión?
- **Sí:** Variables que determinan el tratamiento y están correlacionadas con el resultado (por ejemplo, habilidad).
  - En general, estas variables serán características fijas o predeterminadas antes del tratamiento (por ejemplo, escolaridad).
- **Sí:** Variables no correlacionadas con el tratamiento pero sí con el resultado.
  - Estas variables pueden ayudar a reducir los errores estándar.
- **No:** Variables que son resultados del propio tratamiento (mediadores o colliders). Estas son *malos controles*.

Malos Controles

Malos controles

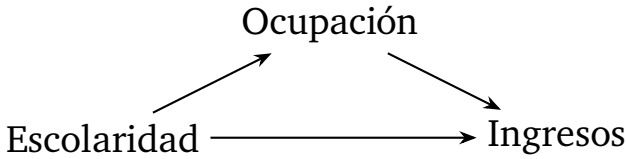
- Algunos trabajos, al realizar una regresión de ingresos sobre escolaridad (y experiencia), incluyen controles para la ocupación. ¿Tiene sentido esto?
- Podemos pensar que la escolaridad afecta el acceso a ocupaciones de mayor nivel, por ejemplo, necesitas un doctorado para ser profesor universitario.
- Esto da lugar a un sistema de dos ecuaciones simultáneas.

$$Y_i = \alpha + \rho S_i + \gamma O_i + e_i$$

$$O_i = \lambda_0 + \lambda_1 S_i + u_i$$

- La ocupación es una variable endógena, por lo que no necesariamente podrías estimar la primera ecuación utilizando OLS.
- La ocupación es un mal control.

Malos controles: DAG



- O_i es un **mediador**: está en el camino causal entre S_i e Y_i, no es una variable de confusión.
- Controlar por O_i bloquea parte del efecto de S_i sobre Y_i (el que pasa *a través* de la ocupación); por eso el coeficiente de escolaridad cae al agregar dummies de ocupación (Tabla 3.2.1).

Malos controles

Table 3.2.1: Estimates of the returns to education for men in the NLSY

(1) None	(2) Age Dummies	(3) (2) + Additional Controls*	(4) (3) + AFQT Score	(5) (4) + Occupation Dummies
.132	.131	.114	.087	.066
(.007)	(.007)	(.007)	(.009)	(.010)

Notas: coeficiente de años de escolaridad en una regresión de log salarios sobre escolaridad y los controles indicados. NLSY 1979, muestra restringida a hombres, $N = 2,434$. **Controles adicionales: escolaridad de los padres y dummies de raza y región censal. Fuente: Angrist y Pischke (2009).*

Control por proxy

- Una segunda versión de este escenario implica el control proxy, es decir, la inclusión de variables que podrían controlar parcialmente factores omitidos, pero que a su vez están influenciadas por la variable de interés.
- Supongamos que estás interesado en una regresión larga:

$$Y_i = \alpha + \rho S_i + \gamma A_i + \epsilon_i \tag{6}$$

  donde A_i es una medida de habilidad.
- Piensa en A_i como un puntaje de coeficiente intelectual (IQ) que mide la habilidad innata en octavo grado, antes de cualquier experiencia relevante.
- El término de error en esta ecuación satisface $\mathbb{E}[S_i \epsilon_i] = \mathbb{E}[A_i \epsilon_i] = 0$ por definición.
- Dado que se mide antes de que se determine S_i, se considera un buen control.

Control por proxy

- Supongamos que tenemos una medida de habilidad recopilada a los 18 o 20 años, y llamémosla “habilidad tardía”, A_{ti}.
- En general, la escolaridad aumenta la habilidad tardía en relación con la habilidad innata.
- Específicamente, supongamos:

$$A_{ti} = \pi_0 + \pi_1 S_i + \pi_2 A_i + u_i \tag{7}$$

- Con esto queremos decir que tanto la escolaridad como la habilidad innata aumentan la habilidad tardía o medida de habilidad.

Control por proxy

- Si estamos preocupados por el OVB en la regresión de Y_i sobre S_i, y regresionamos sobre S_i y la habilidad tardía A_{ti}, dado que el control deseado A_i no está disponible.
- Usando la ecuación (7) para sustituir A_i en (6), la regresión sobre S_i y A_{ti} es:

$$Y_i = \left(\alpha - \gamma\frac{\pi_0}{\pi_2}\right) + \left(\rho - \gamma\frac{\pi_1}{\pi_2}\right)S_i + \frac{\gamma}{\pi_2}A_{ti} + \varepsilon_i \tag{8}$$

- En este escenario, γ, π_1, y π_2 son todos positivos, por lo que $\rho - \gamma\frac{\pi_1}{\pi_2}$ será demasiado pequeño a menos que π_1 sea igual a cero.
- Entonces, el uso de un control proxy que es influenciado por la variable de interés genera un coeficiente menor al efecto deseado.

Control por proxy vs Mal control

- Controlar por variables endógenas es simplemente erróneo; no se debe controlar por ocupación en una regresión de escolaridad si se busca una interpretación causal.
- Sin embargo, en el escenario de control proxy, tus intenciones son buenas.
- Y aunque el control proxy no genera el coeficiente de regresión de interés, puede ser una mejora respecto a no usar ningún control.

Control por proxy vs OVB

- Supongamos que corremos una regresión de Y_i sobre S_i.
- La fórmula de OVB nos dice que el coeficiente será de $\rho + \delta_{AS}$, donde δ_{AS} es el coeficiente de la regresión de A_i sobre S_i.
- El coeficiente de S_i en (8) podría estar más cerca del verdadero efecto ρ que la regresión sin controles.
- Asumiendo que $\delta_{AS} > 0$, podríamos decir que el efecto causal de interés se encuentra entre los otros dos.

Conclusión

Conclusión

- La regresión es un matchmaker automatizado: promedia comparaciones dentro de celdas definidas por los controles.
- Bajo independencia condicional, controlar por las variables correctas acerca la comparación entre tratados y controles a la de un experimento.
- La regresión resuelve la identificación solo bajo selección en observables. Esto nos limita mucho para usarla para hacer inferencia. Pero es el benchmark para las otras estrategias de identificación.

Referencias

Referencias I

- Dale, S. B. and Krueger, A. B. (2002). Estimating the payoff to attending a more selective college: An application of selection on observables and unobservables. *The Quarterly Journal of Economics*, 117(4):1491–1527.
- Angrist, J. D. and Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.
- Angrist, J. D. and Pischke, J.-S. (2015). *Mastering 'Metrics: The Path from Cause to Effect*. Princeton University Press.
- Giolito, E. Curso de Economía de las Políticas Sociales. Doctorado en Economía, Universidad del CEMA.

Lecturas

Lecturas

Mastering 'Metrics

Angrist, J. D., y Pischke, J.-S. (2015)

- Capítulo 2 — *"Regression"****

Mostly Harmless Econometrics

Angrist, J. D., y Pischke, J.-S. (2009)

- Capítulo 3 — *"Making Regression Make Sense"***

Contacto

Contacto

Email

juanifavetto@gmail.com

Teléfono

+54 9 2972 40-8438

Por favor evitar usar el webcampus

Apéndice

Variables dependientes limitadas

- La regresión siempre tiene sentido:
  - La regresión aproxima la Curva de Expectativa Condicional (CEF).
  - Si la CEF es no lineal, la regresión genera un promedio ponderado de la derivada de la CEF (ver MHE, Sección 3.4.2 y su apéndice, Sección 3.5, para más detalles).
- ¿Puedo usar MCO si mi variable dependiente es…
  - Una variable binaria (como empleo)?
  - No negativa (como ingresos)?
  - Un conteo (como semanas trabajadas)?

Variables dependientes limitadas

- MHE (Table 3.4.2) compara, para el efecto de tener más de dos hijos sobre el empleo y las horas trabajadas de la madre, las estimaciones por OLS con los efectos promedio de modelos Probit y Tobit (y sus efectos marginales, MFX).
- La conclusión del ejercicio: en la práctica, OLS, Probit y Tobit dan estimaciones del efecto promedio muy parecidas entre sí, a pesar de que la variable dependiente es binaria (empleo) o censurada (horas).

Ejemplo Ingresos e inmigrantes asiáticos

- Muestra de varones con secundaria completa edad 40-49 en la American Community Survey de 2016.

```
Variable    Obs      Mean       Std. Dev.   Min   Max
agep        57,696   44.632     2.834972    40    49
yearsEd     57,696   14.53616   2.42775     12    21
hsgrad      57,696   1          0           1     1
somcoll     57,696   .5348751   .498788     0     1
collgrad    57,696   .4422664   .4965599    0     1
asianpac    57,696   .0987243   .2982941    0     1
white       57,289   .9076786   .2894816    0     1
^^I
```

Ingresos e inmigrantes asiáticos

- Note que los asiáticos (75% nacidos en el extranjero) ganan más que los blancos. ¿Es causal el efecto asiático?

```
-> asianpac = 0
Variable    Obs     Mean       Std. Dev.   Min        Max
loguhe      48,411  3.345458   .7155705    -6.437752  5.306181
yearsEd     52,000  14.40617   2.377595    12         21
collgrad    52,000  .4188462   .4933748    0          1

-> asianpac = 1
Variable    Obs     Mean       Std. Dev.   Min        Max
loguhe      5,339   3.506776   .7775642    -3.912023  5.30231
yearsEd     5,696   15.72279   2.555968    12         21
collgrad    5,696   .6560744   .4750933    0          1
^^I
```

Ingresos e inmigrantes asiáticos

- ¿Podrían explicar el efecto las distintas tasas de graduación universitaria?

```
. reg loguhe asianpac

loguhe     Coef.     Std. Err.    t       P>|t|
asianpac   .1613188  .0104113     15.49   0.000
_cons      3.345458  .0032813     1019.56 0.000
^^I
```

- Incluyendo una dummy por graduación universitaria tenemos:

```
. reg loguhe asianpac colgrad

loguhe     Coef.     Std. Err.    t       P>|t|
asianpac   .016507   .0095892     1.72    0.085
colgrad    .6043304  .0057731     104.68  0.000
_cons      3.091722  .0038496     803.14  0.000
^^I
```

Ingresos e inmigrantes asiáticos

- Si controlamos por años de educación el efecto desaparece totalmente

```
. reg loguhe asianpac yearsEd

loguhe     Coef.      Std. Err.    t      P>|t|
asianpac   -.0109312  .0095219    -1.15  0.251
yearsEd    .1301684   .0011751    110.78 0.000
_cons      1.469512   .0171914    85.48  0.000
^^I
```

Anatomía de la regresión

- Considere la siguiente regresión bivariada:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i \tag{9}$$

- Entonces:

$$\beta_1 = \frac{\text{Cov}(Y_i, \tilde{x}_{1i})}{\text{Var}(\tilde{x}_{1i})}$$

donde $\tilde{x}_{1i}$ es el residuo de la regresión de X_{1i} sobre X_{2i}

$$X_{1i} = \delta_{10} + \delta_{12} X_{2i} + \tilde{x}_{1i}.$$

Anatomía de la regresión

- Sustituyamos la expresión para la regresión larga en:

$$\begin{aligned}\frac{\text{cov}(Y_i, \tilde{x}_{1i})}{\text{var}(\tilde{x}_{1i})} &= \frac{\text{Cov}(\beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i, \tilde{x}_{1i})}{\text{Var}(\tilde{X}_{1i})} \\ &= \frac{\beta_1 \overbrace{\text{Cov}(X_{1i}, \tilde{x}_{1i})}^{=\text{Var}(\tilde{x}_{1i})} + \beta_2 \overbrace{\text{Cov}(X_{2i}, \tilde{x}_{1i})}^{=0} + \overbrace{\text{Cov}(e_i, \tilde{x}_{1i})}^{=0}}{\text{Var}(\tilde{x}_{1i})} \\ &= \beta_1 \frac{\text{Var}(\tilde{x}_{1i})}{\text{Var}(\tilde{x}_{1i})} = \beta_1.\end{aligned}$$

- El β_1 multivariado captura el efecto de $\tilde{x}_{1i}$, la parte de X_1 que no es explicada (en el sentido de una regresión) por X_2.

Ejemplo Ingresos e inmigrantes asiáticos

$$Y_i = \beta_0 + \beta_1 asian_pac_i + \beta_2 years_educ_i + \beta_3 age_i + \varepsilon_i$$

```
. reg loguhe asianpac yearsEd age

loguhe     Coef.      Std. Err.    t      P>|t|
asianpac   -.008028   .0095198    -0.84  0.399
yearsEd    .1302374   .0011717    110.95  0.000
agep       .0090692   .0009906    9.16    0.000
_cons      1.062983   .0476094    22.33   0.000
^^I
```

Etapa 1: Residuos regresión auxiliar

```
. **step 1
. reg asianpac age yearsEd

asianpac  Coef.       Std. Err.  t     P>|t|
agep      -.003466    .0004536   -7.73 0.000
yearsEd   .0200877    .0005207   38.27 0.000
_cons     -.0381703   .0215712   -1.77 0.077

. predict ap_resid, residuals
^^I
```

Etapa 2: variable dependiente contra residuos

$$Y_i = \beta_0 + \beta_1 \tilde{x}_{1i} + \beta_2 \tilde{x}_{2i} + \beta_3 \tilde{x}_{3i} + \varepsilon_i$$

```
. **step 2
. reg loguhe ap_resid

loguhe     Coef.       Std. Err.   t      P>|t|
ap_resid   -.008028    .0105823    -0.76 0.448
_cons      3.361481    .003121     1077.06 0.000
^^I
```

- El coeficiente de `ap_resid` coincide con el β_1 de la regresión múltiple ($-.008028$).
- Este procedimiento de dos etapas (residualizar y luego regresionar) se conoce como el **teorema de Frisch-Waugh-Lovell** (Frisch y Waugh, 1933; Lovell, 1963).

OVB: Deducción de la fórmula

- Partiendo de la regresión larga:

$$Y_i = \alpha^l + \beta^l X_{1i} + \gamma X_{2i} + \varepsilon_i^l \tag{10}$$

- Y una corta de

$$Y_i = \alpha^c + \beta^c X_{1i} + \varepsilon_i^c$$

- Sabemos que:

$$\beta^c = \beta^l + \delta_{21} \times \gamma$$

- donde δ_{21} es el coeficiente de una regresión de X_{2i} contra X_{1i}.

OVB: Deducción de la fórmula

- El coeficiente de la regresión corta:

$$\begin{aligned}\beta^c &= \frac{\text{Cov}(Y_i, X_{1i})}{\text{Var}(X_{1i})} = \frac{C(\alpha^l + \beta^l X_{1i} + \gamma X_{2i} + \varepsilon_i^l, X_{1i})}{\text{Var}(X_{1i})} \\ &= \frac{\beta^l \overbrace{\text{Cov}(X_{1i}, X_{1i})}^{=\text{Var}(X_{1i})} + \gamma \overbrace{\text{Cov}(X_{2i}, X_{1i})}^{\delta_{21}} + \overbrace{\text{Cov}(\varepsilon_i^l, X_{1i})}^{=0}}{\text{Var}(X_{1i})} \\ &= \beta^l + \frac{\text{Cov}(X_{2i}, X_{1i})}{\text{Var}(X_{1i})}\gamma = \beta^l + \delta_{21} \times \gamma\end{aligned}$$