

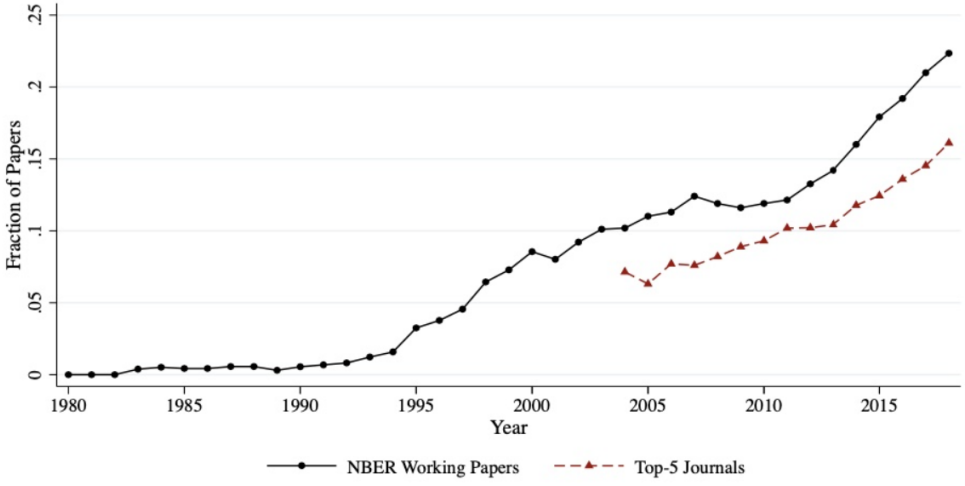
Introducción a Diferencias en Diferencias

Juan Martín Favetto

Primavera 2026

Introducción

Los buenos intrumentos son dificiles de conseguir. Vamos a tener que extender el toolkit para identificar efectos causales.



Fuente: Currie, Kleven y Zwiers (2020).

- El método de diferencias en diferencias (DiD) reconoce que los grupos de control y tratamiento pueden diferir en muchos aspectos.
- No obstante, a veces, veremos que el grupo de control y tratamiento se mueven paralelos en la ausencia del tratamiento.
- Cuando esto ocurre, la diferencia entre el camino después del tratamiento y la tendencia establecida por el control, nos puede decir algo del efecto causal.

Efectos fijos y diferencias en diferencias

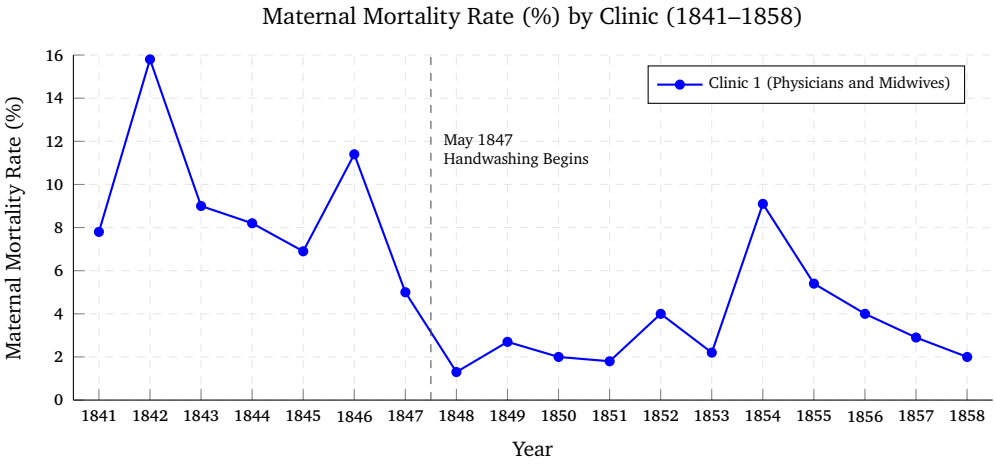
Efectos fijos supone

$$\mathbb{E}(y_{0it} \mid A_i, t) = \alpha + \lambda_t + \gamma A_i \qquad \text{o bien} \qquad \mathbb{E}(y_{0it} \mid i, t) = \alpha_i + \lambda_t$$

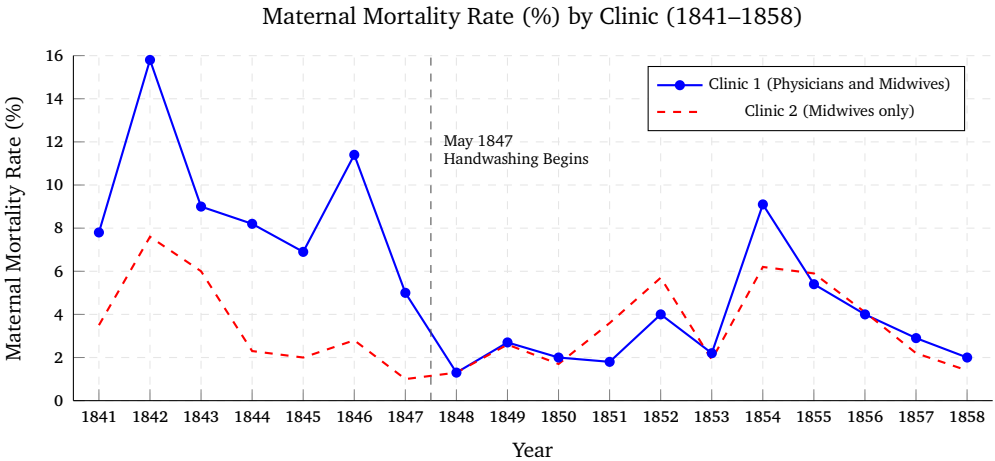
DiD hace el mismo supuesto a nivel de grupo s (por ejemplo, un estado de EE. UU.)

$$\mathbb{E}(y_{0ist} \mid s, t) = \alpha_s + \lambda_t$$

- Alcanza para cualquier tratamiento que ocurra a nivel estado-tiempo.
- Los requisitos de datos son menores. Con muestras repetidas de secciones cruzadas de la misma unidad agregada s basta.



Mortalidad materna en la Clínica 1 (médicos y parteras) del Hospital General de Viena. La línea vertical marca mayo de 1847, cuando empieza el lavado de manos. *Fuente: Cunningham (2021), Figura 9.2.*



Se agrega la Clínica 2, atendida solo por parteras. *Fuente: Cunningham (2021), Figura 9.2.*

- **Participantes vs. no participantes.** El problema es la selección. ¿Por qué no participan los que no participan?
- **Antes vs. después.** Los mismos individuos o comunidades antes y después del programa. El problema es que absorbe las tendencias temporales.

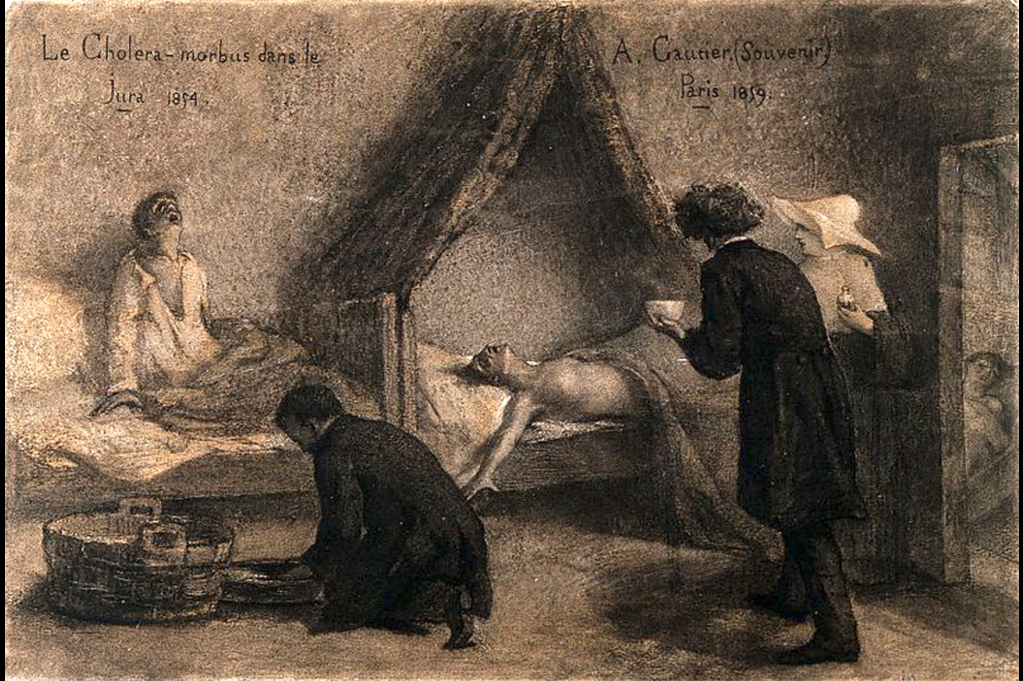
DiD combina las dos comparaciones

$$DD = \left(\bar{Y}^{\text{tratados}}_{\text{después}} - \bar{Y}^{\text{tratados}}_{\text{antes}}\right) - \left(\bar{Y}^{\text{comparación}}_{\text{después}} - \bar{Y}^{\text{comparación}}_{\text{antes}}\right)$$

El cólera en Londres (Snow, 1855)

El cólera en el siglo XIX

- Diarrea y vómitos. El enfermo puede perder varios litros de líquido por día, la piel se vuelve azulada y se muere rápido por deshidratación.
- Llega a Gran Bretaña en 1831, desde la India, y vuelve en oleadas en 1848–49, 1853–54 y 1866.
- La epidemia de 1848–49 mata a más de 50.000 personas en Inglaterra y Gales.
- Nadie sabía qué la causaba.


Le Cholera-morbus dans le
Jura 1854
A. Gautier (Souvenir)
Paris 1859

El cólera en el siglo XIX

- La explicación dominante era el miasma. Las enfermedades se contagiaban por el aire contaminado.
- Eso era coherente con lo que se observaba, el cólera pegaba peor en los barrios más pobres.
- Con esta idea, se hicieron varios esfuerzos para limpiar la ciudad y, aunque tendrían algún efecto en la salud, no ayudaban mucho con el cólera.
- En el 49, un médico propone que el cólera se transmite al ingerir agua contaminada.
- Para convencer necesitaba mostrar que las muertes seguían al agua, aun entre barrios igual de pobres y que respiraban el mismo aire.

El experimento natural

- Dos compañías proveían el agua, Lambeth Waterworks Co. (LC) y Southwark and Vauxhall Water Co. (SVC). Ambas la tomaban del Támesis en el centro de Londres.
- Snow sospechaba que el cólera se transmitía por el agua contaminada.
- En 1852, LC mueve su toma río arriba.
- En 1853 surge otro brote.
- ¿Cuál fue el efecto causal de cambiar la toma de agua?

Companies	Time	Average mortality	D_1	D_2
Lambeth	Before	$Y = L$		

Source: Cunningham (2021), Causal Inference: The Mixtape.

Companies	Time	Average mortality	D_1	D_2
Lambeth	Before	$Y = L$		
	After	$Y = L + \mathbf{L_t} + \mathbf{D}$		

Source: Cunningham (2021), Causal Inference: The Mixtape.

Companies	Time	Average mortality	D_1	D_2
Lambeth	Before	$Y = L$		
	After	$Y = L + \mathbf{L_t} + \mathbf{D}$	$\mathbf{L_t} + \mathbf{D}$	

Source: Cunningham (2021), Causal Inference: The Mixtape.

Companies	Time	Average mortality	D_1	D_2
Lambeth	Before	$Y = L$		
	After	$Y = L + \mathbf{L_t} + \mathbf{D}$	$\mathbf{L_t} + \mathbf{D}$	
				$\mathbf{D} + (\mathbf{L_t} - SV_t)$

Source: Cunningham (2021), Causal Inference: The Mixtape.

Companies	Time	Average mortality	D_1	D_2
Lambeth	Before	$Y = L$		
	After	$Y = L + \mathbf{L_t} + \mathbf{D}$	$\mathbf{L_t} + \mathbf{D}$	
				$\mathbf{D} + (\mathbf{L_t} - SV_t)$
Southwark and Vauxhall	Before	$Y = SV$		

Source: Cunningham (2021), Causal Inference: The Mixtape.

Companies	Time	Average mortality	D_1	D_2
Lambeth	Before	$Y = L$		
	After	$Y = L + \mathbf{L_t} + \mathbf{D}$	$\mathbf{L_t} + \mathbf{D}$	
				$\mathbf{D} + (\mathbf{L_t} - SV_t)$
Southwark and Vauxhall	Before	$Y = SV$		
	After	$Y = SV + SV_t$	SV_t	

Source: Cunningham (2021), Causal Inference: The Mixtape.

Companies	Time	Average mortality	D_1	D_2
Lambeth	Before	62		
	After	14	−48	
				−97
Southwark and Vauxhall	Before	565		
	After	614	49	

Source: Cunningham (2021), Causal Inference: The Mixtape.

Mortalidad por cólera cada 100.000 habitantes

	Distritos de LC (tratados)	Distritos de SVC (comparación)
1849	131	165
1853	60	114
Diferencia	-71	-51

$$DD = (-71) - (-51) = -20$$

El 2×2 y tendencias paralelas

Lo que queremos y lo que calculamos

El parámetro de interés es el efecto promedio sobre los tratados

$$\delta^{ATT} = \mathbb{E}[Y_1 \mid \text{tratado, después}] - \mathbb{E}[Y_0 \mid \text{tratado, después}]$$

Y_1: resultado potencial bajo tratamiento. Y_0: resultado potencial sin tratamiento.

- El primer término lo observamos. En el período posterior, para los tratados, $Y = Y_1$.
- El segundo término no existe en los datos. Es el resultado que habrían tenido los tratados si no los hubiésemos tratado.
- Todo el diseño consiste en construir un reemplazo creíble para ese segundo término.

El diseño 2×2

Cunningham llama a este caso el DiD 2×2. Hay un grupo tratado k y un grupo no tratado U, y hay un antes y un después para cada uno.

$$\delta_{kU}^{2\times 2} = \left(\bar{y}_k^{post(k)} - \bar{y}_k^{pre(k)}\right) - \left(\bar{y}_U^{post(k)} - \bar{y}_U^{pre(k)}\right)$$

- El primer paréntesis es el cambio del grupo tratado.
- El segundo paréntesis es el cambio del grupo no tratado en esas mismas fechas.
- Esto es la mecánica del cálculo. La pregunta es a qué parámetro corresponde.

Paso 1. De promedios muestrales a esperanzas

Los promedios muestrales estiman esperanzas condicionales, así que escribimos

$$\delta_{kU}^{2\times 2} = \Big(\mathbb{E}[Y_k \mid \text{después}] - \mathbb{E}[Y_k \mid \text{antes}]\Big) - \Big(\mathbb{E}[Y_U \mid \text{después}] - \mathbb{E}[Y_U \mid \text{antes}]\Big)$$

- Todavía no aparecen resultados potenciales, solo resultados observados.
- El paso que sigue es reemplazar cada Y observado por el resultado potencial que le corresponde.

Paso 2. Aplicamos la ecuación de switching

La ecuación de switching dice $Y = D \cdot Y_1 + (1 - D) \cdot Y_0$: el resultado observado es Y_1 si hay tratamiento y Y_0 si no lo hay.

El grupo k está tratado solo en el período posterior. El grupo U nunca lo está.

$$\delta_{kU}^{2\times 2} = \Big(\mathbb{E}[Y_{1k} \mid \text{después}] - \mathbb{E}[Y_{0k} \mid \text{antes}]\Big) - \Big(\mathbb{E}[Y_{0U} \mid \text{después}] - \mathbb{E}[Y_{0U} \mid \text{antes}]\Big)$$

Ahora sumamos y restamos el mismo término, que es cero

$$+ \underbrace{\mathbb{E}[Y_{0k} \mid \text{después}] - \mathbb{E}[Y_{0k} \mid \text{después}]}_{\text{sumamos cero}}$$

Paso 3. La descomposición

Reordenando los términos

$$\delta_{kU}^{2\times 2} = \underbrace{\mathbb{E}[Y_{1k} \mid \text{después}] - \mathbb{E}[Y_{0k} \mid \text{después}]}_{ATT}$$

$$+ \underbrace{\Big(\mathbb{E}[Y_{0k} \mid \text{después}] - \mathbb{E}[Y_{0k} \mid \text{antes}]\Big) - \Big(\mathbb{E}[Y_{0U} \mid \text{después}] - \mathbb{E}[Y_{0U} \mid \text{antes}]\Big)}_{\text{sesgo de tendencias no paralelas}}$$

La diferencia de las diferencias aísla el ATT si y solo si el segundo renglón es cero.

$$\Big(\mathbb{E}[Y_{0k} \mid \text{después}] - \mathbb{E}[Y_{0k} \mid \text{antes}]\Big) = \Big(\mathbb{E}[Y_{0U} \mid \text{después}] - \mathbb{E}[Y_{0U} \mid \text{antes}]\Big)$$

- LHS: cuánto habría cambiado el grupo tratado si no lo hubiésemos tratado.
- RHS: cuánto cambió el grupo no tratado.
- Traducción: los resultados Y de ambos grupos (tratados k y no tratados U) habrían varíado de igual forma en ausencia del tratamiento (de ahí, el subíndice 0 para todos).

Por qué el supuesto no se puede testear

Miremos el objeto $\mathbb{E}[Y_{0k} \mid \text{después}]$.

- Es un resultado sin tratamiento, pero en el período en el que el grupo ya está tratado.
- Nunca lo observamos!

El supuesto central del diseño es no testeable. Todo lo que vamos a hacer de acá en adelante es juntar evidencia indirecta a favor.

Salario mínimo (Card y Krueger, 1994)

¿Cuál es el efecto del salario mínimo?

La teoría predice que,

- en un mercado de trabajo competitivo, subir el salario mínimo nos mueve sobre una demanda con pendiente negativa y sobre una oferta con pendiente positiva, aumentando el desempleo.
- en un mercado con poder de compra del lado del empleador, el salario mínimo puede aumentar el empleo.

¿Qué tipo de mercado se asemeja más a la realidad de Estados Unidos? No podemos asignar el salario mínimo de manera aleatoria. Mejor buscamos dos estados parecidos y vemos como cambian sus diferencias en niveles de desemplo cuando uno aumenta el salario mínimo.


PENNSYLVANIA
Pittsburgh
Harrisburg
Philadelphia
New
NEW JERSEY
MARYLAND
Baltimore

El diseño

- En noviembre de 1992 Nueva Jersey sube su salario mínimo de $4,25 a $5,05. Pensilvania, el estado vecino, lo deja en $4,25.
- Card y Krueger encuestan alrededor de 400 locales de comida rápida a los dos lados de la frontera.
- Una vez en febrero de 1992, antes de la suba, y otra vez en noviembre, después.
- Con esas dos olas miden empleo de tiempo completo equivalente en cada local.

Figure 1
Distribution of Starting Wage Rates

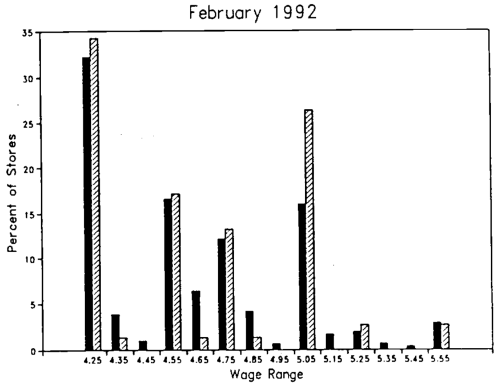


Figura 1. *Fuente: Card y Krueger (1993), NBER WP 4509.*

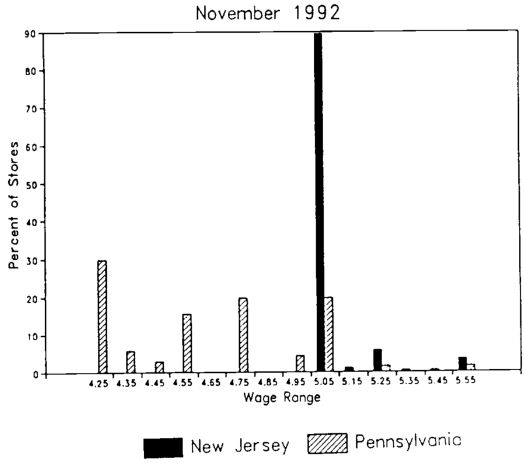


Figura 1. *Fuente: Card y Krueger (1993), NBER WP 4509.*

La descomposición, aplicada a Nueva Jersey

$$\delta^{2\times 2}_{NJ,PA} = \underbrace{\mathbb{E}[Y_{1,NJ} \mid \text{después}] - \mathbb{E}[Y_{0,NJ} \mid \text{después}]}_{ATT}$$

$$+ \underbrace{\Big(\mathbb{E}[Y_{0,NJ} \mid \text{después}] - \mathbb{E}[Y_{0,NJ} \mid \text{antes}]\Big) - \Big(\mathbb{E}[Y_{0,PA} \mid \text{después}] - \mathbb{E}[Y_{0,PA} \mid \text{antes}]\Big)}_{\text{sesgo de tendencias no paralelas}}$$

El cálculo con promedios

	Stores by state		
Dependent variable	PA	NJ	NJ − PA
FTE before	23.33	20.44	−2.89
	(1.35)	(0.51)	(1.44)
FTE after	21.17	21.03	−0.14
	(0.94)	(0.52)	(1.07)
Change in mean FTE	−2.16	0.59	2.76
	(1.25)	(0.54)	(1.36)

Source: Card y Krueger (1994), reproducida en Cunningham (2021). Standard errors in parentheses.

El resultado de Card y Krueger

- El empleo cayó en Pensilvania, donde no pasó nada, y subió levemente en Nueva Jersey, donde subió el salario mínimo.
- La estimación del DiD da +2,76 empleos de tiempo completo por local, no un número negativo.

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA			
NJ			
Diferencia			

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA	α		
NJ			
Diferencia			

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA	α	$\alpha + \lambda$	
NJ			
Diferencia			

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA	α	$\alpha + \lambda$	
NJ	$\alpha + \gamma$		
Diferencia			

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA	α	$\alpha + \lambda$	
NJ	$\alpha + \gamma$	$\alpha + \gamma + \lambda + \delta$	
Diferencia			

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA	α	$\alpha + \lambda$	λ
NJ	$\alpha + \gamma$	$\alpha + \gamma + \lambda + \delta$	
Diferencia			

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA	α	$\alpha + \lambda$	λ
NJ	$\alpha + \gamma$	$\alpha + \gamma + \lambda + \delta$	$\lambda + \delta$
Diferencia			

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA	α	$\alpha + \lambda$	λ
NJ	$\alpha + \gamma$	$\alpha + \gamma + \lambda + \delta$	$\lambda + \delta$
Diferencia	γ		

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

	Antes	Después	Diferencia
PA	α	$\alpha + \lambda$	λ
NJ	$\alpha + \gamma$	$\alpha + \gamma + \lambda + \delta$	$\lambda + \delta$
Diferencia	γ	$\gamma + \delta$	

La misma cuenta como regresión

$$Y_{its} = \alpha + \gamma\, NJ_s + \lambda\, D_t + \delta\, (NJ \times D)_{st} + \varepsilon_{its}$$

donde $NJ_s = 1$ si la observación es de Nueva Jersey y $D_t = 1$ si es de noviembre.

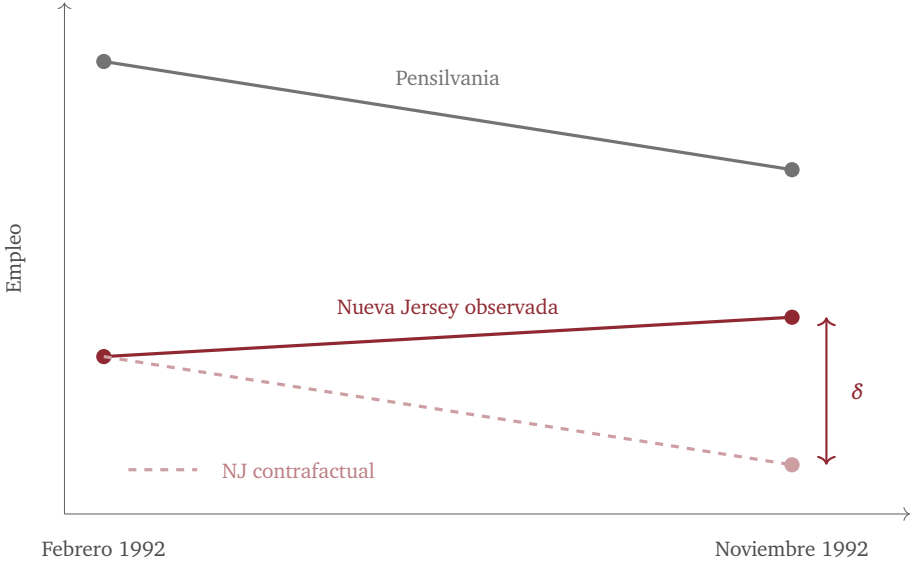
	Antes	Después	Diferencia
PA	α	$\alpha + \lambda$	λ
NJ	$\alpha + \gamma$	$\alpha + \gamma + \lambda + \delta$	$\lambda + \delta$
Diferencia	γ	$\gamma + \delta$	δ

Por qué usar regresión y no solo promedios

Con tendencias paralelas, la diferencia de promedios ya identifica el ATT. Igual solemos estimar por regresión.

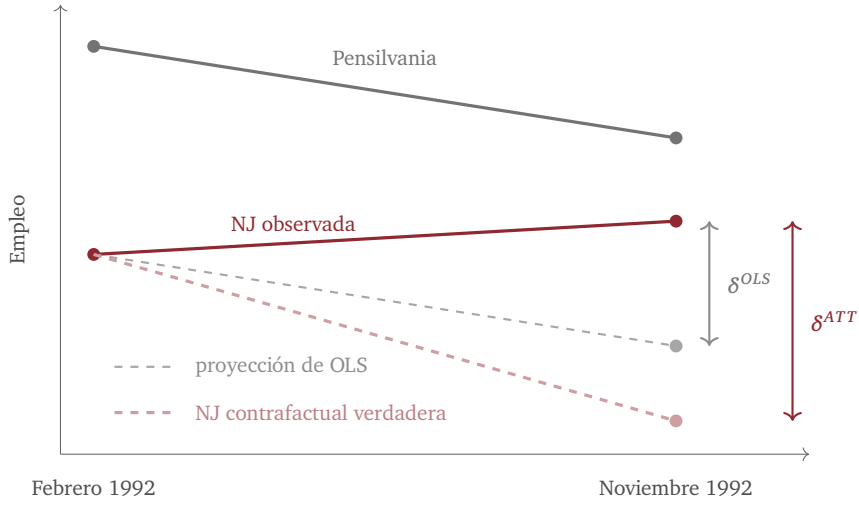
- Para incluir controles que varían en el tiempo y cerrar puertas traseras conocidas.
- Para reducir la varianza residual y ganar precisión.

Cuidado con cargar la regresión con todo lo que haya disponible. Si uno de esos controles es un colisionador, condicionarlo abre un camino que estaba cerrado y genera patrones que confunden.


Pensilvania
Empleo
Nueva Jersey observada
δ
NJ contrafactual
Febrero 1992
Noviembre 1992

OLS siempre estima esa línea

- OLS toma el cambio de Pensilvania y lo proyecta desde el punto de Nueva Jersey antes del tratamiento.
- Una vez completado ese valor faltante, el coeficiente es la distancia entre el valor observado y el valor proyectado.
- Lo hace siempre, sin importar si la pendiente de Pensilvania era o no la pendiente correcta para Nueva Jersey.


Pensilvania
NJ observada
Empleo
δ^{OLS}
δ^{ATT}
proyección de OLS
NJ contrafactual verdadera
Febrero 1992
Noviembre 1992

- OLS estima el ATT únicamente cuando la pendiente del control coincide con la pendiente contrafactual del tratado.
- Podría haber sido la línea gris. Podría haber sido cualquier otra. No lo sabemos, porque nunca ocurrió.
- Ahí está todo el trabajo del diseño: argumentar que las tendencias hubiesen sido paralelas en ausencia del tratamiento.

Inferencia con datos de panel

Recordemos, $$SE = \frac{\sigma}{\sqrt{n}}$$

Donde σ es la desviación estándar de los resultados de cada observación y n el número de observaciones independientes.

El problema de los errores estándar en el DiD

Muchos diseños de DiD usan datos de muchos años, no solo un antes y un después.

- La variable de interés varía a nivel de grupo, por ejemplo el estado.
- El resultado está correlacionado consigo mismo a lo largo del tiempo dentro de cada estado.
- Esa correlación viola la independencia que pide la fórmula del error estándar. Bertrand, Duflo y Mullainathan (2004) muestran que, al ignorarla, los errores estándar convencionales quedan demasiado chicos.

Lo que quiere decir que rechazamos la hipótesis nula mucho más seguido de lo que deberíamos. Encontramos efectos donde no los hay.

```
* Asi no: errores estandar convencionales
reg y treat post treatXpost, robust
```

La solución: clusterizar

- En vez de tratar cada observación como independiente, agrupa las observaciones de un mismo estado y les permite estar correlacionadas entre sí, como en la realidad.
- Entre estados sí asume independencia, como antes.
- El “tamaño de muestra” que cuenta para el error estándar deja de ser el número de observaciones y pasa a ser el número de clusters.

```
reg y treat post treatXpost, vce(cluster state)
```

Estudios de eventos

Volvamos al término que nos molesta

$$\Big(\mathbb{E}[Y_{0k} \mid \text{después}] - \mathbb{E}[Y_{0k} \mid \text{antes}]\Big) - \Big(\mathbb{E}[Y_{0U} \mid \text{después}] - \mathbb{E}[Y_{0U} \mid \text{antes}]\Big)$$

- No podemos evaluarlo porque el primer término es contrafactual.
- Lo que hacemos en su lugar es estimar coeficientes de DiD para los períodos anteriores al tratamiento.
- Si esos coeficientes son cero, los dos grupos venían moviéndose parecido antes del tratamiento.

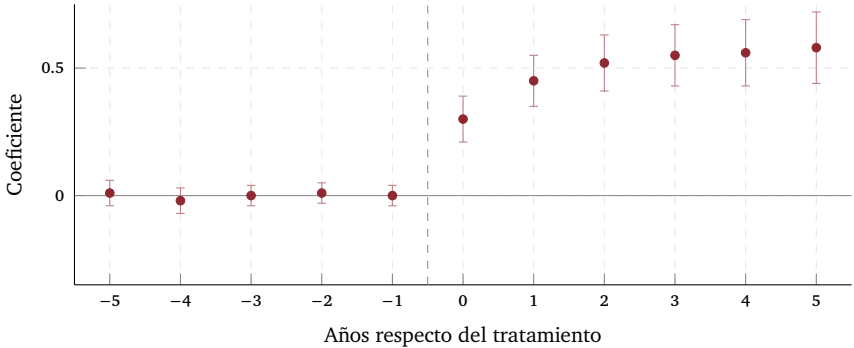
El modelo con leads y lags

$$Y_{its} = \gamma_s + \lambda_t + \sum_{\tau=-q}^{-1} \gamma_\tau D_{s\tau} + \sum_{\tau=0}^{m} \delta_\tau D_{s\tau} + x_{ist} + \varepsilon_{ist}$$

- El tratamiento ocurre en $\tau = 0$.
- Los q adelantos capturan efectos de anticipación y sirven de test previo.
- Los m rezagos muestran si el efecto varía con el tiempo.

Esto es un DiD donde, en vez de una sola variable de después, hay una por período.

Esquema de un estudio de eventos



Esquema ilustrativo. Coeficientes previos pegados al cero y estimados con precisión, salto en el momento del tratamiento, efecto que se sostiene después.

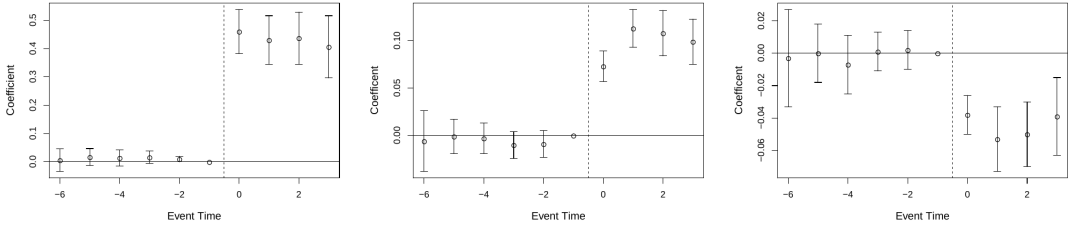
Estudios de eventos

Medicaid y mortalidad (Miller et al., 2019)

Medicaid y mortalidad (Miller et al., 2019)

- La expansión de Medicaid bajo la Affordable Care Act. Algunos estados la adoptaron y otros no.
- Trabajo previo dudaba de que Medicaid tuviera efectos sobre la mortalidad, así que revisitar la pregunta era importante.
- Los autores cruzan registros administrativos de defunciones con una encuesta federal grande. Saben quién estaba en Medicaid y quién no.

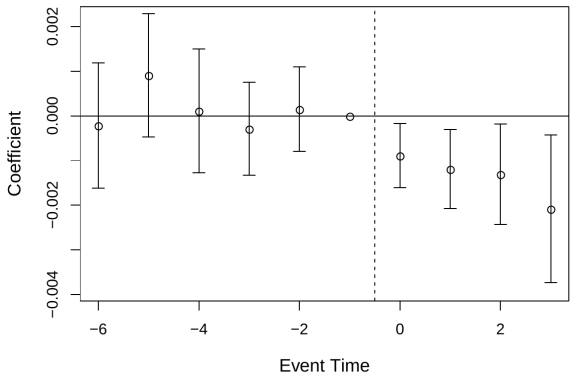
Figure 1: Effect of the ACA Medicaid Expansions on Eligibility and Coverage



(a) Medicaid Eligibility (b) Medicaid Coverage (c) Uninsured

Fuente: Miller, Altekruse, Johnson y Wherry (2019), NBER WP 26081.

Figure 2: Effect of the ACA Medicaid Expansions on Annual Mortality



Fuente: Miller, Altekruse, Johnson y Wherry (2019), NBER WP 26081.

Di Tella y Schargrodsky (2004)

¿Más policía en la calle reduce el crimen?

- La teoría económica del crimen de Becker (1968) predice que sí. Se asume que los criminales son racionales y evalúan los costos y beneficios de delinquir.
- Pero esa predicción no encontraba apoyo empírico. Cameron (1988) revisa la literatura y encuentra que en 18 de 22 papers, los investigadores estiman una relación positiva entre policía y crimen, o ninguna relación.
- El tema es que los gobiernos mandan más policía justamente a donde hay más crimen, así que responder esta pregunta con datos observacionales no es sencillo.

Hace falta variación en la cantidad de policía que no dependa del nivel de crimen del lugar.



- El 18 de julio de 1994 un atentado destruye la AMIA, el centro comunitario judío más importante de Buenos Aires. Mueren 85 personas.
- Una semana después, el gobierno ordena custodia policial de 24 horas para más de 270 instituciones judías y musulmanas en todo el país.
- La asignación de custodia depende de si el edificio es religioso, no de cuánto robo de autos había en esa cuadra.

Se rompe la endogeneidad.

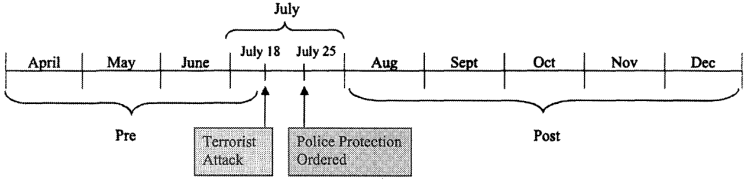


FIGURE 1. TIMELINE OF EVENTS

Fuente: Di Tella y Schargrodsky (2004), American Economic Review 94(1).

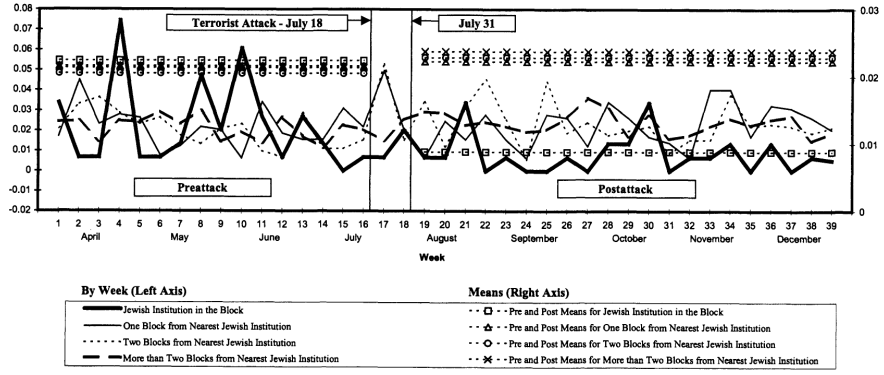
El diseño

- Datos de robos de auto por cuadra y por mes, en tres barrios de Buenos Aires, de abril a diciembre de 1994.
- Comparan cuadras con una institución judía o musulmana (*tratadas*, reciben custodia) contra el resto de las cuadras del barrio (*control*).
- Antes del atentado, ninguna cuadra tenía custodia. Después, solo las que tienen la institución.

La ecuación

$$CarTheft_{it} = \alpha_0 SameBlockPolice_{it} + \alpha_1 OneBlockPolice_{it} + \alpha_2 TwoBlocksPolice_{it} + M_t + F_i + \varepsilon_{it}$$

- $SameBlockPolice_{it}$ vale 1 después del atentado si la cuadra i tiene una institución protegida.
- $OneBlockPolice$ y $TwoBlocksPolice$ hacen lo mismo para las cuadras a una y a dos cuadras de distancia.
- M_t es efecto fijo de mes, F_i es efecto fijo de cuadra.



Fuente: Di Tella y Schargrodsky (2004), American Economic Review 94(1).

	Difference-in-difference		
Dependent variable: car thefts	(A)	(B)	(C)
Same-Block Police	−0.07752***	−0.08007***	−0.08080***
	(0.022)	(0.022)	(0.022)
One-Block Police		−0.01325	−0.01398
		(0.013)	(0.014)
Two-Blocks Police			−0.00218
			(0.012)
Block fixed effect	Yes	Yes	Yes
Month fixed effect	Yes	Yes	Yes

*Source: Di Tella y Schargrodsky (2004). Huber-White standard errors in parentheses. *** significant at 1%.*

Resultados

- El promedio de robos por cuadra en el grupo de control es 0,108. La caída es de casi el 75 %.
- A una cuadra o a dos cuadras de la institución protegida, el coeficiente no es distinguible de cero.

La policía en la puerta reduce el robo de auto ahí mismo. El efecto no se derrama ni siquiera a la cuadra de al lado.

Placebo (activada en fecha falsa)	April 30	May 31	June 30
Same-Block Police	−0.01864	0.01467	−0.03611
	(0.053)	(0.040)	(0.038)
One-Block Police	−0.02553	0.01402	0.02310
	(0.025)	(0.019)	(0.022)
Two-Blocks Police	−0.03263	−0.01465	−0.00940
	(0.022)	(0.017)	(0.016)
Block fixed effect	Yes	Yes	Yes
Month fixed effect	Yes	Yes	Yes

Source: Di Tella y Schargrodsky (2004), Table 4. Sample: April 1 – July 17, antes del atentado real.

El placebo

- Toman solo los datos de antes del atentado (abril a julio 17) y fingen que la custodia arrancó el 30 de abril, el 31 de mayo, o el 30 de junio.
- Si hubiera algo espurio (una cuadra con institución que ya viniera con una dinámica de crimen distinta), estos "efectos" falsos deberían salir significativos.
- Ningún coeficiente es significativo en ninguna de las tres fechas falsas.

Es el mismo truco de fechas placebo que vimos con Anderson et al. Acá lo corren los propios autores, sobre su propio diseño.

Conclusión

Lo que vimos hoy

- DiD evalúa como cambia la diferencia entre un grupo tratado uno no tratado antes y después del tratamiento.
- Todo se sostiene sobre un supuesto que no se puede probar directamente, tendencias paralelas. Se corrobora con leads planos y con placebos, nunca se demuestra.
- Funciona mejor cuando alguien de afuera decide quién se trata. El agua en Snow, la frontera de estados en Card y Krueger, la bomba en Di Tella y Schargrodsky.

Referencias

Referencias I

- Anderson, D. M., Hansen, B., & Rees, D. I. (2013). Medical marijuana laws, traffic fatalities, and alcohol consumption. *Journal of Law and Economics*, 56(2), 333–369.
- Angrist, J. D., & Pischke, J.-S. (2015). *Mastering 'metrics: The path from cause to effect*. Princeton University Press.
- Ashenfelter, O. (1978). Estimating the effect of training programs on earnings. *The Review of Economics and Statistics*, 60(1), 47–57.
- Bertrand, M., Duflo, E., & Mullainathan, S. (2004). How much should we trust differences-in-differences estimates? *The Quarterly Journal of Economics*, 119(1), 249–275.
- Card, D., & Krueger, A. B. (1994). Minimum wages and employment: A case study of the fast-food industry in New Jersey and Pennsylvania. *American Economic Review*, 84(4), 772–793.
- Cheng, C., & Hoekstra, M. (2013). Does strengthening self-defense law deter crime or escalate violence? Evidence from expansions to castle doctrine. *Journal of Human Resources*, 48(3), 821–854.
- Cunningham, S. (2021). *Causal inference: The Mixtape*. Yale University Press.

Referencias II

- Currie, J., Kleven, H., & Zwiers, E. (2020). Technology and big data are changing economics: Mining text to track methods. *AEA Papers and Proceedings*, 110, 42–48.
- Di Tella, R., & Schargrodsky, E. (2004). Do police reduce crime? Estimates using the allocation of police forces after a terrorist attack. *American Economic Review*, 94(1), 115–133.
- Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254–277.
- Kahn-Lang, A., & Lang, K. (2020). The promise and pitfalls of differences-in-differences. *Journal of Business & Economic Statistics*, 38(3), 613–620.
- Levitt, S. D. (1997). Using electoral cycles in police hiring to estimate the effect of police on crime. *American Economic Review*, 87(3), 270–290.
- McCrary, J. (2002). Using electoral cycles in police hiring to estimate the effect of police on crime: Comment. *American Economic Review*, 92(4), 1236–1243.
- Miller, S., Altekruse, S., Johnson, N., & Wherry, L. R. (2019). *Medicaid and mortality: New evidence from linked survey and administrative data* (NBER Working Paper No. 26081).
- Snow, J. (1855). *On the mode of communication of cholera* (2nd ed.). John Churchill.

Lecturas

Lecturas

Causal Inference: The Remix

Cunningham, S.

- Capítulo 9. *"Difference-in-Differences Fundamentals"* **LINK**

Mastering 'Metrics

Angrist, J. D., y Pischke, J.-S. (2015)

- Capítulo 5. *"Differences-in-Differences"*