

Validez de la Conclusión Estadística

Juan Martín Favetto

Primavera 2026

De dónde venimos

	$Y_i(0)$	$Y_i(1)$	τ_i
Unit 1	?	6	?
Unit 2	6	?	?
Unit 3	?	8	?
Unit 4	?	7	?
Unit 5	4	?	?
Unit 6	5	?	?
Average	5	7	2

Fuente: List (2026), Exhibit 3.2.

- Por el problema fundamental de la inferencia causal, sólo vemos un resultado potencial para cada individuo.
- No podemos recuperar los efectos individuales del tratamiento.
- Si se cumplen ciertos supuestos y tenemos un buen mecanismo de asignación (non-zero probability, individualism, unconfoundedness), podemos recuperar el efecto promedio del tratamiento.

Clase 9. Identificación

Supuestos sobre la población

$\tau = \mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0]$

¿Qué hace falta para que la diferencia de medias sea el ATE?

Clase 10. Medición

Datos de una muestra

$\hat{\tau} = \bar{Y}_1 - \bar{Y}_0$

¿Qué tan lejos puede estar $\hat{\tau}$ de τ?

Validez de la conclusión estadística

- Este capítulo se pregunta cómo cuantificar la incertidumbre en los parámetros que estimamos, de forma tal que podamos llegar a conclusiones estadísticamente válidas.
- ¿Cómo podemos estimar el efecto promedio del tratamiento en casos donde las restricciones de exclusión se cumplen y el mecanismo de asignación está bien?
- Vamos a recorrer los criterios que nos hablan de la validez de la conclusión que nos permite sacar nuestra estimación internamente válida.

Validez de la conclusión estadística

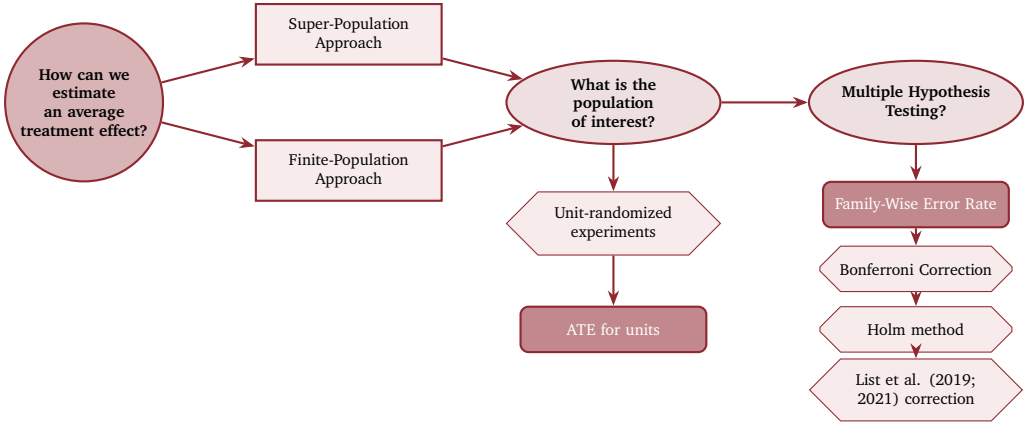
- Este capítulo se pregunta cómo cuantificar la incertidumbre en los parámetros que estimamos, de forma tal que podamos llegar a conclusiones estadísticamente válidas.
- ¿Cómo podemos estimar el efecto promedio del tratamiento en casos donde las restricciones de exclusión se cumplen y el mecanismo de asignación está bien?
- Vamos a recorrer los criterios que nos hablan de la validez de la conclusión que nos permite sacar nuestra estimación internamente válida.

Si no violamos ninguna restricción de exclusión y tenemos buena randomización, ¿podemos saber que esta es la verdad?

Ideas clave

1. Hay una relación entre diseño y muestreo.
2. Vamos a pensar cómo pasar de nuestras estimaciones del ATE a testear nuestras hipótesis.
3. En algunos casos vamos a tener varias hipótesis (tal vez sobre varios resultados). En esos casos, necesitamos controlar la tasa de error por familia de hipótesis (*family-wise error rate*, FWER).
4. Se ignora el rol de las covariables.

Mind's Eye: Measurement of Causal Effects



Fuente: List (2026), capítulo 4.

Dos experimentos

Aimone, North y Rentschler (2019)

- Desde 1995, Texas les ofrece a los jurados donar su pago a un fondo para víctimas de delitos, antes de cada juicio. Después de la ley subieron los veredictos de culpabilidad.
- ¿Pensar en las víctimas antes del juicio cambia el veredicto?
- Llevan el juzgado al laboratorio con estudiantes de Baylor. Aleatorizan si la pregunta de donación va antes o después del juicio.
- En promedio, el momento de la donación no cambia el veredicto. Los hombres a los que se les pregunta antes condenan más y las mujeres condenan menos.
- Un ATE cercano a cero puede esconder efectos de signo opuesto en distintos grupos.



Dal Bó, Finan, Li y Schechter (2021)

- En el Paraguay rural, cada extensionista agrícola asesora a unos 80 productores con visitas a sus chacras. Si no las hace, el programa no cumple su objetivo.
- ¿Monitorear a los extensionistas con celulares con GPS aumenta las visitas?
- Aleatorizan qué oficinas reciben los celulares. Antes, los supervisores señalan qué agentes responderían más al celular.
- Las visitas suben 6.6 puntos porcentuales y no son más cortas. Casi todo el efecto viene de los agentes señalados.
- Los supervisores saben cosas de sus agentes que no se ven en los datos. Sirve para decidir a quién darle primero los celulares.



¿De dónde viene la incertidumbre?

Sampling frameworks

Antes de discutir la estimación y la incertidumbre de las estimaciones, necesitamos ser precisos acerca de cuál es la fuente de la incertidumbre. Hay dos enfoques en inferencia causal con datos experimentales.

- **Super-population approach.** Hay una población hipotética infinita de la cual extraemos una muestra. La incertidumbre viene de qué unidades caen en la muestra y de la asignación del tratamiento.
- **Finite-population approach.** Tenemos una población finita, pero sólo observamos un resultado potencial por persona. La incertidumbre viene de la asignación del tratamiento.

Estos dos enfoques difieren conceptual y matemáticamente. Eso da lugar a distintas varianzas muestrales (*sampling variances*) del ATE.

Super-population approach

- Comienza definiendo una población hipotética infinita o, más formalmente, la distribución de probabilidades sobre los resultados potenciales, $\{Y(1), Y(0)\}$.
- Llamamos Q a esa distribución. Nos interesan características de Q, como la varianza de $Y(1)$ y de $Y(0)$.
- Bajo este enfoque, el investigador quiere conocer una característica de Q a partir de una muestra de tamaño n, extraída de manera independiente e idénticamente distribuida (i.i.d.).
- Por ejemplo, una característica particularmente relevante de Q es el efecto promedio del tratamiento, $\mathbb{E}[Y(1) - Y(0)]$.
- Buscamos estimarlo utilizando una muestra i.i.d. de resultados potenciales, $\{Y_i(1), Y_i(0)\}_{i=1}^{n}$.
- Además, existe un tratamiento binario $D \in \{0, 1\}$.

Super-population approach

El mecanismo de asignación define

1. el tratamiento que cada unidad de la muestra i.i.d. va a recibir,
2. cuál de los resultados potenciales se observa para la unidad i.

Es decir,

$$Y_i = Y_i(1)D_i + Y_i(0)(1 - D_i) \tag{4.1}$$

Un experimento es una muestra i.i.d. de tamaño n de Q más un mecanismo de asignación, que nos deja una muestra observada $\{Y_i, D_i\}_{i=1}^n$.

Super-population approach

El mecanismo de asignación define

1. el tratamiento que cada unidad de la muestra i.i.d. va a recibir,
2. cuál de los resultados potenciales se observa para la unidad i.

Es decir,

$$Y_i = Y_i(1)D_i + Y_i(0)(1 - D_i) \tag{4.1}$$

Un experimento es una muestra i.i.d. de tamaño n de Q más un mecanismo de asignación, que nos deja una muestra observada $\{Y_i, D_i\}_{i=1}^n$.

Hay dos fuentes de variación que van a surgir en cualquier muestra i.i.d. con respecto a la población.

- Variación muestral.
- Variación por el mecanismo de asignación.

Finite-population (or design-based) approach

- Comienza con una muestra finita de tamaño N.
- Esta población finita puede ser la población de interés o la muestra que podamos usar para el experimento. No hay propiedades generales de las unidades en esta población.
- A diferencia del super-population approach, los resultados potenciales de las unidades están fijos y no son aleatorios.
- Bajo esta perspectiva, el parámetro de interés es el *finite-population average treatment effect*,

$$\tau_{fp} = \frac{1}{N} \sum_{i=1}^{N} \left[Y_i(1) - Y_i(0) \right] \tag{4.2}$$

¿Por qué importa el marco muestral?

1. **Sobre quién es la conclusión.** En el finite-population approach, el efecto habla de las unidades del experimento. En el super-population approach habla de una población más grande, y eso vale sólo si la muestra la representa.

¿Por qué importa el marco muestral?

1. **Sobre quién es la conclusión.** En el finite-population approach, el efecto habla de las unidades del experimento. En el super-population approach habla de una población más grande, y eso vale sólo si la muestra la representa.
2. **Qué mide el error estándar.** Mide cuánto variaría $\hat{\tau}$ si repitiéramos el experimento. Para interpretarlo hay que saber qué se repite. Puede ser la muestra, la asignación o las dos.

¿Para quién vale el ATE? Aimone et al. (2019)

En Aimone et al. (2019), la conclusión sale de estudiantes de Baylor que estaban en la lista de correo del laboratorio y decidieron participar del experimento ($P = 1$).

- El ATE que recupera parece algo limitado para informar la política.



¿Para quién vale el ATE? Aimone et al. (2019)

En Aimone et al. (2019), la conclusión sale de estudiantes de Baylor que estaban en la lista de correo del laboratorio y decidieron participar del experimento ($P = 1$).

- El ATE que recupera parece algo limitado para informar la política.
- Sin embargo, tal vez Aimone et al. (2019) nos puede decir algo acerca de ciertos sesgos humanos. Incluso un ATE de una población muy acotada nos puede dar un resultado interesante para testear con un estudio más ambicioso.



¿Para quién vale el ATE? Dal Bó et al. (2021)

En Dal Bó et al. (2021), la conclusión sale de los extensionistas del sistema público paraguayo y de los productores que atienden. Los agentes no eligieron participar del experimento.

- La población del experimento es la misma a la que se le aplicaría la política.

¿Para quién vale el ATE? Dal Bó et al. (2021)

En Dal Bó et al. (2021), la conclusión sale de los extensionistas del sistema público paraguayo y de los productores que atienden. Los agentes no eligieron participar del experimento.

- La población del experimento es la misma a la que se le aplicaría la política.
- La asignación se hizo por oficina y no por agente. Los agentes de una misma oficina comparten el tratamiento, así que la variación por el mecanismo de asignación depende de cuáles oficinas resultaron tratadas.

Subpoblaciones en el super-population approach

Una consecuencia de hacer explícita la población de interés es la necesidad de incorporar explícitamente las subpoblaciones en el marco muestral. Por ejemplo, los CATEs y los EPATEs.

- En el caso de los CATEs, consideramos un marco muestral con una muestra i.i.d. de $\{Y(1,X),\ Y(0,X),\ X\}$, junto con supuestos sobre la relación entre $\{Y(1,X),\ Y(0,X)\}$ y D para cada valor que toma X.
- De la misma forma, para los EPATEs introducimos una variable aleatoria $P \in \{0,1\}$ que indica participación, y muestreamos de $\{Y(1,P),\ Y(0,P),\ P\}$, junto con supuestos sobre la relación entre $\{Y(1,P),\ Y(0,P)\}$ y D para cada valor que toma P.

De la población a los datos

La diferencia de medias

Con D_i asignado al azar, el ATE se puede escribir como una diferencia de esperanzas condicionales,

$$\begin{aligned}\tau &\equiv \mathbb{E}[Y_i(1) - Y_i(0)] \\ &= \mathbb{E}[Y_i(1) \mid D_i = 1] - \mathbb{E}[Y_i(0) \mid D_i = 0] \\ &= \underbrace{\mathbb{E}[Y_i \mid D_i = 1]}_{\text{esperanza condicional, tratados}} - \underbrace{\mathbb{E}[Y_i \mid D_i = 0]}_{\text{esperanza condicional, control}}\end{aligned} \tag{4.3}$$

Cada esperanza condicional se estima con su media muestral.

Motivando la diferencia de medias como estimador

- Hacemos supuestos al nivel de la población para mostrar que podemos recuperar el ATE a través de la diferencia de medias.
- Esta lógica se extiende inmediatamente a
  - CATEs, donde nos enfocamos en subconjuntos de nuestros datos,
  - EPATEs, donde nos enfocamos en subconjuntos de la población basados en la decisión de participar.
- La distinción clave en ambos es que la consistencia del estimador no depende del tamaño de los grupos de tratamiento y de control, sino del tamaño de las submuestras relevantes.

Exhibit 4.2: Estimates of Conditional Expectations and ATEs

Study	Outcome	$\frac{1}{n_1}\sum Y_i D_i$ Estimate of $\mathbb{E}[Y_i \mid D_i = 1]$ (A)	$\frac{1}{n_0}\sum Y_i(1 - D_i)$ Estimate of $\mathbb{E}[Y_i \mid D_i = 0]$ (B)	$\hat{\tau}$ Estimate of ATE (A) − (B)
Aimone, North, and Rentschler (2019)	Guilty verdict indicator	0.382	0.381	0.0011
Dal Bó, Finan, Li, and Schechter (2021)	House call indicator	0.336	0.270	0.066

Fuente: List (2026), Exhibit 4.2.

Test de hipótesis simple y poder estadístico

¿Qué tan seguros estamos?

Sin embargo, todavía nos falta información acerca de la incertidumbre de este estimador.

¿Podemos estar seguros de las magnitudes de los efectos que aparentemente encontramos?

¿Qué tan seguros estamos?

Sin embargo, todavía nos falta información acerca de la incertidumbre de este estimador.

¿Podemos estar seguros de las magnitudes de los efectos que aparentemente encontramos?

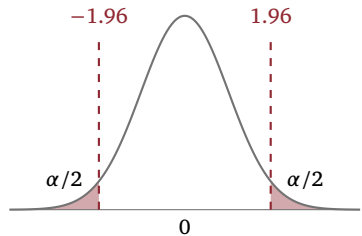
- La hipótesis nula es que el tratamiento no tiene efecto, $H_0 : \tau = 0$.
- La hipótesis alternativa es su complemento, $H_A : \tau \neq 0$.
- Con el ATE estimado y su error estándar estimado armamos el t-statistic, $t = \hat{\tau} / \widehat{\text{se}}(\hat{\tau})$.
- Si $|t|$ es suficientemente grande, rechazamos H_0.
- En Aimone et al., ¿podemos distinguir 0.0011 de cero? En Dal Bó et al., ¿y 0.066?

El t-statistic

- Cuando la muestra crece, el t-statistic (que surge del estimador muestral del ATE y del estimador muestral de su error estándar) converge a una distribución conocida, con propiedades que nos convienen. Es la campana de Gauss.
- En este marco, un t-statistic grande en valor absoluto sirve como evidencia en contra de la hipótesis nula.
- Para determinar a partir de qué umbral rechazamos la hipótesis nula, tenemos que definir un nivel de significatividad.

Error tipo I

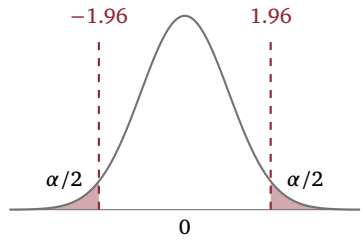
- Elegimos la tasa a la cual estamos cómodos rechazando equivocadamente la hipótesis nula. Rechazarla cuando es verdadera es el **error tipo I**.
- ¿Cuántos falsos positivos estamos dispuestos a ver en nuestros datos?
- El nivel de significatividad, α, es el área de las colas de la distribución bajo H_0. Define el valor crítico que usamos para decidir si rechazamos la hipótesis nula. Con $\alpha = 0.05$, rechazamos si $|t| > 1.96$.



Distribución de t bajo H_0.

Error tipo I

- Elegimos la tasa a la cual estamos cómodos rechazando equivocadamente la hipótesis nula. Rechazarla cuando es verdadera es el **error tipo I**.
- ¿Cuántos falsos positivos estamos dispuestos a ver en nuestros datos?
- El nivel de significatividad, α, es el área de las colas de la distribución bajo H_0. Define el valor crítico que usamos para decidir si rechazamos la hipótesis nula. Con $\alpha = 0.05$, rechazamos si $|t| > 1.96$.



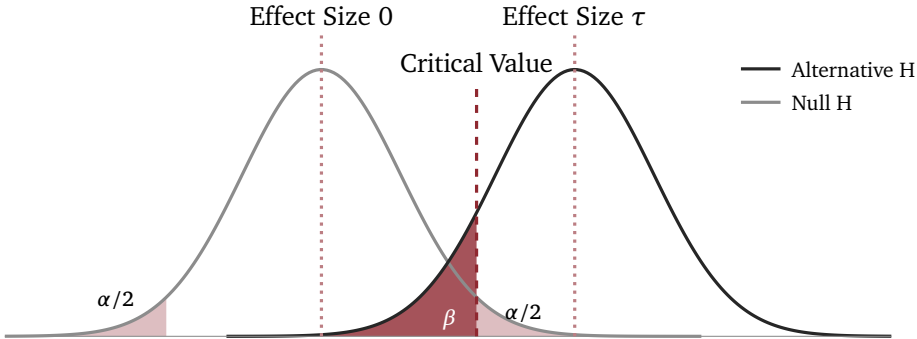
Distribución de t bajo H_0.

Pero rechazar equivocadamente la hipótesis nula no es nuestra única preocupación.

Error tipo II y el poder estadístico

- Así como elegimos una tasa de error tipo I, también debemos elegir un nivel aceptable para el otro error.
- El **poder estadístico** de un test de hipótesis es la probabilidad de detectar un efecto cuando de verdad existe.
- Asociado al poder está el **error tipo II**, β, que es la tasa a la cual rechazamos la hipótesis nula cuando en realidad deberíamos rechazarla. El poder es $1 - \beta$.

Exhibit 4.3: An Ocular View of Type I and II Errors and Power



$\alpha/2$ en cada cola de la distribución bajo H_0. β es el área de la distribución bajo H_A que queda a la izquierda del valor crítico. El poder es $1 - \beta$.

Fuente: List (2026), Exhibit 4.3.

Multiple hypothesis testing

Familias de hipótesis

Es muy raro un trabajo que sólo tenga un test simple de hipótesis. Casi siempre tenemos situaciones donde hay una familia de hipótesis.

- ¿Hay un efecto del tratamiento en alguno de los resultados?
- ¿Podemos encontrar un efecto del tratamiento para alguna subpoblación particular?
- ¿Alguno de los tratamientos tiene efecto?

Familias de hipótesis

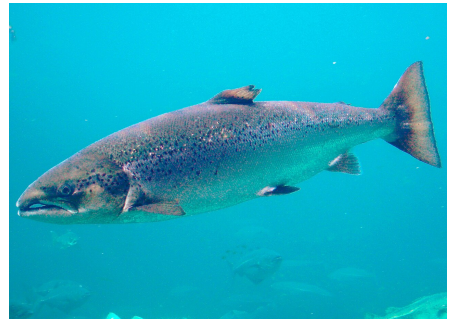
Es muy raro un trabajo que sólo tenga un test simple de hipótesis. Casi siempre tenemos situaciones donde hay una familia de hipótesis.

- ¿Hay un efecto del tratamiento en alguno de los resultados?
- ¿Podemos encontrar un efecto del tratamiento para alguna subpoblación particular?
- ¿Alguno de los tratamientos tiene efecto?

En estos casos, ¿cuál es el α correcto? ¿Cuál es la probabilidad correcta de un falso positivo cuando tengo varias hipótesis?

Bennett, Miller y Wolford (2009)

- Ponen un salmón del Atlántico muerto en un resonador (fMRI). Le muestran fotos de personas en situaciones sociales y le "piden" que identifique qué emoción tiene cada persona.
- El salmón está muerto. La hipótesis nula de cero actividad cerebral es verdadera en cada vóxel, el píxel en tres dimensiones del escáner.
- Usan un nivel de significatividad estricto, $\alpha = 0.001$, pero testean miles de vóxeles.
- Encuentran dos pequeñas zonas del cerebro del salmón que se "activan" con las fotos.



¿Por qué aparecen varias hipótesis?

Problemas de este estilo surgen normalmente por tres razones.

1. Cuando hay múltiples resultados Y_i y queremos determinar si son afectados por el tratamiento.
2. Para los CATEs, cuando el efecto del tratamiento varía entre subgrupos definidos por características observables y queremos saber para cuál de estos grupos el tratamiento tiene un efecto.
3. Cuando hay múltiples tratamientos D_i y deseamos determinar cuál es el efecto de cada uno.

Tenemos que determinar cuáles hipótesis dependen unas de otras y cuáles son independientes. El tema es determinar cuáles hipótesis son parte de la misma familia.

Tests conjuntos y tests múltiples

Podemos dividir la noción de comparaciones múltiples en dos grandes tipos de tests de hipótesis estadísticos, los conjuntos y los simultáneos o múltiples.

- El factor clave que distingue a los tests conjuntos de los múltiples es la pregunta que buscan responder.
- **Conjuntos:** ¿es verdadera al menos una de las hipótesis A y B que me planteo?
- **Múltiples:** ¿son las hipótesis A y B verdaderas simultáneamente?

Ejemplo. Dal Bó et al. (2021)

- Midieron los efectos del tratamiento sobre varios resultados.
- La pregunta que nos surge de tener varios tests es la siguiente. Dada una familia de hipótesis definida, ¿podemos seguir usando el nivel de significatividad α (usualmente, $\alpha = 0.05$) para cada test?

Ejemplo. Dal Bó et al. (2021)

- Midieron los efectos del tratamiento sobre varios resultados.
- La pregunta que nos surge de tener varios tests es la siguiente. Dada una familia de hipótesis definida, ¿podemos seguir usando el nivel de significatividad α (usualmente, $\alpha = 0.05$) para cada test?
- ¡No! De lo contrario vamos a pensar que todos los salmones muertos pueden pensar.
- Necesitamos extender la noción del nivel de significatividad al contexto del multiple testing.

Multiple hypothesis testing

Controlando por Family-wise Error Rate (FWER)

Family-wise error rate

Bajo la hipótesis nula, ¿cuál es la probabilidad de que, sólo por azar, rechacemos una de las múltiples hipótesis?

FWER con k tests

- Sabemos que la probabilidad de que cualquier test individual (de un total de k tests) rechace incorrectamente la hipótesis nula es α.
- ¿Qué ocurre con una familia de k tests?
- Denotemos por H_k el evento estadístico de que la k-ésima hipótesis rechace incorrectamente la nula al nivel α.
- Dado que sabemos que los tests son independientes, la FWER al testear por separado es

$$\begin{aligned}\mathbb{P}[\text{algún rechazo bajo la nula al nivel } \alpha] &= \\ &\vdots \\ &= 1 - (1-\alpha)^k\end{aligned}$$

Derivación paso a paso

- En un test de hipótesis individual, la probabilidad de no cometer un error de tipo I (es decir, de no rechazar correctamente la hipótesis nula) es $1 - \alpha$.
- La probabilidad de no cometer ningún error de tipo I en los k tests (suponiendo que los tests son independientes) es $(1 - \alpha)^k$.

Derivación paso a paso

- En un test de hipótesis individual, la probabilidad de no cometer un error de tipo I (es decir, de no rechazar correctamente la hipótesis nula) es $1 - \alpha$.
- La probabilidad de no cometer ningún error de tipo I en los k tests (suponiendo que los tests son independientes) es $(1 - \alpha)^k$.
- La probabilidad de cometer al menos un error de tipo I en k tests es el complemento de la probabilidad de no cometer ningún error de tipo I en los k tests. Por lo tanto, la FWER se calcula como $1 - (1 - \alpha)^k$.

Derivación paso a paso

- En un test de hipótesis individual, la probabilidad de no cometer un error de tipo I (es decir, de no rechazar correctamente la hipótesis nula) es $1 - \alpha$.
- La probabilidad de no cometer ningún error de tipo I en los k tests (suponiendo que los tests son independientes) es $(1 - \alpha)^k$.
- La probabilidad de cometer al menos un error de tipo I en k tests es el complemento de la probabilidad de no cometer ningún error de tipo I en los k tests. Por lo tanto, la FWER se calcula como $1 - (1 - \alpha)^k$.
- Si realizamos $k = 5$ tests, cada uno con $\alpha = 0.05$, la probabilidad de no cometer ningún error de tipo I en los 5 tests es $(1 - 0.05)^5 = 0.95^5 = 0.7738$.

Derivación paso a paso

- En un test de hipótesis individual, la probabilidad de no cometer un error de tipo I (es decir, de no rechazar correctamente la hipótesis nula) es $1 - \alpha$.
- La probabilidad de no cometer ningún error de tipo I en los k tests (suponiendo que los tests son independientes) es $(1 - \alpha)^k$.
- La probabilidad de cometer al menos un error de tipo I en k tests es el complemento de la probabilidad de no cometer ningún error de tipo I en los k tests. Por lo tanto, la FWER se calcula como $1 - (1 - \alpha)^k$.
- Si realizamos $k = 5$ tests, cada uno con $\alpha = 0.05$, la probabilidad de no cometer ningún error de tipo I en los 5 tests es $(1 - 0.05)^5 = 0.95^5 = 0.7738$.
- Por lo tanto, FWER $= 1 - 0.7738 = 0.2262$. Es decir, hay aproximadamente un 22.62% de probabilidad de cometer al menos un error de tipo I a lo largo de los 5 tests.

Controlando por FWER

Como el problema de MHT puede aumentar mucho la tasa de falsos positivos, se han buscado muchas soluciones. Discutamos tres versiones.

1. Bonferroni correction.
2. Holm-Bonferroni correction.
3. List et al. correction.

1. Bonferroni correction

- Busca mantener la FWER en un nivel igual o inferior a α_{FWER}.
- Un umbral de $\alpha^* = \dfrac{\alpha_{\text{FWER}}}{k}$ para cada test individual logra una FWER de α_{FWER} o menos.

	Sin corregir		Bonferroni	
k	α de cada test	FWER real	α^* de cada test	FWER real
1	0.05	0.05	0.05	0.05
2	0.05	0.0975	0.025	0.0494
5	0.05	0.2262	0.01	0.0490
10	0.05	0.4013	0.005	0.0489

$\alpha_{\text{FWER}} = 0.05$. FWER real $= 1 - (1 - \alpha)^k$, suponiendo tests independientes.

1. Bonferroni correction

- Busca mantener la FWER en un nivel igual o inferior a α_{FWER}.
- Un umbral de $\alpha^* = \dfrac{\alpha_{\text{FWER}}}{k}$ para cada test individual logra una FWER de α_{FWER} o menos.
- Además, esta corrección no toma en cuenta que puede haber diferentes grados de evidencia para cada hipótesis. Eso la vuelve todavía más exigente.

	Sin corregir		Bonferroni	
k	α de cada test	FWER real	α^* de cada test	FWER real
1	0.05	0.05	0.05	0.05
2	0.05	0.0975	0.025	0.0494
5	0.05	0.2262	0.01	0.0490
10	0.05	0.4013	0.005	0.0489

$\alpha_{\text{FWER}} = 0.05$. FWER real $= 1 - (1 - \alpha)^k$, suponiendo tests independientes.

1. Bonferroni correction

Testeamos $k = 5$ hipótesis con $\alpha_{\text{FWER}} = 0.05$. Entonces $\alpha^* = 0.05/5 = 0.01$.

Hipótesis	p-value	¿p-value < 0.01?	p-value ajustado ($5\times$ p-value)
H_1	0.001	Sí	0.005
H_2	0.008	Sí	0.040
H_3	0.012	No	0.060
H_4	0.020	No	0.100
H_5	0.300	No	1

Comparar cada p-value con α^* es lo mismo que multiplicarlo por k (con tope en 1) y compararlo con α_{FWER}. Bonferroni rechaza 2 de las 5 hipótesis.

Exhibit 4.4: Simple Rules of Thumb for Bonferroni Correction

Number of Hypotheses	Largest Unadjusted p-value	Bonferroni Adjusted (bounded above by 1)
1	0.05	0.05
	0.01	0.01
	0.001	0.001
2	0.05	0.10
	0.01	0.02
	0.001	0.002
5	0.05	0.25
	0.01	0.05
	0.001	0.005
10	0.05	0.50
	0.01	0.10
	0.001	0.01

The table presents the Bonferroni adjusted p-values for a series of representative scenarios that vary in the number of hypotheses considered and the magnitude of the smallest p-value across all hypotheses. We note that, even when we have only two hypotheses, the Bonferroni method has a substantial impact on the p-value. That is, the Bonferroni correction is considerable even when the number of hypotheses is small. Intuitively, with two hypotheses, the results show that if you do not correct for multiple testing, there is a Type 1 error rate of 0.1 rather than 0.05.

Fuente: List (2026), Exhibit 4.4.

2. Holm-Bonferroni correction

- La corrección de Bonferroni no aprovecha que, aun con tests independientes, la fuerza de la evidencia (medida por el p-value) no tiene por qué ser la misma en todos los tests.
- Tal vez podría ser posible utilizar una corrección menos conservadora que el método de Bonferroni, eligiendo de manera adaptativa un conjunto de α^*s a lo largo de los tests.

2. Holm-Bonferroni correction

- La corrección de Bonferroni no aprovecha que, aun con tests independientes, la fuerza de la evidencia (medida por el p-value) no tiene por qué ser la misma en todos los tests.
- Tal vez podría ser posible utilizar una corrección menos conservadora que el método de Bonferroni, eligiendo de manera adaptativa un conjunto de α^*s a lo largo de los tests.
- El método de Holm comienza con una lista de los p-values ordenados de manera creciente, correspondientes a cada hipótesis de la familia de hipótesis.

2. Holm-Bonferroni correction

- La corrección de Bonferroni no aprovecha que, aun con tests independientes, la fuerza de la evidencia (medida por el p-value) no tiene por qué ser la misma en todos los tests.
- Tal vez podría ser posible utilizar una corrección menos conservadora que el método de Bonferroni, eligiendo de manera adaptativa un conjunto de α^*s a lo largo de los tests.
- El método de Holm comienza con una lista de los p-values ordenados de manera creciente, correspondientes a cada hipótesis de la familia de hipótesis.
- Comenzando por el p-value más pequeño, lo comparamos con el umbral de Bonferroni.

2. Holm-Bonferroni correction

- La corrección de Bonferroni no aprovecha que, aun con tests independientes, la fuerza de la evidencia (medida por el p-value) no tiene por qué ser la misma en todos los tests.
- Tal vez podría ser posible utilizar una corrección menos conservadora que el método de Bonferroni, eligiendo de manera adaptativa un conjunto de α^*s a lo largo de los tests.
- El método de Holm comienza con una lista de los p-values ordenados de manera creciente, correspondientes a cada hipótesis de la familia de hipótesis.
- Comenzando por el p-value más pequeño, lo comparamos con el umbral de Bonferroni.
- Si no rechazamos la nula, entonces necesariamente todas las demás hipótesis de la familia tampoco se rechazarían con el umbral de Bonferroni (dado que los p-values están ordenados de manera creciente).

2. Holm-Bonferroni paso a paso

Los mismos 5 p-values, ordenados de menor a mayor, son 0.001, 0.008, 0.012, 0.020 y 0.300. Con $\alpha_{\text{FWER}} = 0.05$,

- **Paso 1:** ¿$0.001 < 0.05/5 = 0.01$? Sí. Rechazamos y pasamos al siguiente.

2. Holm-Bonferroni paso a paso

Los mismos 5 p-values, ordenados de menor a mayor, son 0.001, 0.008, 0.012, 0.020 y 0.300. Con $\alpha_{\text{FWER}} = 0.05$,

- **Paso 1:** ¿$0.001 < 0.05/5 = 0.01$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 2:** ¿$0.008 < 0.05/4 = 0.0125$? Sí. Rechazamos y pasamos al siguiente.

2. Holm-Bonferroni paso a paso

Los mismos 5 p-values, ordenados de menor a mayor, son 0.001, 0.008, 0.012, 0.020 y 0.300. Con $\alpha_{\text{FWER}} = 0.05$,

- **Paso 1:** ¿$0.001 < 0.05/5 = 0.01$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 2:** ¿$0.008 < 0.05/4 = 0.0125$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 3:** ¿$0.012 < 0.05/3 \approx 0.0167$? Sí. Rechazamos y pasamos al siguiente.

2. Holm-Bonferroni paso a paso

Los mismos 5 p-values, ordenados de menor a mayor, son 0.001, 0.008, 0.012, 0.020 y 0.300. Con $\alpha_{\text{FWER}} = 0.05$,

- **Paso 1:** ¿$0.001 < 0.05/5 = 0.01$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 2:** ¿$0.008 < 0.05/4 = 0.0125$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 3:** ¿$0.012 < 0.05/3 \approx 0.0167$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 4:** ¿$0.020 < 0.05/2 = 0.025$? Sí. Rechazamos y pasamos al siguiente.

2. Holm-Bonferroni paso a paso

Los mismos 5 p-values, ordenados de menor a mayor, son 0.001, 0.008, 0.012, 0.020 y 0.300. Con $\alpha_{\text{FWER}} = 0.05$,

- **Paso 1:** ¿$0.001 < 0.05/5 = 0.01$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 2:** ¿$0.008 < 0.05/4 = 0.0125$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 3:** ¿$0.012 < 0.05/3 \approx 0.0167$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 4:** ¿$0.020 < 0.05/2 = 0.025$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 5:** ¿$0.300 < 0.05/1 = 0.05$? No. No rechazamos.

2. Holm-Bonferroni paso a paso

Los mismos 5 p-values, ordenados de menor a mayor, son 0.001, 0.008, 0.012, 0.020 y 0.300. Con $\alpha_{\text{FWER}} = 0.05$,

- **Paso 1:** ¿$0.001 < 0.05/5 = 0.01$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 2:** ¿$0.008 < 0.05/4 = 0.0125$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 3:** ¿$0.012 < 0.05/3 \approx 0.0167$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 4:** ¿$0.020 < 0.05/2 = 0.025$? Sí. Rechazamos y pasamos al siguiente.
- **Paso 5:** ¿$0.300 < 0.05/1 = 0.05$? No. No rechazamos.
- Holm rechaza 4 de las 5 hipótesis. Bonferroni, con los mismos p-values, rechazaba 2.

3. List et al. correction

- Holm sigue teniendo el problema de que puede haber dependencia entre múltiples tests.

3. List et al. correction

- Holm sigue teniendo el problema de que puede haber dependencia entre múltiples tests.
- List, Shaikh y Xu (2019) y List, Shaikh y Vayalinkal (2023) proponen un método para corregir por testeo múltiple que tiene en cuenta la dependencia entre tests, al costo de supuestos débiles y una carga computacional (relativamente) alta.

¿Quién está en la familia?

Determinar si un conjunto de hipótesis debe considerarse una “familia” implica considerar el contexto y los objetivos del estudio (conjunto vs. individual, común vs. separado).

¿Quién está en la familia?

- Un único tratamiento, un único resultado y múltiples subpoblaciones. Probablemente pertenecen a la familia.
- Un único tratamiento, múltiples resultados y una única subpoblación. Poco claro.
- Múltiples tratamientos, un único resultado y una única subpoblación. Probablemente pertenecen a la familia.

Fuente: List, Shaikh y Vayalinkal (2023), Remark 2.1, p. 922.

Conclusión

Lo que vimos hoy

- Antes de medir la incertidumbre hay que decir de dónde viene el azar. El super-population approach y el finite-population approach definen sobre quién es la conclusión y qué mide el error estándar.

Lo que vimos hoy

- Antes de medir la incertidumbre hay que decir de dónde viene el azar. El super-population approach y el finite-population approach definen sobre quién es la conclusión y qué mide el error estándar.
- Identificación y estimación son dos pasos distintos. Con asignación aleatoria, la diferencia de esperanzas identifica el ATE. La diferencia de medias lo estima de forma insesgada y consistente. Para CATEs y EPATEs lo que importa es el tamaño de la submuestra relevante.

Lo que vimos hoy

- Antes de medir la incertidumbre hay que decir de dónde viene el azar. El super-population approach y el finite-population approach definen sobre quién es la conclusión y qué mide el error estándar.
- Identificación y estimación son dos pasos distintos. Con asignación aleatoria, la diferencia de esperanzas identifica el ATE. La diferencia de medias lo estima de forma insesgada y consistente. Para CATEs y EPATEs lo que importa es el tamaño de la submuestra relevante.
- Un test de hipótesis tiene dos errores. El error tipo I (α) lo elegimos. El error tipo II (β) y el poder dependen del diseño.

Lo que vimos hoy

- Antes de medir la incertidumbre hay que decir de dónde viene el azar. El super-population approach y el finite-population approach definen sobre quién es la conclusión y qué mide el error estándar.
- Identificación y estimación son dos pasos distintos. Con asignación aleatoria, la diferencia de esperanzas identifica el ATE. La diferencia de medias lo estima de forma insesgada y consistente. Para CATEs y EPATEs lo que importa es el tamaño de la submuestra relevante.
- Un test de hipótesis tiene dos errores. El error tipo I (α) lo elegimos. El error tipo II (β) y el poder dependen del diseño.
- Con una familia de hipótesis, testear cada una a 0.05 infla los falsos positivos. Con 5 tests, la FWER llega a 0.23. Bonferroni, Holm y List et al. la controlan, cada uno con más poder que el anterior.

Preguntas que hay que hacerse

1. ¿Cuál es la población de interés? ¿De qué población salen mis datos?

Preguntas que hay que hacerse

1. ¿Cuál es la población de interés? ¿De qué población salen mis datos?
2. ¿De dónde viene la incertidumbre? ¿Del muestreo, de la asignación o de las dos?

Preguntas que hay que hacerse

1. ¿Cuál es la población de interés? ¿De qué población salen mis datos?
2. ¿De dónde viene la incertidumbre? ¿Del muestreo, de la asignación o de las dos?
3. ¿Qué parámetro estoy estimando (ATE, CATE o EPATE)? ¿Cuántas unidades tengo en la submuestra relevante?

Preguntas que hay que hacerse

1. ¿Cuál es la población de interés? ¿De qué población salen mis datos?
2. ¿De dónde viene la incertidumbre? ¿Del muestreo, de la asignación o de las dos?
3. ¿Qué parámetro estoy estimando (ATE, CATE o EPATE)? ¿Cuántas unidades tengo en la submuestra relevante?
4. ¿Mi estimación se distingue de cero? Si el efecto existía, ¿qué probabilidad tenía de detectarlo?

Preguntas que hay que hacerse

1. ¿Cuál es la población de interés? ¿De qué población salen mis datos?
2. ¿De dónde viene la incertidumbre? ¿Del muestreo, de la asignación o de las dos?
3. ¿Qué parámetro estoy estimando (ATE, CATE o EPATE)? ¿Cuántas unidades tengo en la submuestra relevante?
4. ¿Mi estimación se distingue de cero? Si el efecto existía, ¿qué probabilidad tenía de detectarlo?
5. ¿Cuántas hipótesis estoy testeando? ¿Cuáles forman una familia? ¿Corregí por testeo múltiple?

Preguntas que hay que hacerse

1. ¿Cuál es la población de interés? ¿De qué población salen mis datos?
2. ¿De dónde viene la incertidumbre? ¿Del muestreo, de la asignación o de las dos?
3. ¿Qué parámetro estoy estimando (ATE, CATE o EPATE)? ¿Cuántas unidades tengo en la submuestra relevante?
4. ¿Mi estimación se distingue de cero? Si el efecto existía, ¿qué probabilidad tenía de detectarlo?
5. ¿Cuántas hipótesis estoy testeando? ¿Cuáles forman una familia? ¿Corregí por testeo múltiple?
6. ¿Cuál es el diseño óptimo del experimento?

Referencias

Referencias I

- Aimone, J. A., North, C., & Rentschler, L. (2019). Priming the jury by asking for donations: An empirical and experimental study. *Journal of Economic Behavior & Organization*, 160, 158–167.
- Bennett, C. M., Miller, M. B., & Wolford, G. L. (2009). Neural correlates of interspecies perspective taking in the post-mortem Atlantic salmon: An argument for multiple comparisons correction. *NeuroImage*, 47(Suppl. 1), S125.
- Bonferroni, C. E. (1935). Il calcolo delle assicurazioni su gruppi di teste. *Studi in Onore del Professore Salvatore Ortu Carboni*, 13–60.
- Dal Bó, E., Finan, F., Li, N. Y., & Schechter, L. (2021). Information technology and government decentralization: Experimental evidence from Paraguay. *Econometrica*, 89(2), 677–701.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- List, J. A. (2026). *Experimental economics: Theory and practice*. University of Chicago Press.
- List, J. A., Shaikh, A. M., & Vayalinkal, A. (2023). Multiple testing with covariate adjustment in experimental economics. *Journal of Applied Econometrics*, 38(6), 920–939.

Referencias II

- List, J. A., Shaikh, A. M., & Xu, Y. (2019). Multiple hypothesis testing in experimental economics. *Experimental Economics*, 22(4), 773–793.

Lecturas

Lecturas

Experimental Economics: Theory and Practice
List, J. A. (2026)

- Capítulo 4. *"Statistical Conclusion Validity: Measurement in Economic Experiments"*

Contacto

Contacto

Email

juanifavetto@gmail.com

Teléfono

+54 9 2972 40-8438

Por favor evitar usar el webcampus