

Diseño Experimental Óptimo

Juan Martín Favetto

Primavera 2026

Re-cap

- Los experimentos resuelven el problema de la falta de datos.
- Para poder recuperar estimadores válidos a partir de las diferencias de medias necesitamos que se cumplan ciertos criterios en el mecanimsmo de asignación y las restricciones de exclusión.
- La validez de la conclusión que saquemos a partir de los estimadores recuperados depende de la magnitud del efecto encontrado relativo a su desvío estandár.

Re-cap

- Los experimentos resuelven el problema de la falta de datos.
- Para poder recuperar estimadores válidos a partir de las diferencias de medias necesitamos que se cumplan ciertos criterios en el mecanimsmo de asignación y las restricciones de exclusión.
- La validez de la conclusión que saquemos a partir de los estimadores recuperados depende de la magnitud del efecto encontrado relativo a su desvío estandár.
- Hoy: ¿Cómo podemos hacer un diseño óptimo? es decir ¿qué criterios vamos a usar para determinar cuántas unidades van a cada brazo del experimento?

Clase 9. Identificación

Supuestos sobre la población

$\tau = \mathbb{E}[Y_i(1) - Y_i(0)]$

¿Qué hace falta para que la diferencia de medias sea el ATE?

Clase 10. Medición

Datos de una muestra

$\hat{\tau} = \bar{Y}_1 - \bar{Y}_0$

¿Qué tan lejos puede estar $\hat{\tau}$ de τ?

Clase 11. Diseño

Antes de tener datos

$n_0,\ n_1,\ P,\ m,\ k$

¿Cuántas unidades necesitamos y cómo las repartimos?

El experimentador genera los datos

- En un experimento, el investigador elige el mecanismo de asignación. El proceso que genera los datos queda en sus manos.
- Eso trae decisiones que no aparecen cuando trabajamos con datos observacionales. Cuántas unidades aleatorizar. A qué tratamientos asignarlas. Qué forma toman los tratamientos. Qué resultados medir.

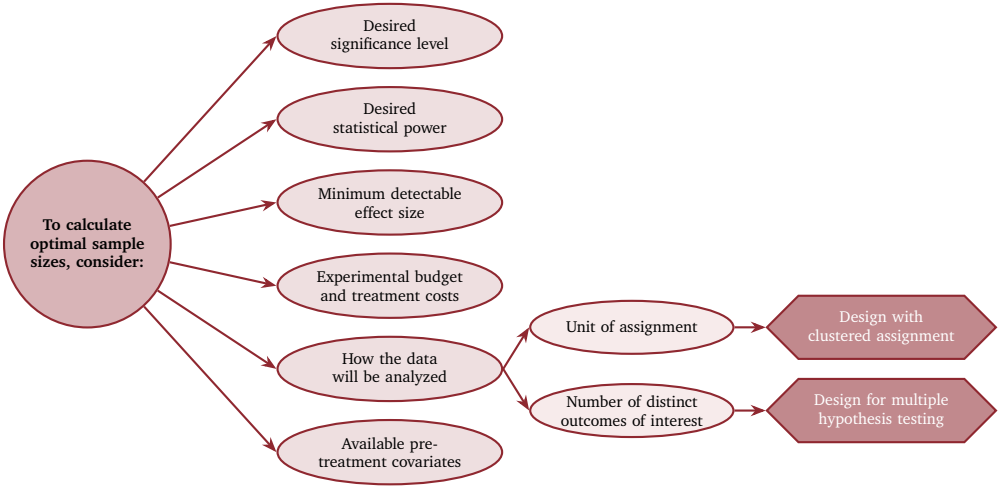
El experimentador genera los datos

- En un experimento, el investigador elige el mecanismo de asignación. El proceso que genera los datos queda en sus manos.
- Eso trae decisiones que no aparecen cuando trabajamos con datos observacionales. Cuántas unidades aleatorizar. A qué tratamientos asignarlas. Qué forma toman los tratamientos. Qué resultados medir.
- Un diseño subóptimo en general puede conservar la validez interna. El problema de optimización en el diseño implica generar la evidencia de la forma más barata posible y evitar correr experimentos si puedo anticipar que no encontrarán el resultado que se esperaría normalmente.

Ideas clave

1. El poder estadístico indica qué tan probable es detectar un efecto cuando de verdad existe.
2. Hay varias formas de aumentar el poder de un experimento, desde el diseño inicial hasta el análisis de los datos.
3. El tamaño de la muestra, la variación del tratamiento, el costo por observación, la variabilidad de la respuesta al tratamiento, las covariables previas al tratamiento y la forma de modelar los datos juegan un rol clave en el diseño óptimo.
4. Cuando la unidad de aleatorización es distinta de la unidad de observación, hay que tener en cuenta los clusters.

Mind's Eye: Optimal Experimental Design



Fuente: List (2026), capítulo 5.

Tres experimentos

Holladay, LaRiviere, Novgorodsky y Price (2019)

- Una empresa de energía de un estado del sur de Estados Unidos quiere que los hogares hagan auditorías energéticas en sus casas (*in-home energy audits*, IHEA).
- Los hogares tratados reciben cartas sobre el programa. Las cartas aleatorizan mensajes con normas sociales (*nudges*) y un subsidio para la auditoría. El grupo de control no recibe carta.
- El resultado es binario. ¿El hogar hizo la auditoría?
- Los nudges funcionan algo mejor que los subsidios. Igual, ninguno de los dos cambia mucho la tasa de auditorías. Y muy pocas auditorías terminan en mejoras de eficiencia.

Bessone, Rao, Schilbach, Schofield y Toma (2021)

- En Chennai (India), la población urbana pobre duerme mal. Pasa muchas horas en la cama, duerme pocas y se despierta seguido.
- Aleatorizan información sobre cómo dormir mejor y acceso a dispositivos que ayudan a dormir. A una parte de los tratados le ofrecen además un pago por cada minuto de sueño por encima de su nivel inicial.
- Los resultados son continuos. Horas de sueño, calidad del sueño, productividad, ingresos y memoria.
- Los tratamientos nocturnos aumentan el tiempo en la cama. Las horas dormidas y los demás resultados quedan igual. Las siestas en el trabajo aumentan la productividad y varias medidas cognitivas y de bienestar.

El experimento de Oregon (Finkelstein et al., 2016)

- En 2008, Oregon expandió Medicaid para adultos pobres sin seguro con una lotería. Ganar la lotería permitía inscribirse.
- Como la selección al programa quedó aleatorizada, se pueden estimar los efectos causales de Medicaid.
- Se esperaba que el seguro aumentara el uso de la atención primaria y redujera las visitas a la guardia (*emergency department*, ED).
- Pasó lo contrario. Las visitas a la guardia aumentaron 40% en los 15 meses posteriores a la lotería.

Exhibit 5.1: Essential Elements of Our Three Running Examples

Experiment	Type	Units	Control Condition	Treatment Condition(s)	Outcome(s)
Holladay, LaRiviere, Novgorodsky, and Price (2019)	NFE	Households in a mid-size southern U.S. state	No letter, nudge, or subsidy around in-home energy audits (IHEAs)	Nudges and/or subsidies for IHEAs	Binary: completion of an IHEA
Bessone, Rao, Schilbach, Schofield, and Toma (2021)	FFE	Temporary data entry workers in Chennai, India aged 25 to 55, had numerical literacy, had relatively low earnings, and had willingness and ability to have sleep monitored	Sleep monitoring	Sleep monitoring together with access to naps, sleep encouragement, and sleep subsidies	Many continuous, including sleep amount, sleep quality, worker productivity, earnings, and memory
Oregon Health Insurance Experiment (OHIE; Finkelstein et al., 2016)	FFE	Uninsured low-income adults	No Medicaid coverage	Medicaid coverage	Many, with the focus on emergency room visits

Fuente: List (2026), Exhibit 5.1.

Los ingredientes del poder

El modelo

Tratamiento binario y resultado continuo, como las horas de sueño en Bessone et al. (2021).

$$Y_{iT} = \alpha_i + X_i\beta + \bar{\tau}D + \tau_i D + \varepsilon_i$$

α_i es un efecto individual no observado. τ_i es cuánto se aparta el efecto de cada persona del promedio $\bar{\tau}$, con $\mathbb{E}(\tau_i) = 0$. Con efectos heterogéneos, los tratados tienen un componente de varianza más (τ_i) que los controles. ε_i es un error i.i.d.

Con asignación aleatoria, la diferencia de medias estima $\bar{\tau}$ sin sesgo. Su varianza es

$$\text{var}(\hat{\tau}) = \frac{\text{var}(\varepsilon)}{N \cdot \text{var}(D)} \tag{1}$$

Varianza del ATE

$$\text{var}(\hat{\tau}) = \frac{\text{var}(\varepsilon)}{N \cdot \text{var}(D)} \tag{1}$$

- Es creciente en la varianza del componente no observado ($\text{var}(\varepsilon)$) y decreciente en el número de unidades (N) y la varianza del tratamiento ($\text{var}(\varepsilon)$).
- Con un tratamiento binario, $\text{var}(D) = p(1-p)$. Es máxima con la mitad de la muestra tratada.
- En Bessone et al. (2021), con la misma cantidad de tratamientos, un rango más amplio de pagos por dormir da más poder.

Varianza del ATE

$$\text{var}(\hat{\tau}) = \frac{\text{var}(\varepsilon)}{N \cdot \text{var}(D)} \tag{1}$$

- Es creciente en la varianza del componente no observado ($\text{var}(\varepsilon)$) y decreciente en el número de unidades (N) y la varianza del tratamiento ($\text{var}(\varepsilon)$).
- Con un tratamiento binario, $\text{var}(D) = p(1-p)$. Es máxima con la mitad de la muestra tratada.
- En Bessone et al. (2021), con la misma cantidad de tratamientos, un rango más amplio de pagos por dormir da más poder.

Minimum Detectable Effect

- Antes de correr el experimento, tenemos que formar creencias acerca de la varianza de los resultados. Puede venir de la teoría, de evidencia previa o de un piloto.
- Además, antes de gastar plata y tiempo en cualquier estudio, tenemos que determinar cuál es **la mínima diferencia de medias entre los resultados de control y tratamiento que el exprimento podrá detectar para un nivel de significatividad y un poder dados.** Esto es el minimum detectable effect.
  - Si $Y_{i0} \mid X_i \sim N(\mu_0, \sigma_0^2)$ e $Y_{i1} \mid X_i \sim N(\mu_1, \sigma_1^2)$, $MDE = \mu_1 - \mu_0$

Minimum Detectable Effect

- Antes de correr el experimento, tenemos que formar creencias acerca de la varianza de los resultados. Puede venir de la teoría, de evidencia previa o de un piloto.
- Además, antes de gastar plata y tiempo en cualquier estudio, tenemos que determinar cuál es **la mínima diferencia de medias entre los resultados de control y tratamiento que el exprimento podrá detectar para un nivel de significatividad y un poder dados.** Esto es el minimum detectable effect.
  - Si $Y_{i0} \mid X_i \sim N(\mu_0, \sigma_0^2)$ e $Y_{i1} \mid X_i \sim N(\mu_1, \sigma_1^2)$, $MDE = \mu_1 - \mu_0$
- Como el experimento todavía no se hizo, tenemos que mirar la literatura y preguntarnos qué efecto sería económicamente relevante.
- En Bessone et al. (2021), si el resultado clave fuera la productividad, el MDE podría ser el efecto de algún programa de información anteriror o un año extra de educación.

Tamaño óptimo de la muestra

Para calcular el tamaño de muestra óptimo, necesitamos especificar las hipótesis.

Queremos testear $H_0 : \mu_1 = \mu_0$ contra $H_1 : \mu_1 \neq \mu_0$.

Si las observaciones de tratamiento y control son independientes, la diferencia de medias, que aún no observamos, debe satisfacer dos condiciones.

Condición 1

Bajo H_0, la diferencia de medias (todavía no observada) supera el valor crítico con probabilidad α en un test a dos colas.

$$\frac{\bar{Y}_1 - \bar{Y}_0}{\sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}}} = t_{\alpha/2} \quad \Longrightarrow \quad \bar{Y}_1 - \bar{Y}_0 = t_{\alpha/2}\sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}} \tag{2}$$

n_T y σ_T^2 son el tamaño de muestra y la varianza condicional del resultado del grupo $T \in \{0, 1\}$.

Condición 2

Si el efecto verdadero es igual al MDE, queremos que la diferencia de medias caiga por encima de ese mismo valor crítico con probabilidad $1 - \beta$.

$$\frac{\bar{Y}_1 - \bar{Y}_0 - MDE}{\sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}}} = -t_\beta \quad \Longrightarrow \quad \bar{Y}_1 - \bar{Y}_0 = MDE - t_\beta \sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}} \tag{3}$$

El efecto mínimo detectable

Las dos condiciones describen el mismo valor crítico. Llamemos $S = \sqrt{\sigma_0^2/n_0 + \sigma_1^2/n_1}$ e igualemos los lados derechos de (2) y (3).

$$
\begin{aligned}
t_{\alpha/2}\, S &= MDE - t_{\beta}\, S \\
MDE &= t_{\alpha/2}\, S + t_{\beta}\, S \\
MDE &= (t_{\alpha/2} + t_{\beta}) \sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}} \qquad (4)
\end{aligned}
$$

El efecto mínimo detectable

Las dos condiciones describen el mismo valor crítico. Llamemos $S = \sqrt{\sigma_0^2/n_0 + \sigma_1^2/n_1}$ e igualemos los lados derechos de (2) y (3).

$$
\begin{aligned}
t_{\alpha/2}\, S &= MDE - t_\beta\, S \\
MDE &= t_{\alpha/2}\, S + t_\beta\, S \\
MDE &= (t_{\alpha/2} + t_\beta)\sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}} \qquad (4)
\end{aligned}
$$

Es el menor valor de $|\bar{\tau}| > 0$ para el cual el experimento rechaza la hipótesis nula con probabilidad $1 - \beta$ al nivel de significatividad α.

Con varianzas iguales

Supongamos $\sigma_1^2 = \sigma_0^2 = \sigma^2$. Sea $N = n_0 + n_1$, $P = n_1/N$ la proporción tratada y $1 - P = n_0/N$.

$$\begin{aligned}\frac{\sigma^2}{n_0} + \frac{\sigma^2}{n_1} &= \frac{\sigma^2}{(1-P)N} + \frac{\sigma^2}{PN} \\ &= \frac{\sigma^2}{N}\left[\frac{P + (1-P)}{P(1-P)}\right] \\ &= \frac{1}{P(1-P)}\frac{\sigma^2}{N}\end{aligned}$$

$$MDE = (t_{\alpha/2} + t_\beta)\sqrt{\frac{1}{P(1-P)}\frac{\sigma^2}{N}} \tag{5}$$

El término $\frac{1}{P(1-P)}\frac{\sigma^2}{N}$ es la varianza exacta del estimador, $\text{var}(\hat{\tau})$.

Tamaño de muestra óptimo

$P(1-P)$ es máximo en $P = 1/2$, donde vale $1/4$. Reemplazamos en (5) y despejamos N.

$$MDE = (t_{\alpha/2} + t_{\beta})\sqrt{\frac{4\sigma^2}{N}}$$

$$MDE^2 = (t_{\alpha/2} + t_{\beta})^2 \frac{4\sigma^2}{N}$$

$$N = 4(t_{\alpha/2} + t_{\beta})^2 \left(\frac{\sigma}{MDE}\right)^2$$

Con $n_0 = n_1 = N/2$,

$$n_0^* = n_1^* = n^* = 2(t_{\alpha/2} + t_{\beta})^2 \left(\frac{\sigma}{MDE}\right)^2 \tag{6}$$

Con varianzas distintas. ¿Cómo repartir la muestra?

Sea $\pi_T = n_T/N$ la proporción de la muestra en el grupo T. Con N fijo, minimizar el MDE de (4) es minimizar el término de la raíz.

$$\min_{n_0,n_1} \frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1} \quad \text{s.a.} \quad n_0 + n_1 = N$$

Con varianzas distintas. ¿Cómo repartir la muestra?

Sea $\pi_T = n_T/N$ la proporción de la muestra en el grupo T. Con N fijo, minimizar el MDE de (4) es minimizar el término de la raíz.

$$\min_{n_0,n_1} \frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1} \quad \text{s.a.} \quad n_0 + n_1 = N$$

CPOs,

$$\frac{\sigma_0^2}{n_0^2} = \lambda, \qquad \frac{\sigma_1^2}{n_1^2} = \lambda$$

$$\implies \quad \frac{n_1}{n_0} = \frac{\sigma_1}{\sigma_0} \quad \implies \quad \pi_0^* = \frac{\sigma_0}{\sigma_0 + \sigma_1}, \qquad \pi_1^* = \frac{\sigma_1}{\sigma_0 + \sigma_1}$$

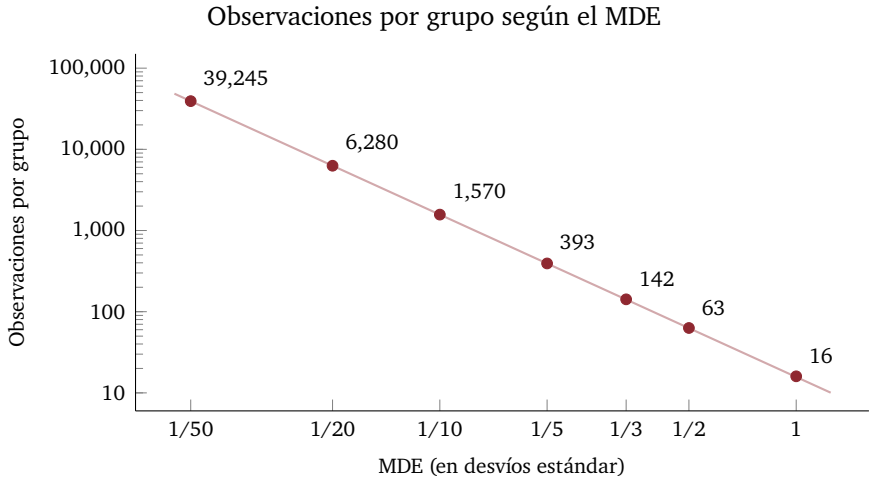
Con varianzas distintas

Reemplazando $n_T = \pi_T^* N$ en (4) y despejando N, igual que antes,

$$N^* = \left(\frac{t_{\alpha/2} + t_\beta}{MDE} \right)^2 \left(\frac{\sigma_0^2}{\pi_0^*} + \frac{\sigma_1^2}{\pi_1^*} \right) \tag{7}$$

Cada grupo recibe $n_0^* = \pi_0^* N^*$ y $n_1^* = \pi_1^* N^*$.

- La proporción de la muestra en cada grupo es proporcional al desvío estándar de su resultado.
- Si las muestras son grandes, la normal aproxima bien a la t y estas son soluciones cerradas.



$\alpha = 0.05$, poder 0.8 y varianzas iguales. Ambos ejes en escala logarítmica.
Fuente: List (2026), Exhibit 5.3.

Bessone et al. (2021)

- Nos concentramos en un solo contraste. El efecto del pago por dormir sobre las horas de sueño nocturno.
- En el grupo de control, el tiempo dormido promedio es 5.61 horas, con un desvío de 1.2.
- Con $\alpha = 0.05$ y poder 0.8, sólo falta elegir el MDE. O podemos hacer la cuenta al revés. Con 150 unidades en tratamiento y 150 en control, ¿qué efecto podemos detectar?

Bessone et al. (2021)

- Nos concentramos en un solo contraste. El efecto del pago por dormir sobre las horas de sueño nocturno.
- En el grupo de control, el tiempo dormido promedio es 5.61 horas, con un desvío de 1.2.
- Con $\alpha = 0.05$ y poder 0.8, sólo falta elegir el MDE. O podemos hacer la cuenta al revés. Con 150 unidades en tratamiento y 150 en control, ¿qué efecto podemos detectar?

$$\begin{aligned} MDE &= (1.96 + 0.84)\sqrt{\frac{1.2^2}{150} + \frac{1.2^2}{150}} \\ &= 2.8 \times 0.139 \approx 0.39 \text{ horas} \end{aligned}$$

Bessone et al. (2021)

- Nos concentramos en un solo contraste. El efecto del pago por dormir sobre las horas de sueño nocturno.
- En el grupo de control, el tiempo dormido promedio es 5.61 horas, con un desvío de 1.2.
- Con $\alpha = 0.05$ y poder 0.8, sólo falta elegir el MDE. O podemos hacer la cuenta al revés. Con 150 unidades en tratamiento y 150 en control, ¿qué efecto podemos detectar?

$$\begin{aligned} MDE &= (1.96 + 0.84)\sqrt{\frac{1.2^2}{150} + \frac{1.2^2}{150}} \\ &= 2.8 \times 0.139 \approx 0.39 \text{ horas} \end{aligned}$$

Es un aumento de unos 23 minutos de sueño por noche.

Choice & Consequence. List (2001)

- Experimento de campo en una feria de figuritas deportivas (*sportscards*). Subastas de Vickrey, de segundo precio.
- Entre los asistentes que no son comerciantes, compara ofertas hipotéticas con ofertas reales.
- La literatura ya sugería que las valuaciones hipotéticas tienen más varianza que las reales.

Choice & Consequence. List (2001)

- Experimento de campo en una feria de figuritas deportivas (*sportscards*). Subastas de Vickrey, de segundo precio.
- Entre los asistentes que no son comerciantes, compara ofertas hipotéticas con ofertas reales.
- La literatura ya sugería que las valuaciones hipotéticas tienen más varianza que las reales.
- List puso aproximadamente la misma cantidad de personas en cada grupo. El desvío de las ofertas hipotéticas resultó casi el doble que el de las reales.
- Con $N = 175$, el diseño óptimo según (7) era $n_H = 111$ y $n_A = 64$.
- El diseño uniforme baja el poder (para el efecto observado) de 69% a 66%. Y aun el diseño óptimo queda por debajo del 80% convencional.

¿Cuánto cuesta repartir mitad y mitad?

Con mitad y mitad, $n_0 = n_1 = N/2$,

$$\text{var}(\hat{\tau}) = \frac{\sigma_0^2}{N/2} + \frac{\sigma_1^2}{N/2} = \frac{2(\sigma_0^2 + \sigma_1^2)}{N}$$

Con el reparto óptimo, $n_T = N\sigma_T/(\sigma_0 + \sigma_1)$,

$$\text{var}(\hat{\tau}) = \frac{\sigma_0(\sigma_0 + \sigma_1)}{N} + \frac{\sigma_1(\sigma_0 + \sigma_1)}{N} = \frac{(\sigma_0 + \sigma_1)^2}{N}$$

Para lograr la misma varianza, con $r = \sigma_1/\sigma_0$,

$$\frac{N_{\text{mitad y mitad}}}{N_{\text{óptimo}}} = \frac{2(\sigma_0^2 + \sigma_1^2)}{(\sigma_0 + \sigma_1)^2} = \frac{2(1 + r^2)}{(1 + r)^2}$$

$r = \sigma_1/\sigma_0$	2	3	4	5
Muestra adicional con mitad y mitad	11%	25%	36%	44%
MDE más alto con la misma muestra	5%	12%	17%	20%

La fórmula derivada para resultados continuos cuando se aleatoriza entre los individuos puede ser adaptada para otros diseños experimentales.

Resultados binarios

La varianza depende de la media

- Con un resultado binario, usando la aproximación normal a la binomial, la varianza es $p(1-p)$, donde p es la media del resultado.
- Bajo $H_0 : p_0 = p_1$, los dos grupos tienen la misma media y por lo tanto la misma varianza. La usamos en (2),

$$\bar{Y}_1 - \bar{Y}_0 = t_{\alpha/2}\sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}} \tag{2}$$

- Bajo $H_1 : p_0 \neq p_1$, las medias son distintas y las varianzas también. Las usamos en (3),

$$\bar{Y}_1 - \bar{Y}_0 = MDE - t_{\beta}\sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}} \tag{3}$$

La varianza depende de la media

- Con un resultado binario, usando la aproximación normal a la binomial, la varianza es $p(1-p)$, donde p es la media del resultado.
- Bajo $H_0 : p_0 = p_1$, los dos grupos tienen la misma media y por lo tanto la misma varianza. La usamos en (2),

$$\bar{Y}_1 - \bar{Y}_0 = t_{\alpha/2}\sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}} \tag{2}$$

- Bajo $H_1 : p_0 \neq p_1$, las medias son distintas y las varianzas también. Las usamos en (3),

$$\bar{Y}_1 - \bar{Y}_0 = MDE - t_{\beta}\sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}} \tag{3}$$

$$n_0^* = n_1^* = n^* = \left(t_{\alpha/2}\sqrt{2\bar{p}(1-\bar{p})} + t_{\beta}\sqrt{p_0(1-p_0) + p_1(1-p_1)}\right)^2 MDE^{-2} \tag{8}$$

donde $\bar{p} = (p_0 + p_1)/2$.

Consecuencias

- A diferencia del caso continuo, con resultados binarios la media y la varianza se mueven juntas. Si cambia la media, cambia la varianza.
- $p(1-p)$ es máxima en $p = 0.5$. La muestra necesaria crece cuando $\bar{p}$ se acerca a 0.5.

Con $H_0 : p_1 = kp_0$

Si la hipótesis nula es $H_0 : p_1 = kp_0$ con $k > 0$, el reparto sigue la misma regla que (7),

$$\Longrightarrow \quad N^* = \left(\frac{t_{\alpha/2} + t_\beta}{MDE} \right)^2 \left(\frac{p_0(1-p_0)}{\pi_0^*} + \frac{kp_0(1-kp_0)}{\pi_1^*} \right)$$

con

$$\pi_0^* = \frac{\sqrt{1-p_0}}{\sqrt{1-p_0} + \sqrt{k(1-kp_0)}}, \qquad \pi_1^* = \frac{\sqrt{k(1-kp_0)}}{\sqrt{1-p_0} + \sqrt{k(1-kp_0)}}.$$

Cuanto más cerca de 0.5 esté p_1 en relación con p_0, más muestra va al grupo tratado.

Holladay et al. (2019)

La empresa quería poder detectar un aumento en la tasa mensual de auditorías de 0.1% (la tasa base) a 0.2%. Entonces $p_0 = 0.001$, $p_1 = 0.002$, $\bar{p} = 0.0015$ y $MDE = 0.001$.

Holladay et al. (2019)

La empresa quería poder detectar un aumento en la tasa mensual de auditorías de 0.1% (la tasa base) a 0.2%. Entonces $p_0 = 0.001$, $p_1 = 0.002$, $\bar{p} = 0.0015$ y $MDE = 0.001$.

$$t_{\alpha/2}\sqrt{2\bar{p}(1-\bar{p})} = 1.96\sqrt{2 \times 0.0015 \times 0.9985} \approx 0.1073$$

$$t_{\beta}\sqrt{p_0(1-p_0) + p_1(1-p_1)} = 0.84\sqrt{0.001 \times 0.999 + 0.002 \times 0.998} \approx 0.0460$$

$$n^* \approx \frac{(0.1073 + 0.0460)^2}{0.001^2} \approx 23{,}500 \text{ por grupo}$$

Holladay et al. (2019)

La empresa quería poder detectar un aumento en la tasa mensual de auditorías de 0.1% (la tasa base) a 0.2%. Entonces $p_0 = 0.001$, $p_1 = 0.002$, $\bar{p} = 0.0015$ y $MDE = 0.001$.

$$t_{\alpha/2}\sqrt{2\bar{p}(1-\bar{p})} = 1.96\sqrt{2 \times 0.0015 \times 0.9985} \approx 0.1073$$

$$t_{\beta}\sqrt{p_0(1-p_0) + p_1(1-p_1)} = 0.84\sqrt{0.001 \times 0.999 + 0.002 \times 0.998} \approx 0.0460$$

$$n^* \approx \frac{(0.1073 + 0.0460)^2}{0.001^2} \approx 23{,}500 \text{ por grupo}$$

Un piloto mostró una tasa base de la mitad de la que informaba la empresa. Además, el grupo de control casi no costaba. Los autores duplicaron el tamaño de los grupos, en línea con detectar un aumento de 0.05% a 0.1%.

Intensidad del tratamiento

Tratamientos con varios niveles

- Muchas veces el tratamiento toma más de dos valores. En medicina, la dosis. En economía, un precio, la cantidad de avisos o un subsidio.
- Así como podríamos estar interesados en efectos heterogeneos para tratar a las personas que responden más fuertemente, nos puede interesar evaluar en qué tramo de un tratamiento continúo se genera más impacto.

Tratamientos con varios niveles

- Muchas veces el tratamiento toma más de dos valores. En medicina, la dosis. En economía, un precio, la cantidad de avisos o un subsidio.
- Así como podríamos estar interesados en efectos heterogeneos para tratar a las personas que responden más fuertemente, nos puede interesar evaluar en qué tramo de un tratamiento continúo se genera más impacto.
- Ejemplo. Lyft o Uber quiere saber cómo responde la cantidad demandada al precio en una ruta. Varía el precio entre 10 y 12 dólares, de a 50 centavos.

$$Y_i = X_i\beta + \bar{\tau}D_i + \varepsilon_i, \qquad D_i \in [0, \bar{D}]$$

Tratamientos con varios niveles

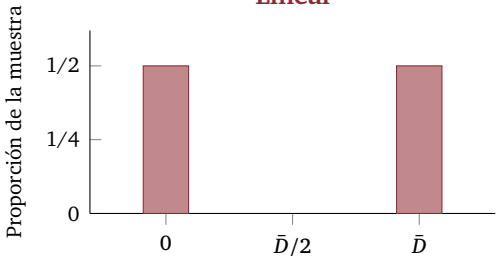
- Muchas veces el tratamiento toma más de dos valores. En medicina, la dosis. En economía, un precio, la cantidad de avisos o un subsidio.
- Así como podríamos estar interesados en efectos heterogeneos para tratar a las personas que responden más fuertemente, nos puede interesar evaluar en qué tramo de un tratamiento continúo se genera más impacto.
- Ejemplo. Lyft o Uber quiere saber cómo responde la cantidad demandada al precio en una ruta. Varía el precio entre 10 y 12 dólares, de a 50 centavos.

$$Y_i = X_i\beta + \bar{\tau}D_i + \varepsilon_i, \qquad D_i \in [0, \bar{D}]$$

¿Cómo cambia este problema nuestras posibilidades para maximizar la precisión, i.e. $\min \text{var}(\hat{\tau}) = \frac{\text{var}(\varepsilon)}{N \cdot \text{var}(D)}$?

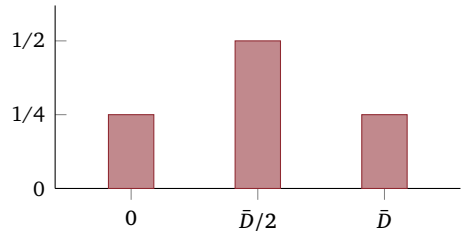
Efecto lineal y efecto cuadrático

Lineal



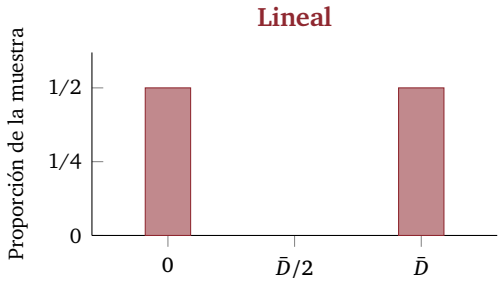
La mitad de la muestra en cada extremo maximiza var(D). El tamaño total sale de (6).

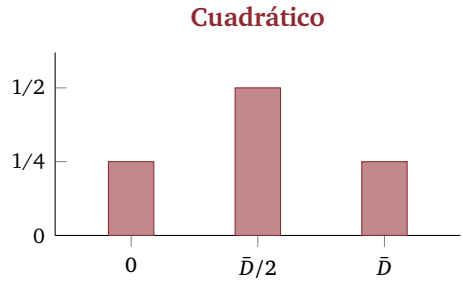
Cuadrático



Con todo en los extremos no se ve la curvatura. El test compara la media en los extremos con la media en el punto medio. Por eso la mitad va al medio.

Efecto lineal y efecto cuadrático





La mitad de la muestra en cada extremo maximiza var(D). El tamaño total sale de (6).

Con todo en los extremos no se ve la curvatura. El test compara la media en los extremos con la media en el punto medio. Por eso la mitad va al medio.

En general, la cantidad de celdas de tratamiento tiene que ser el mayor orden del polinomio más uno.

Exhibit 5.4: Simple Rules of Thumb for Sample Size for Polynomial Outcome Models

Highest and Only Polynomial Order	Number of Treatment Cells	Sample Allocation
1	2	$\left\{\frac{1}{2}, \frac{1}{2}\right\}$
2	3	$\left\{\frac{1}{4}, \frac{1}{2}, \frac{1}{4}\right\}$
3	4	$\left\{\frac{1}{6}, \frac{1}{3}, \frac{1}{3}, \frac{1}{6}\right\}$
⋮	⋮	⋮
10	11	$\left\{\frac{1}{20}, \frac{1}{10}, \cdots, \frac{1}{10}, \frac{1}{20}\right\}$

The table reports the optimal sample allocations for various powers of polynomial responses. Generally, the number of treatment cells is equal to the highest polynomial order plus one. The sample allocation for a quadratic relationship, for example, has three treatment cells: two cells at the extremes and one cell at the midpoint. If multiple effects are included, then the experimenter must take the weighted average of the optimal allocations for each effect.

Fuente: List (2026), Exhibit 5.4.

Tratamientos sin orden

- Si los niveles del tratamiento son ordinales o no tienen orden, lo central es decidir qué comparaciones nos interesan.
- Supongamos tres escenarios $\{A, B, C\}$. A es la línea de base. Sólo nos interesan las comparaciones de A con B y de A con C.

Tratamientos sin orden

- Si los niveles del tratamiento son ordinales o no tienen orden, lo central es decidir qué comparaciones nos interesan.
- Supongamos tres escenarios $\{A, B, C\}$. A es la línea de base. Sólo nos interesan las comparaciones de A con B y de A con C.
- A participa de las dos comparaciones. El reparto óptimo le da más peso,

$$\left\{\frac{1}{2}, \frac{1}{4}, \frac{1}{4}\right\}$$

Tratamientos sin orden

- Si los niveles del tratamiento son ordinales o no tienen orden, lo central es decidir qué comparaciones nos interesan.
- Supongamos tres escenarios $\{A, B, C\}$. A es la línea de base. Sólo nos interesan las comparaciones de A con B y de A con C.
- A participa de las dos comparaciones. El reparto óptimo le da más peso,

$$\left\{\frac{1}{2}, \frac{1}{4}, \frac{1}{4}\right\}$$

- Si queremos un efecto lineal y uno cuadrático a la vez, el problema se complica bastante. En ese caso, podríamos hacer un promedio ponderado de los dos repartos óptimos.

Choice & Consequence. Karlan y List (2007)

- Piden donaciones a más de 50,000 simpatizantes de una organización sin fines de lucro.
- ¿Un fondo que iguala las donaciones (*matching*) aumenta lo que se dona? ¿Importa la tasa de matching?
- Tres celdas de tratamiento con tasas 1:1, 2:1 y 3:1. Con 1:1, si alguien dona 100 dólares la organización recibe 200.

Supongamos costos iguales en todas las celdas, $\alpha = 0.05$ y poder 0.8. Si sólo nos interesa un efecto lineal de la tasa de matching, ¿hacía falta la celda 2:1?

¿Cuánto se pierde?

Sea $D \in \{1, 2, 3\}$ la tasa de matching.

- **Tres celdas iguales:** la media es 2 y $\text{var}(D) = \frac{1}{3}(1 + 0 + 1) = \frac{2}{3}$.
- **Dos celdas en los extremos:** $\text{var}(D) = \frac{1}{2}(1) + \frac{1}{2}(1) = 1$.

Como $\text{var}(\hat{\tau}) \propto 1/\text{var}(D)$,

$$\frac{MDE_3}{MDE_2} = \sqrt{\frac{1}{2/3}} \approx 1.22, \qquad \frac{N_3}{N_2} = 1.5$$

- El MDE es 22% más alto con la misma muestra. Para el mismo MDE, hace falta 50% más de muestra.
- Si hubieran repartido para un efecto cuadrático $\{\frac{1}{4}, \frac{1}{2}, \frac{1}{4}\}$ y el efecto fuera lineal, $\text{var}(D) = \frac{1}{2}$ y el MDE sería $\sqrt{2} \approx 1.41$ veces el óptimo.

Tratamientos con costos diferentes

Costos distintos por grupo

- Hasta ahora asumimos que generar un dato cuesta lo mismo en tratamiento y en control.
- Pero esto casi nunca es la realidad.
- Sea c_0 el costo de una observación de control y c_1 el de una tratada. El costo total del experimento es

$$M = c_0 n_0 + c_1 n_1$$

Costos distintos por grupo

- Hasta ahora asumimos que generar un dato cuesta lo mismo en tratamiento y en control.
- Pero esto casi nunca es la realidad.
- Sea c_0 el costo de una observación de control y c_1 el de una tratada. El costo total del experimento es

$$M = c_0 n_0 + c_1 n_1$$

- Buscamos los n_0 y n_1 que minimizan el MDE de (4) sujeto al presupuesto.

Derivación

Minimizar el MDE es lo mismo que minimizar el término dentro de la raíz.

$$\min_{n_0,n_1} \frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1} \quad \text{s.a} \quad c_0 n_0 + c_1 n_1 = M$$

CPOs,

$$\frac{\sigma_0^2}{n_0^2} = \lambda c_0, \qquad \frac{\sigma_1^2}{n_1^2} = \lambda c_1$$

$$\frac{n_1^*}{n_0^*} = \frac{\pi_1^*}{\pi_0^*} = \sqrt{\frac{c_0}{c_1}}\frac{\sigma_1}{\sigma_0}$$

Exhibit 5.5: Simple Rules of Thumb for Sample Size for Treatments with Unequal Costs

Cost of Treatment (c_1) versus Control Cost (c_0)	Cost-Based Sampling Weights
$c_1 = 1.1c_0$	$n_1^*/n_0^* = \sqrt{10/11}$
$c_1 = 1.5c_0$	$n_1^*/n_0^* = \sqrt{2/3}$
$c_1 = 2c_0$	$n_1^*/n_0^* = \sqrt{1/2}$
$c_1 = 4c_0$	$n_1^*/n_0^* = 1/2$

The table reports the relationship between the cost of a treatment observation versus the cost of a control observation and its corresponding optimal sample size. For example, when the cost of the treatment observation is four times the cost of the control observation ($4c_0$), then the optimal sample size is 1/2 as many treated units as control units because the optimal sample size is inversely proportional to the square root of the relative sampling cost. These values are determined under the assumption of equal standard deviations.

Fuente: List (2026), Exhibit 5.5.

Ejemplos tienen costos inciertos

- **Holladay et al. (2019):** subsidios para que los hogares tratados hagan la auditoría.
- **Bessone et al. (2021):** un pago por cada hora de sueño nocturno por encima del nivel inicial, con un tope por persona.

La diferencia exacta de costos es incierta en ambos. Lo que se paga depende de cuánto respondan los participantes. Por eso importan los pilotos y la evidencia previa.

Diseños por clusters

Cuando se trata a un grupo entero

- Hasta ahora, la unidad de observación coincidía con la unidad de aleatorización.
- Muchas veces el tratamiento es grupal. Hay que tratar una empresa, un pueblo, un mercado o un aula.
- Ejemplo. Un experimento sobre el tamaño de la clase. Todos los alumnos de un aula comparten el tratamiento por construcción.
- Puede ser que sea necesario hacer el diseño de esta forma para que se cumplan las restricciones de exclusión.
- También aparece por restricciones prácticas, éticas o legales.

Cuando se trata a un grupo entero

- Hasta ahora, la unidad de observación coincidía con la unidad de aleatorización.
- Muchas veces el tratamiento es grupal. Hay que tratar una empresa, un pueblo, un mercado o un aula.
- Ejemplo. Un experimento sobre el tamaño de la clase. Todos los alumnos de un aula comparten el tratamiento por construcción.
- Puede ser que sea necesario hacer el diseño de esta forma para que se cumplan las restricciones de exclusión.
- También aparece por restricciones prácticas, éticas o legales.
- En un experimento aleatorizado por clusters, el cluster g es la unidad a la que se le asigna el tratamiento y agrupa N_g unidades observadas.

$$Y_{i,g} = Y_{i,g}(1)D_g + Y_{i,g}(0)(1 - D_g)$$

¿Qué efecto queremos estimar?

Si el cluster es la unidad de interés, cada cluster pesa lo mismo.

$$\theta_1 = \mathbb{E}\left[\frac{1}{N_g}\sum_{i=1}^{N_g} Y_{i,g}(1) - Y_{i,g}(0)\right]$$

Si nos sigue interesando el ATE a nivel individual, pesamos cada cluster por su tamaño.

$$\theta_2 = \mathbb{E}\left[\frac{1}{\mathbb{E}[N_g]}\sum_{i=1}^{N_g} Y_{i,g}(1) - Y_{i,g}(0)\right]$$

Si todos los clusters tienen el mismo tamaño, los dos parámetros coinciden.

Cada unidad pertenece a un cluster g. Para $T \in \{0, 1\}$,

$$Y_{igT} = \alpha + \bar{\tau} D_g + \nu_g + \varepsilon_{ig}$$

- ε_{ig} es un error individual i.i.d. y ν_g es un error del cluster i.i.d.
- Dejamos de lado X_i, α_i y τ_i para simplificar.
- Cada cluster tiene m unidades, en tratamiento y en control.

Cada unidad pertenece a un cluster g. Para $T \in \{0, 1\}$,

$$Y_{igT} = \alpha + \bar{\tau} D_g + \nu_g + \varepsilon_{ig}$$

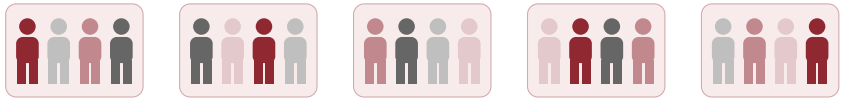
- ε_{ig} es un error individual i.i.d. y ν_g es un error del cluster i.i.d.
- Dejamos de lado X_i, α_i y τ_i para simplificar.
- Cada cluster tiene m unidades, en tratamiento y en control.
- El coeficiente de correlación intra-cluster es

$$\rho = \frac{\text{var}(\nu_g)}{\text{var}(\nu_g) + \text{var}(\varepsilon_{ig})}$$

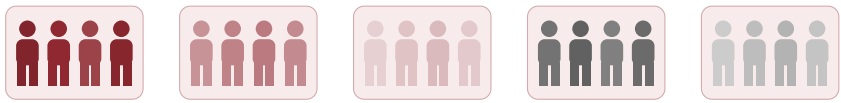
$\rho \approx 0$



$\rho \approx 0$



$\rho \approx 1$



Tamaño de muestra con clusters

Con costos y varianzas iguales en tratamiento y control,

$$n_0^* = n_1^* = n^* = 2(t_{\alpha/2} + t_\beta)^2 \left(\frac{\sigma}{MDE}\right)^2 \left(1 + (m-1)\rho\right) \tag{9}$$

con $k = n/m$ clusters y $2(k-1)$ grados de libertad.

- Es (6) multiplicada por el factor de inflación de la varianza, $1 + (m-1)\rho$.
  Derivación en el apéndice
- La muestra total crece casi proporcionalmente con el tamaño de cada cluster y con ρ.

Tamaño óptimo de cluster

- El costo total de generar los datos en un diseño clusterizado es $2(c_m m + c_k)k = M$. Donde c_m es el costo de cada sujeto y c_k es el costo fijo de cada cluster.
- Minimizando el MDE de (9) sujeto a ese presupuesto nos da el tamaño óptimo por cluster,

$$m^* = \sqrt{\frac{1-\rho}{\rho}}\sqrt{\frac{c_k}{c_m}} \tag{10}$$

Exhibit 5.6: Simple Rules of Thumb for Sample Size for Clustered Units

ρ	m	n^*	k^*
0	10	$62.79 \approx 63$	$6.28 \approx 7$
	30	$62.79 \approx 63$	$2.09 \approx 3$
0.25	10	$204.07 \approx 205$	$20.4 \approx 21$
	30	$518.02 \approx 519$	$17.26 \approx 18$
0.5	10	$345.35 \approx 346$	$34.53 \approx 35$
	30	$973.26 \approx 974$	$32.44 \approx 33$
0.75	10	$486.63 \approx 487$	$48.66 \approx 49$
	30	$1428.50 \approx 1429$	$47.61 \approx 48$
1	10	$627.91 \approx 628$	$62.79 \approx 63$
	30	$1883.73 \approx 1884$	$62.79 \approx 63$

The table reports several intra-cluster correlation coefficient values (ρ) and the corresponding optimal number of units in each cluster (m), the optimal overall sample size (n), as well as the optimal number of clusters (k). The table demonstrates how the optimal number of clusters increases as the intra-cluster correlation coefficient increases.

Fuente: List (2026), Exhibit 5.6. MDE de 0.5 desvíos.

Los casos extremos

- $\rho = 0$: (9) es igual a (6) y n^* no cambia con m. Con 10 unidades por cluster hacen falta 7 clusters. Con 30, alcanzan 3.

Los casos extremos

- $\rho = 0$: (9) es igual a (6) y n^* no cambia con m. Con 10 unidades por cluster hacen falta 7 clusters. Con 30, alcanzan 3.
- $\rho = 1$: todas las unidades de un cluster responden igual. La muestra útil crece sólo con más clusters. Hacen falta 63 con cualquier m.

Los casos extremos

- $\rho = 0$**:** (9) es igual a (6) y n^* no cambia con m. Con 10 unidades por cluster hacen falta 7 clusters. Con 30, alcanzan 3.
- $\rho = 1$**:** todas las unidades de un cluster responden igual. La muestra útil crece sólo con más clusters. Hacen falta 63 con cualquier m.
- **¿De dónde sacamos** ρ**?** De un valor típico de la literatura. De experimentos publicados con datos disponibles. De datos observacionales. De modelos.

Diseño óptimo con MHT

Diseño óptimo con MHT

- En la clase pasada corregimos por testeo múltiple al analizar los datos.
- Si no tenemos en cuenta esa corrección al diseñar, después de corregir nos vamos a quedar sin poder.
- Las familias de hipótesis aparecen por varios resultados, varios tratamientos o heterogeneidad.
- Así como la FWER generaliza el error tipo I a una familia de hipótesis, el poder por familia (*familywise power*, FWP) generaliza el poder. Es la probabilidad de rechazar correctamente todas las nulas falsas de la familia.

Diseño óptimo con MHT

Supongamos que medimos K resultados para cada persona, como en Bessone et al. (2021), y que los tests son independientes.

- La probabilidad de rechazar las dos nulas cuando ambas son verdaderas es el producto de las probabilidades de cada una.

Diseño óptimo con MHT

Supongamos que medimos K resultados para cada persona, como en Bessone et al. (2021), y que los tests son independientes.

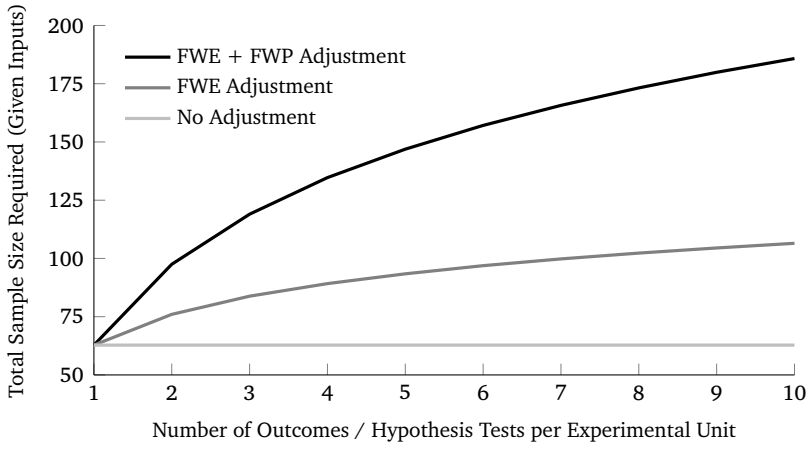
- La probabilidad de rechazar las dos nulas cuando ambas son verdaderas es el producto de las probabilidades de cada una.
- **Error tipo I:** dividimos el nivel de significatividad por la cantidad de tests, α/K.

Diseño óptimo con MHT

Supongamos que medimos K resultados para cada persona, como en Bessone et al. (2021), y que los tests son independientes.

- La probabilidad de rechazar las dos nulas cuando ambas son verdaderas es el producto de las probabilidades de cada una.
- **Error tipo I:** dividimos el nivel de significatividad por la cantidad de tests, α/K.
- **Poder:** para tener un poder por familia de $1-\beta$, cada test necesita un poder de $(1-\beta)^{1/K}$.

Exhibit 5.7: MHT and Statistical Power



MDE de 0.5 desvíos, $\alpha = 0.05$ y poder 0.8. Con un solo test reproduce los 63 del Exhibit 5.3.
Fuente: List (2026), Exhibit 5.7.

Opciones no tan consideradas para aumentar el poder

Opciones no tan consideradas para aumentar el poder

Covariables

Covariables en la estimación

- Con asignación aleatoria y efecto homogéneo, controlar por covariables previas al tratamiento que predicen el resultado mantiene el valor esperado del estimador de τ y puede reducir su varianza.
- En (1), las covariables bajan var(ε).
- En un programa educativo podrían ser la edad, el género, el lugar o el ingreso familiar.
- Para resultados que persisten en el tiempo, como las notas, la medición del resultado antes del tratamiento es especialmente útil.

La idea del ajuste por regresión

Por la aleatorización, $X \perp W$. Para cualquier función h, $\mathbb{E}[h(X) \mid W = w]$ no depende de w.

La idea del ajuste por regresión

Por la aleatorización, $X \perp W$. Para cualquier función h, $\mathbb{E}[h(X) \mid W = w]$ no depende de w.

$$\frac{1}{n_1}\sum_{i=1}^{n} W_i Y_i + \left\{ \frac{1}{n}\sum_{i=1}^{n} h(X_i) - \frac{1}{n_1}\sum_{i=1}^{n} W_i h(X_i) \right\}$$

La idea del ajuste por regresión

Por la aleatorización, $X \perp W$. Para cualquier función h, $\mathbb{E}[h(X) \mid W = w]$ no depende de w.

$$\frac{1}{n_1}\sum_{i=1}^{n} W_i Y_i + \left\{ \frac{1}{n}\sum_{i=1}^{n} h(X_i) - \frac{1}{n_1}\sum_{i=1}^{n} W_i h(X_i) \right\}$$

- El término entre llaves tiene media cero. Mide cuánto difiere el promedio de $h(X)$ entre los tratados y la muestra completa. Ese desbalance aparece sólo por azar.

La idea del ajuste por regresión

Por la aleatorización, $X \perp W$. Para cualquier función h, $\mathbb{E}[h(X) \mid W = w]$ no depende de w.

$$\frac{1}{n_1}\sum_{i=1}^{n} W_i Y_i + \left\{ \frac{1}{n}\sum_{i=1}^{n} h(X_i) - \frac{1}{n_1}\sum_{i=1}^{n} W_i h(X_i) \right\}$$

- El término entre llaves tiene media cero. Mide cuánto difiere el promedio de $h(X)$ entre los tratados y la muestra completa. Ese desbalance aparece sólo por azar.
- Sumarlo mantiene insesgada la estimación de $\bar{Y}^1$ y puede bajar su varianza.

La idea del ajuste por regresión

Por la aleatorización, $X \perp W$. Para cualquier función h, $\mathbb{E}[h(X) \mid W = w]$ no depende de w.

$$\frac{1}{n_1}\sum_{i=1}^{n} W_i Y_i + \left\{ \frac{1}{n}\sum_{i=1}^{n} h(X_i) - \frac{1}{n_1}\sum_{i=1}^{n} W_i h(X_i) \right\}$$

- El término entre llaves tiene media cero. Mide cuánto difiere el promedio de $h(X)$ entre los tratados y la muestra completa. Ese desbalance aparece sólo por azar.
- Sumarlo mantiene insesgada la estimación de $\bar{Y}^1$ y puede bajar su varianza.
- La mejor h es la esperanza condicional, $m(x) = \mathbb{E}[Y \mid W = 1, X = x]$. List, Muir y Sun (2022) la estiman con machine learning y separación de la muestra.

Covariables en el OHIE

- Usan el método de List, Muir y Sun (2022) con cuatro covariables. Género, edad, salud previa y educación.
- El resultado es si la persona visitó la guardia. También estiman el LATE de tener Medicaid.

Covariables en el OHIE

- Usan el método de List, Muir y Sun (2022) con cuatro covariables. Género, edad, salud previa y educación.
- El resultado es si la persona visitó la guardia. También estiman el LATE de tener Medicaid.
- Los errores estándar bajan alrededor de 1.5%.

Covariables en el OHIE

- Usan el método de List, Muir y Sun (2022) con cuatro covariables. Género, edad, salud previa y educación.
- El resultado es si la persona visitó la guardia. También estiman el LATE de tener Medicaid.
- Los errores estándar bajan alrededor de 1.5%.
- Es poco para una muestra dada. Pero para el mismo poder, la muestra podría ser 3% más chica, con el ahorro de costos correspondiente.

Covariables en el OHIE

- Usan el método de List, Muir y Sun (2022) con cuatro covariables. Género, edad, salud previa y educación.
- El resultado es si la persona visitó la guardia. También estiman el LATE de tener Medicaid.
- Los errores estándar bajan alrededor de 1.5%.
- Es poco para una muestra dada. Pero para el mismo poder, la muestra podría ser 3% más chica, con el ahorro de costos correspondiente.
- Con covariables más ricas, como el resultado medido antes del tratamiento, la ganancia sería mucho mayor.

¿Las covariables son gratis?

- Si las covariables no predicen el resultado, sólo consumen grados de libertad.
- Esto importa sólo en muestras chicas, donde perder unos pocos grados de libertad cambia la incertidumbre de la estimación.

¿Las covariables son gratis?

- Si las covariables no predicen el resultado, sólo consumen grados de libertad.
- Esto importa sólo en muestras chicas, donde perder unos pocos grados de libertad cambia la incertidumbre de la estimación.
- Regla práctica de los procedimientos del Green Lab. La cantidad de covariables no debería superar 1/20 del tamaño de la muestra.

¿Las covariables son gratis?

- Si las covariables no predicen el resultado, sólo consumen grados de libertad.
- Esto importa sólo en muestras chicas, donde perder unos pocos grados de libertad cambia la incertidumbre de la estimación.
- Regla práctica de los procedimientos del Green Lab. La cantidad de covariables no debería superar 1/20 del tamaño de la muestra.
- Si el efecto varía con las covariables (CATEs), hay que incluir interacciones del tratamiento con las covariables (Lin, 2013).

Carneiro, Lee y Wilhelm (2020)

- Con un presupuesto fijo, ¿conviene medir una covariable para todos o sumar unidades? Se igualan el beneficio marginal y el costo marginal.
- Usan datos de un piloto para aprender qué covariables predicen el resultado y un algoritmo *greedy* para elegirlas.

Carneiro, Lee y Wilhelm (2020)

- Con un presupuesto fijo, ¿conviene medir una covariable para todos o sumar unidades? Se igualan el beneficio marginal y el costo marginal.
- Usan datos de un piloto para aprender qué covariables predicen el resultado y un algoritmo *greedy* para elegirlas.
- Aplicación a subsidios escolares aleatorizados en Senegal (Carneiro et al., 2015). Hay más de 100 covariables previas, de escuelas, docentes y notas.



Escuela primaria en Senegal. Imagen ilustrativa. Foto: Shutterstock, vía J-PAL.

Carneiro, Lee y Wilhelm (2020)

- Con un presupuesto fijo, ¿conviene medir una covariable para todos o sumar unidades? Se igualan el beneficio marginal y el costo marginal.
- Usan datos de un piloto para aprender qué covariables predicen el resultado y un algoritmo *greedy* para elegirlas.
- Aplicación a subsidios escolares aleatorizados en Senegal (Carneiro et al., 2015). Hay más de 100 covariables previas, de escuelas, docentes y notas.
- Si de todos modos hay que medir la nota de base (por ejemplo, para mostrar balance), conviene gastar el resto del presupuesto en agrandar la muestra. La nota previa explica 25% de la varianza de la nota final.



Escuela primaria en Senegal. Imagen ilustrativa. Foto: Shutterstock, vía J-PAL.

Carneiro, Lee y Wilhelm (2020)

- Con un presupuesto fijo, ¿conviene medir una covariable para todos o sumar unidades? Se igualan el beneficio marginal y el costo marginal.
- Usan datos de un piloto para aprender qué covariables predicen el resultado y un algoritmo *greedy* para elegirlas.
- Aplicación a subsidios escolares aleatorizados en Senegal (Carneiro et al., 2015). Hay más de 100 covariables previas, de escuelas, docentes y notas.
- Si de todos modos hay que medir la nota de base (por ejemplo, para mostrar balance), conviene gastar el resto del presupuesto en agrandar la muestra. La nota previa explica 25% de la varianza de la nota final.
- Para el mismo tamaño de muestra, el presupuesto puede bajar del orden de 50%.



Escuela primaria en Senegal. Imagen ilustrativa. Foto: Shutterstock, vía J-PAL.

Opciones no tan consideradas para aumentar el poder

Cumplimiento

Diseñar para que se cumpla el tratamiento

- Si no todos los asignados reciben el tratamiento, lo que estimamos de forma directa es el efecto de la asignación (Z sobre Y). En general nos interesa el efecto del tratamiento (D sobre Y).

Diseñar para que se cumpla el tratamiento

- Si no todos los asignados reciben el tratamiento, lo que estimamos de forma directa es el efecto de la asignación (Z sobre Y). En general nos interesa el efecto del tratamiento (D sobre Y).
- **Programas con reuniones:** pagar por asistir, preguntar qué días y horarios les sirven, ofrecer cuidado de los hijos, mandar recordatorios, dejar los incentivos para el final.

Diseñar para que se cumpla el tratamiento

- Si no todos los asignados reciben el tratamiento, lo que estimamos de forma directa es el efecto de la asignación (Z sobre Y). En general nos interesa el efecto del tratamiento (D sobre Y).
- **Programas con reuniones:** pagar por asistir, preguntar qué días y horarios les sirven, ofrecer cuidado de los hijos, mandar recordatorios, dejar los incentivos para el final.
- **Tratamientos de información:** las cartas, mails y mensajes que nunca se abren no tratan a nadie. Ayuda el diseño del sobre. Las cartas de la autoridad tributaria se abren casi siempre.

Diseñar para que se cumpla el tratamiento

- Si no todos los asignados reciben el tratamiento, lo que estimamos de forma directa es el efecto de la asignación (Z sobre Y). En general nos interesa el efecto del tratamiento (D sobre Y).
- **Programas con reuniones:** pagar por asistir, preguntar qué días y horarios les sirven, ofrecer cuidado de los hijos, mandar recordatorios, dejar los incentivos para el final.
- **Tratamientos de información:** las cartas, mails y mensajes que nunca se abren no tratan a nadie. Ayuda el diseño del sobre. Las cartas de la autoridad tributaria se abren casi siempre.
- Incluso en el laboratorio, recibir el tratamiento puede requerir que la persona lo entienda e internalice.

¿Cuánto cuesta el incumplimiento?

- MailChimp encuentra que se abre poco más del 20% de los mails.
- Con efectos homogéneos y sin tratados en el grupo de control, el efecto de la asignación es

$$ITT = 0.2\,\tau$$

¿Cuánto cuesta el incumplimiento?

- MailChimp encuentra que se abre poco más del 20% de los mails.
- Con efectos homogéneos y sin tratados en el grupo de control, el efecto de la asignación es

$$ITT = 0.2\,\tau$$

Por (6), $n^* \propto 1/MDE^2$. Para detectar τ a través de un efecto de 0.2τ,

$$n^*_{ITT} = \frac{n^*}{0.2^2} = 25\,n^*$$

¿Cuánto cuesta el incumplimiento?

- MailChimp encuentra que se abre poco más del 20% de los mails.
- Con efectos homogéneos y sin tratados en el grupo de control, el efecto de la asignación es

$$ITT = 0.2\,\tau$$

Por (6), $n^* \propto 1/MDE^2$. Para detectar τ a través de un efecto de 0.2τ,

$$n^*_{ITT} = \frac{n^*}{0.2^2} = 25\,n^*$$

- Para un efecto de 0.5 desvíos, pasamos de 63 a unas 1,570 unidades por grupo.
- Lo mismo vale si estimamos el efecto de D con variables instrumentales. El estimador divide por 0.2 y su varianza se multiplica por 25.

Opciones no tan consideradas para aumentar el poder

La naturaleza de la muestra

Muestras homogéneas

- Si las unidades responden igual al tratamiento, la varianza de los residuos es chica.
- Por (1), una muestra más homogénea reduce la varianza del estimador y aumenta el poder.
- Un grupo de estudiantes universitarios, de edades y orígenes parecidos, es más homogéneo que una muestra al azar de la población de Estados Unidos o de usuarios de Google o Uber.

Muestras homogéneas

- Si las unidades responden igual al tratamiento, la varianza de los residuos es chica.
- Por (1), una muestra más homogénea reduce la varianza del estimador y aumenta el poder.
- Un grupo de estudiantes universitarios, de edades y orígenes parecidos, es más homogéneo que una muestra al azar de la población de Estados Unidos o de usuarios de Google o Uber.
- Hay un trade-off con la validez externa. Si los estudiantes son distintos de la población de interés, el experimento detecta efectos más chicos y puede decir poco sobre el parámetro que nos importa.

Opciones no tan consideradas para aumentar el poder

Medición

Error de medición

- **Aleatorio:** la estimación es menos precisa. Hace falta más muestra para el mismo poder y el mismo MDE.
- Aparece, por ejemplo, en encuestas retrospectivas donde las personas recuerdan mal. Ayuda elegir instrumentos que dan el mismo resultado cuando se repiten (confiabilidad test-retest).

Error de medición

- **Aleatorio:** la estimación es menos precisa. Hace falta más muestra para el mismo poder y el mismo MDE.
- Aparece, por ejemplo, en encuestas retrospectivas donde las personas recuerdan mal. Ayuda elegir instrumentos que dan el mismo resultado cuando se repiten (confiabilidad test-retest).
- **Sistemático:** más preocupante, porque puede sesgar la estimación. ¿Un preescolar gratis aumenta la oferta laboral de los padres?
- Con datos administrativos de ingresos (seguridad social, seguro de desempleo), la medición tiene poco ruido.
- Con autorreporte, los padres tratados pueden decir que volvieron a trabajar por SDB o lo que sea. Esto puede estar relacionado con el resultado y sesgar las estimaciones.

Conclusión

Conclusión

- Diseñar es elegir cuántas unidades, cómo repartirlas, qué niveles de tratamiento usar, a qué nivel aleatorizar y qué medir, para tener el mayor poder posible con un presupuesto dado.

Conclusión

- Diseñar es elegir cuántas unidades, cómo repartirlas, qué niveles de tratamiento usar, a qué nivel aleatorizar y qué medir, para tener el mayor poder posible con un presupuesto dado.
- $\text{var}(\hat{\tau}) = \text{var}(\varepsilon)/(N \cdot \text{var}(D))$ resume tres palancas. Menos ruido, más muestra y más variación en el tratamiento.

Conclusión

- Diseñar es elegir cuántas unidades, cómo repartirlas, qué niveles de tratamiento usar, a qué nivel aleatorizar y qué medir, para tener el mayor poder posible con un presupuesto dado.
- $\text{var}(\hat{\tau}) = \text{var}(\varepsilon)/(N \cdot \text{var}(D))$ resume tres palancas. Menos ruido, más muestra y más variación en el tratamiento.
- $n^* = 2(t_{\alpha/2} + t_{\beta})^2(\sigma/MDE)^2$. La muestra crece con la varianza y cae con el cuadrado del MDE. Se reparte según los desvíos y según la raíz de los costos.

Conclusión

- Diseñar es elegir cuántas unidades, cómo repartirlas, qué niveles de tratamiento usar, a qué nivel aleatorizar y qué medir, para tener el mayor poder posible con un presupuesto dado.
- $\text{var}(\hat{\tau}) = \text{var}(\varepsilon)/(N \cdot \text{var}(D))$ resume tres palancas. Menos ruido, más muestra y más variación en el tratamiento.
- $n^* = 2(t_{\alpha/2} + t_{\beta})^2(\sigma/MDE)^2$. La muestra crece con la varianza y cae con el cuadrado del MDE. Se reparte según los desvíos y según la raíz de los costos.
- Con resultados binarios la varianza depende de la media. Con varios niveles, la muestra va a los extremos, y al medio si hay curvatura.

Conclusión

- Diseñar es elegir cuántas unidades, cómo repartirlas, qué niveles de tratamiento usar, a qué nivel aleatorizar y qué medir, para tener el mayor poder posible con un presupuesto dado.
- $\text{var}(\hat{\tau}) = \text{var}(\varepsilon)/(N \cdot \text{var}(D))$ resume tres palancas. Menos ruido, más muestra y más variación en el tratamiento.
- $n^* = 2(t_{\alpha/2} + t_{\beta})^2(\sigma/MDE)^2$. La muestra crece con la varianza y cae con el cuadrado del MDE. Se reparte según los desvíos y según la raíz de los costos.
- Con resultados binarios la varianza depende de la media. Con varios niveles, la muestra va a los extremos, y al medio si hay curvatura.
- Los clusters multiplican la muestra por $1 + (m - 1)\rho$. El tamaño óptimo del cluster no depende del presupuesto.

Conclusión

- Diseñar es elegir cuántas unidades, cómo repartirlas, qué niveles de tratamiento usar, a qué nivel aleatorizar y qué medir, para tener el mayor poder posible con un presupuesto dado.
- $\text{var}(\hat{\tau}) = \text{var}(\varepsilon)/(N \cdot \text{var}(D))$ resume tres palancas. Menos ruido, más muestra y más variación en el tratamiento.
- $n^* = 2(t_{\alpha/2} + t_{\beta})^2(\sigma/MDE)^2$. La muestra crece con la varianza y cae con el cuadrado del MDE. Se reparte según los desvíos y según la raíz de los costos.
- Con resultados binarios la varianza depende de la media. Con varios niveles, la muestra va a los extremos, y al medio si hay curvatura.
- Los clusters multiplican la muestra por $1 + (m - 1)\rho$. El tamaño óptimo del cluster no depende del presupuesto.
- El testeo múltiple, el incumplimiento y el error de medición aumentan la muestra necesaria. Las buenas covariables la reducen.

Preguntas que hay que hacerse

1. ¿Qué efecto mínimo quiero poder detectar? ¿Por qué ese? ¿Tengo presupuesto para detectarlo?

Preguntas que hay que hacerse

1. ¿Qué efecto mínimo quiero poder detectar? ¿Por qué ese? ¿Tengo presupuesto para detectarlo?
2. ¿Qué sé sobre la varianza del resultado en cada grupo? ¿De dónde lo saco?

Preguntas que hay que hacerse

1. ¿Qué efecto mínimo quiero poder detectar? ¿Por qué ese? ¿Tengo presupuesto para detectarlo?
2. ¿Qué sé sobre la varianza del resultado en cada grupo? ¿De dónde lo saco?
3. ¿Cuánto cuesta una observación tratada y una de control?

Preguntas que hay que hacerse

1. ¿Qué efecto mínimo quiero poder detectar? ¿Por qué ese? ¿Tengo presupuesto para detectarlo?
2. ¿Qué sé sobre la varianza del resultado en cada grupo? ¿De dónde lo saco?
3. ¿Cuánto cuesta una observación tratada y una de control?
4. ¿A qué nivel aleatorizo? ¿Cuánto vale ρ?

Preguntas que hay que hacerse

1. ¿Qué efecto mínimo quiero poder detectar? ¿Por qué ese? ¿Tengo presupuesto para detectarlo?
2. ¿Qué sé sobre la varianza del resultado en cada grupo? ¿De dónde lo saco?
3. ¿Cuánto cuesta una observación tratada y una de control?
4. ¿A qué nivel aleatorizo? ¿Cuánto vale ρ?
5. ¿Cuántas hipótesis voy a testear?

Preguntas que hay que hacerse

1. ¿Qué efecto mínimo quiero poder detectar? ¿Por qué ese? ¿Tengo presupuesto para detectarlo?
2. ¿Qué sé sobre la varianza del resultado en cada grupo? ¿De dónde lo saco?
3. ¿Cuánto cuesta una observación tratada y una de control?
4. ¿A qué nivel aleatorizo? ¿Cuánto vale ρ?
5. ¿Cuántas hipótesis voy a testear?
6. ¿Qué covariables previas al tratamiento tengo? ¿Cuántos asignados van a recibir el tratamiento?

Referencias

Referencias I

- Bessone, P., Rao, G., Schilbach, F., Schofield, H., & Toma, M. (2021). The economic consequences of increasing sleep among the urban poor. *The Quarterly Journal of Economics*, 136(3), 1887–1941.
- Carneiro, P., Koussihouèdé, O., Lahire, N., Meghir, C., & Mommaerts, C. (2015). Decentralizing education resources: School grants in Senegal. NBER Working Paper 21063.
- Carneiro, P., Lee, S., & Wilhelm, D. (2020). Optimal data collection for randomized control trials. *The Econometrics Journal*, 23(1), 1–31.
- Finkelstein, A. N., Taubman, S. L., Allen, H. L., Wright, B. J., & Baicker, K. (2016). Effect of Medicaid coverage on ED use. Further evidence from Oregon's experiment. *New England Journal of Medicine*, 375(16), 1505–1507.
- Holladay, S., LaRiviere, J., Novgorodsky, D., & Price, M. (2019). Prices versus nudges: What matters for search versus purchase of energy investments? *Journal of Public Economics*, 172, 151–173.
- Karlan, D., & List, J. A. (2007). Does price matter in charitable giving? Evidence from a large-scale natural field experiment. *American Economic Review*, 97(5), 1774–1793.
- Lin, W. (2013). Agnostic notes on regression adjustments to experimental data: Reexamining Freedman's critique. *The Annals of Applied Statistics*, 7(1), 295–318.

Referencias II

- List, J. A. (2001). Do explicit warnings eliminate the hypothetical bias in elicitation procedures? Evidence from field auctions for sportscards. *American Economic Review*, 91(5), 1498–1507.
- List, J. A. (2026). *Experimental economics: Theory and practice*. University of Chicago Press.
- List, J. A., Muir, I., & Sun, G. K. (2022). Using machine learning for efficient flexible regression adjustment in economic experiments. NBER Working Paper 30756.
- List, J. A., Sadoff, S., & Wagner, M. (2011). So you want to run an experiment, now what? Some simple rules of thumb for optimal experimental design. *Experimental Economics*, 14(4), 439–457.

Lecturas

Lecturas

Experimental Economics: Theory and Practice
List, J. A. (2026)

- Capítulo 5. *"Optimal Experimental Design"*

Contacto

Contacto

Email

juanifavetto@gmail.com

Teléfono

+54 9 2972 40-8438

Por favor evitar usar el webcampus

Apéndice

Apéndice

Varianza con clusters

¿Por qué se pierde precisión?

Sea $\sigma^2 = \text{var}(\nu_g) + \text{var}(\varepsilon_{ig})$. El promedio de un cluster es

$$\bar{Y}_g = \alpha + \bar{\tau} D_g + \nu_g + \frac{1}{m} \sum_{i=1}^{m} \varepsilon_{ig}$$

Su varianza es

$$\begin{aligned} \text{var}(\bar{Y}_g) &= \text{var}(\nu_g) + \frac{\text{var}(\varepsilon_{ig})}{m} \\ &= \sigma^2 \left[\rho + \frac{1-\rho}{m} \right] \\ &= \frac{\sigma^2}{m} \left[1 + (m-1)\rho \right] \end{aligned}$$

¿Por qué se pierde precisión?

Sea $\sigma^2 = \text{var}(\nu_g) + \text{var}(\varepsilon_{ig})$. El promedio de un cluster es

$$\bar{Y}_g = \alpha + \bar{\tau} D_g + \nu_g + \frac{1}{m} \sum_{i=1}^{m} \varepsilon_{ig}$$

Su varianza es

$$\begin{aligned} \text{var}(\bar{Y}_g) &= \text{var}(\nu_g) + \frac{\text{var}(\varepsilon_{ig})}{m} \\ &= \sigma^2 \left[\rho + \frac{1-\rho}{m} \right] \\ &= \frac{\sigma^2}{m} \left[1 + (m-1)\rho \right] \end{aligned}$$

Con $\rho = 0$ es la varianza del promedio de m unidades independientes. Con $\rho > 0$ queda multiplicada por $1 + (m-1)\rho$.

Apéndice

Diseños factoriales

Diseño factorial completo

- En Bessone et al. (2021) hay dos factores, la información y los dispositivos para dormir. Supongamos que cada uno está o no está.
- Un diseño factorial completo mide la respuesta en todas las combinaciones de niveles. Con dos factores binarios son 4 celdas, un diseño 2×2.

Diseño factorial completo

- En Bessone et al. (2021) hay dos factores, la información y los dispositivos para dormir. Supongamos que cada uno está o no está.
- Un diseño factorial completo mide la respuesta en todas las combinaciones de niveles. Con dos factores binarios son 4 celdas, un diseño 2×2.
- Las celdas crecen muy rápido. Con 8 factores hacen falta 256 celdas y con 9, 512. Llenarlas con poder suficiente para detectar efectos realistas es inviable.

Diseño factorial completo

- En Bessone et al. (2021) hay dos factores, la información y los dispositivos para dormir. Supongamos que cada uno está o no está.
- Un diseño factorial completo mide la respuesta en todas las combinaciones de niveles. Con dos factores binarios son 4 celdas, un diseño 2×2.
- Las celdas crecen muy rápido. Con 8 factores hacen falta 256 celdas y con 9, 512. Llenarlas con poder suficiente para detectar efectos realistas es inviable.
- Un diseño factorial fraccional llena sólo un subconjunto elegido de las celdas. Conviene si hay razones para creer que algunos factores actúan de forma independiente.

Tutorías y recursos online

Y son las notas, D_1 es tener tutor después de clase y D_2 es tener acceso a recursos online.

$$TestScores_i = \beta_0 + \beta_1(Tutor)_i + \beta_2(Resources)_i + \beta_3(Tutor \times Resources)_i + \epsilon_i$$

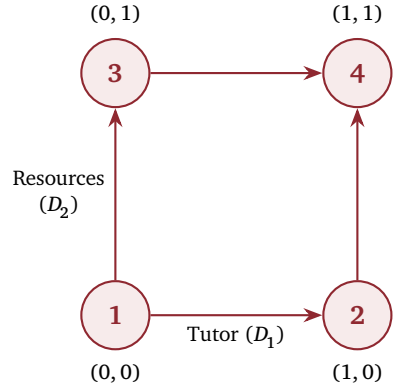


Exhibit 5.3.1A: Two 2-Level Factorial Design

Tutorías y recursos online

Y son las notas, D_1 es tener tutor después de clase y D_2 es tener acceso a recursos online.

$$TestScores_i = \beta_0 + \beta_1(Tutor)_i + \beta_2(Resources)_i + \beta_3(Tutor \times Resources)_i + \epsilon_i$$

- Sin la celda 4, $(1, 1)$, no podemos estimar β_3.

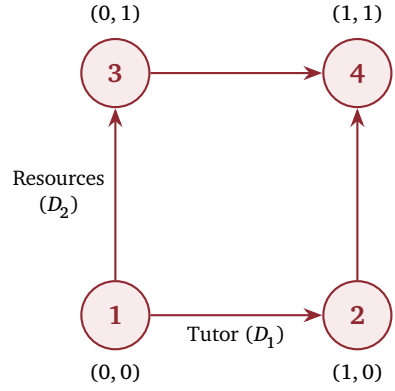


Exhibit 5.3.1A: Two 2-Level Factorial Design

Tutorías y recursos online

Y son las notas, D_1 es tener tutor después de clase y D_2 es tener acceso a recursos online.

$$TestScores_i = \beta_0 + \beta_1(Tutor)_i + \beta_2(Resources)_i + \beta_3(Tutor \times Resources)_i + \epsilon_i$$

- Sin la celda 4, $(1, 1)$, no podemos estimar β_3.
- Elegir entre el diseño completo y el fraccional es decidir si llenamos esa celda.

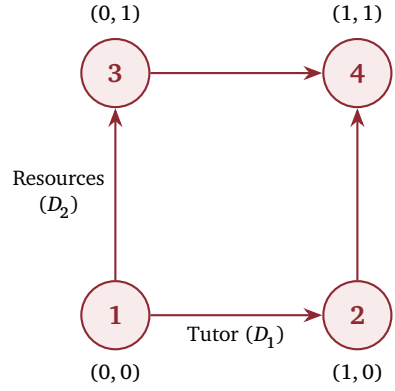


Exhibit 5.3.1A: Two 2-Level Factorial Design

¿Contra qué línea de base?

- El efecto de la tutoría puede medirse comparando la celda 2 con la 1, sin recursos online. Es el τ habitual.
- También comparando la celda 4 con la 3, para quienes ya tienen recursos online.

¿Contra qué línea de base?

- El efecto de la tutoría puede medirse comparando la celda 2 con la 1, sin recursos online. Es el τ habitual.
- También comparando la celda 4 con la 3, para quienes ya tienen recursos online.
- Con un tercer factor (un premio monetario por buenas notas) hay 8 celdas y cuatro estimaciones del efecto de la tutoría, una por cada combinación de los otros dos factores.

¿Contra qué línea de base?

- El efecto de la tutoría puede medirse comparando la celda 2 con la 1, sin recursos online. Es el τ habitual.
- También comparando la celda 4 con la 3, para quienes ya tienen recursos online.
- Con un tercer factor (un premio monetario por buenas notas) hay 8 celdas y cuatro estimaciones del efecto de la tutoría, una por cada combinación de los otros dos factores.
- Si esa información no hace falta, el diseño completo es ineficiente.

¿Contra qué línea de base?

- El efecto de la tutoría puede medirse comparando la celda 2 con la 1, sin recursos online. Es el τ habitual.
- También comparando la celda 4 con la 3, para quienes ya tienen recursos online.
- Con un tercer factor (un premio monetario por buenas notas) hay 8 celdas y cuatro estimaciones del efecto de la tutoría, una por cada combinación de los otros dos factores.
- Si esa información no hace falta, el diseño completo es ineficiente.
- Ojo. La comparación estándar (celda 2 contra 1) no tiene por qué coincidir con el efecto que tendría un experimento de tutorías entre quienes ya usan recursos online. Esa población se seleccionó sola, porque eligió tener los recursos.

Diseños fraccionales

Pasos para reducir un diseño completo.

1. Identificar los tratamientos (factores) y sus niveles, a partir de la teoría y de lo que necesita la investigación.
2. Elegir la fracción del diseño completo que vamos a usar (1/2, 1/4, 1/8).
3. Armar la matriz de diseño. Cada fila es una celda y cada columna, un factor.
4. Elegir la resolución.
5. Estimar los efectos principales y las interacciones de orden bajo.
6. Interpretar con cuidado las interacciones de orden alto, que quedan confundidas.

Resolución

La resolución de un diseño fraccional indica qué efectos quedan confundidos entre sí.

- **Resolución III:** los efectos principales quedan separados entre sí y se confunden con interacciones dobles.
- **Resolución IV:** los efectos principales quedan separados de las interacciones dobles. Las interacciones dobles se confunden entre sí.
- **Resolución V:** los efectos principales y las interacciones dobles quedan separados entre sí.

Resolución

La resolución de un diseño fraccional indica qué efectos quedan confundidos entre sí.

- **Resolución III:** los efectos principales quedan separados entre sí y se confunden con interacciones dobles.
- **Resolución IV:** los efectos principales quedan separados de las interacciones dobles. Las interacciones dobles se confunden entre sí.
- **Resolución V:** los efectos principales y las interacciones dobles quedan separados entre sí.

En las ciencias duras es común aceptar algo de confusión con los efectos principales para estimar interacciones. Para experimentos en economía, List recomienda resoluciones más altas. La prioridad es mantener separados los efectos principales.

Apéndice

Simular el poder

Poder por simulación

Las fórmulas cerradas dependen de supuestos fuertes sobre el efecto del tratamiento y la distribución de los resultados potenciales. Cuando no se cumplen, podemos simular el experimento antes de hacerlo.

Poder por simulación

Las fórmulas cerradas dependen de supuestos fuertes sobre el efecto del tratamiento y la distribución de los resultados potenciales. Cuando no se cumplen, podemos simular el experimento antes de hacerlo.

1. Escribimos un modelo que define todos los resultados potenciales, las variables no observadas y los errores.

Poder por simulación

Las fórmulas cerradas dependen de supuestos fuertes sobre el efecto del tratamiento y la distribución de los resultados potenciales. Cuando no se cumplen, podemos simular el experimento antes de hacerlo.

1. Escribimos un modelo que define todos los resultados potenciales, las variables no observadas y los errores.
2. Elegimos un tamaño de muestra provisorio N.

Poder por simulación

Las fórmulas cerradas dependen de supuestos fuertes sobre el efecto del tratamiento y la distribución de los resultados potenciales. Cuando no se cumplen, podemos simular el experimento antes de hacerlo.

1. Escribimos un modelo que define todos los resultados potenciales, las variables no observadas y los errores.
2. Elegimos un tamaño de muestra provisorio N.
3. Generamos una muestra de tamaño N con ese modelo. Es un experimento hipotético. Corremos el test.

Poder por simulación

Las fórmulas cerradas dependen de supuestos fuertes sobre el efecto del tratamiento y la distribución de los resultados potenciales. Cuando no se cumplen, podemos simular el experimento antes de hacerlo.

1. Escribimos un modelo que define todos los resultados potenciales, las variables no observadas y los errores.
2. Elegimos un tamaño de muestra provisorio N.
3. Generamos una muestra de tamaño N con ese modelo. Es un experimento hipotético. Corremos el test.
4. Repetimos muchas veces, con una muestra nueva cada vez.

Poder por simulación

Las fórmulas cerradas dependen de supuestos fuertes sobre el efecto del tratamiento y la distribución de los resultados potenciales. Cuando no se cumplen, podemos simular el experimento antes de hacerlo.

1. Escribimos un modelo que define todos los resultados potenciales, las variables no observadas y los errores.
2. Elegimos un tamaño de muestra provisorio N.
3. Generamos una muestra de tamaño N con ese modelo. Es un experimento hipotético. Corremos el test.
4. Repetimos muchas veces, con una muestra nueva cada vez.
5. Como conocemos la verdad, la proporción de rechazos de una nula falsa es el poder. La proporción de rechazos de una nula verdadera es el error tipo I.

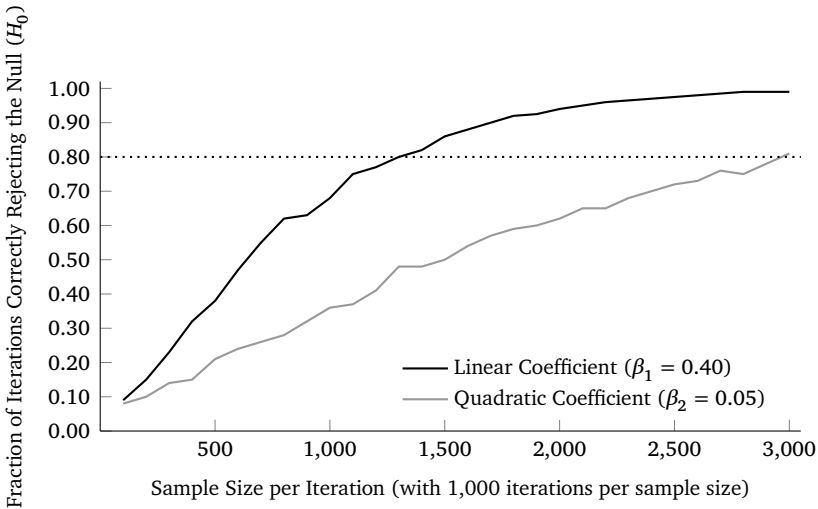
Dosis y respuesta con un resultado binario

Combina un resultado binario con varios niveles de tratamiento. La probabilidad de $Y_i = 1$ sigue un logit con un término lineal y uno cuadrático en D_i.

$$\log\left(\frac{p_i(\beta_0, \beta_1, \beta_2, D_i)}{1 - p_i(\beta_0, \beta_1, \beta_2, D_i)}\right) = \underbrace{-1.75}_{\beta_0} + \underbrace{0.40}_{\beta_1} \times D_i + \underbrace{0.05}_{\beta_2} \times D_i^2$$

- Para cada N, 1,000 iteraciones. En cada una testeamos si $\beta_1 = 0$ y si $\beta_2 = 0$.
- Todos los coeficientes son distintos de cero. Cada rechazo es correcto, así que la fracción de rechazos es el poder.

Exhibit 5.1.1A: The Power of Simulation for Illustrating Power and Required Sample Size



Fuente: List (2026), Exhibit 5.1.1A.

Resultados de la simulación

- Confirma lo que ya sabíamos. El poder crece con el tamaño de la muestra.

Resultados de la simulación

- Confirma lo que ya sabíamos. El poder crece con el tamaño de la muestra.
- Para llegar a 80% de poder, el término lineal necesita unas 1,300 observaciones. El cuadrático necesita unas 3,000.

Resultados de la simulación

- Confirma lo que ya sabíamos. El poder crece con el tamaño de la muestra.
- Para llegar a 80% de poder, el término lineal necesita unas 1,300 observaciones. El cuadrático necesita unas 3,000.
- Según qué coeficiente sea más importante para el análisis, la muestra necesaria puede más que duplicarse.